GoodGraph

Методичка по научной графике на Python

Принципы · нормативы · примеры «плохо/хорошо»

Версия 0.1 · ноябрь 2026

Содержание

Раздел 1. Принципы качественной научной графики 3
Раздел 2. Python-инструментарий и настройка среды 14
Раздел 3. Требования к научной графике: цвет, шрифты, размеры и форматы 26
Раздел 4. Основные виды научных графиков и области применения 35
5.01 Линейный график: динамика во времени 41
5.02 Ступенчатый график: события и дискретные изменения 45
5.03 Area chart: площадь как величина 49
5.04 Small multiples: много панелей, одна логика 53
5.05 Scatter: связь двух непрерывных величин 57
5.06 Hexbin: плотность тысяч точек 61
5.07 Contour: изолинии плотности 65
5.08 LOESS: нелинейный тренд 69
5.09 Гистограмма: распределение одной величины 73
5.10 ECDF: функция распределения 77
5.11 Boxplot: сравнение распределений по группам 81
5.12 Violin: форма распределения 86
5.13 Strip: все точки по группам 90
5.14 Dot + CI: оценка и неопределённость 94
5.15 Bar: сравнение величин 98
5.16 Forest: эффект по подгруппам 102

Раздел 1. Принципы качественной научной графики

График в научной работе — не украшение и не «картинка к тексту». Это способ рассуждения о данных: читатель должен за несколько секунд увидеть закономерность, оценить её величину и понять, насколько ей можно доверять. Поэтому разговор о графике начинается не с библиотек и не с цветов, а с вопроса: **что именно читатель должен понять и какое решение принять?**

Этот раздел задаёт систему координат для всей методички. Сначала — смысловые принципы: честность, контекст, неопределённость, иерархия. Затем — нормативы и оформление: размеры, шрифты, цвет, единицы, подписи. В конце — разбор одного и того же результата в двух версиях: «плохой» и «правильной».

> Все данные в примерах синтетические. Они правдоподобны по единицам и величинам, но не описывают реальных пациентов.

1.1 «Правильный» и «качественный»: два разных требования

Полезно развести два прилагательных, которые часто используют как синонимы.

Правильный график (valid, truthful) — тот, который не искажает данные и не нарушает нормы:

- масштаб осей соответствует типу кодирования;
- статистика показана корректно (есть *n*, разброс, определение ошибок);
- единицы измерения указаны;
- подпись самодостаточна;
- рисунок соответствует требованиям журнала или ГОСТ.

Качественный график (effective, craft) — тот, который решает задачу читателя:

- сообщение считывается за несколько секунд;
- визуальная иерархия ведёт взгляд от главного к второстепенному;
- палитра доступна при дальтонизме и в чёрно-белой печати;
- шрифты и размеры комфортны в конечном физическом размере;
- график согласован с остальными рисунками работы;
- результат воспроизводим по данным и коду.

Эти требования независимы. График может быть правильным, но бесполезным: аккуратные столбики с *n*, SD и единицами, по которым невозможно ничего сравнить. И наоборот: эффектный график с градиентами и тенями может быть красивым, но лживым. Методичка — о том, как удержать оба требования одновременно.

Главный тезис. График проектируется от вопроса читателя и структуры данных, а не от возможностей библиотеки. Matplotlib умеет рисовать 3D-пончики; это не аргумент в пользу 3D-пончиков.

1.2 Смысловые принципы

1.2.1 Сначала сообщение, потом график

Перед первой строкой кода сформулируйте одно предложение:

> «После этого графика читатель должен понять, что препарат B снижает САД примерно вдвое сильнее плацебо, и что разброс между пациентами велик».

Если предложение не формулируется, график, скорее всего, не нужен: данные лучше показать таблицей. Если предложений два, это два графика или две панели A и B.

Из этого следуют практические правила:

- **Заголовок — вывод, а не тема.** «Результаты исследования» сообщает ноль информации. «Препарат B снижает САД вдвое сильнее плацебо» — сообщает вывод и заодно объясняет, что читать на графике.
- **Один график — одна мысль.** Если хочется показать и динамику, и сравнение групп, и корреляцию, — это три панели, а не один «комбайн».
- **Главное — крупнее и контрастнее.** Основная серия или эффект должны визуально доминировать; вспомогательные — уходить на второй план.
- **Читатель не обязан знать контекст.** График должен работать вместе с подписью, но не вместо неё.

Заголовок внутри рисунка — спорная территория. Для слайдов, отчётов и внутренних документов он полезен. Для журнальной публикации многие редакции предпочитают не дублировать заголовок в изобра-

жении и в подписи: содержательный вывод переносят в caption. Проверяйте гайд журнала; в этой методичке заголовок оставлен как дидактический приём.

1.2.2 Форму определяют данные

Тип графика — не вкусовое решение. Он определяется:

- типом переменных (категориальные, непрерывные, временные, парные);
- числом наблюдений и групп;
- наличием распределения, выбросов, цензурирования;
- задачей: сравнить, показать связь, распределение, динамику, состав.

Минимальная таблица соответствия:

Задача	Рекомендуемая форма	Почему
Сравнить несколько категорий	точка с доверительным интервалом, полоса, столбцы	положение читается точнее длины
Показать распределение	гистограмма, ECDF, box, violin, strip	виден разброс и форма, а не только среднее
Связь двух непрерывных	диаграмма рассеяния, hexbin, contour	видна форма зависимости и выбросы
Динамика во времени	линия; small multiples для многих серий	время должно идти по оси X
Доля целого	stacked bar, 100 % bar; круговая — только для 3–5 долей	углы и площади читаются хуже длины
Матрица значений	heatmap с ограниченной палитрой	цвет кодирует величину, но требует шкалы
Парные измерения	slope chart, paired dot plot	видно направление изменения у каждого объекта
Оценки и неопределённость	forest plot	компактно показывает эффект и ДИ
Выживаемость	Kaplan–Meier с числом рисков	цензурирование нельзя игнорировать
Диагностическая точность	ROC-кривая, precision–recall	зависит от prevalence
Многомерные наблюдения	small multiples, PCA/biplot (осторожно)	уменьшение размерности меняет интерпретацию

Подробный разбор видов графиков — в разделе 4, примеры с кодом — в разделе 5.

Полезно помнить «грамматику графики» (Wilkinson, 1999; ggplot2): данные → эстетические отображения → геометрия → шкалы → грани. Matplotlib мыслит императивно («нарисуй линию здесь»), ggplot2 и plotnine — декларативно («свяжи x и y, сгруппируй по цвету»). Оба подхода допустимы; декларативный лучше защищает от несогласованности, императивный — даёт полный контроль.

1.2.3 Честность масштаба

Это самый частый источник визуальной лжи — и самый простой для исправления.

Столбцы кодируют длину. Длина обязана начинаться с нуля. Если ось Y обрезана, читатель сравнивает не значения, а обрезки. Пример из раздела 1.4: средние 4,2 и 9,0 мм рт. ст., ось начинается с 3,5. Визуально препарат B «в 7,5 раза больше» плацебо, хотя в данных разница в 2,1 раза. Коэффициент искажения (lie factor, Tufte):

> **LF** = (5,46 / 0,73) / (8,96 / 4,23) ≈ 3,5.

Значения LF заметно выше 1 или заметно ниже 1 означают искажение; Tufte предлагал считать допустимым диапазон примерно 0,95–1,05.

Точки и линии кодируют положение. Для них нулевая отметка не обязательна: если весь смысл в изменении на 2–3 единицы, растянутая ось помогает увидеть тренд. Но у этого есть условия:

- ось явно подписана, диапазон не скрывает важный контекст;
- читатель не принят за дурака: обрезка не маскирует выбросы и не создаёт ложный «обвал» или «взлёт»;
- для сравнения нескольких серий шкалы одинаковы, если это возможно.

Логарифмическая шкала допустима для величин, которые меняются мультипликативно (титры антител, вирусная нагрузка, концентрации), и только для положительных значений. Она обязана быть подписана: «лог. шкала, основание 10». Логарифм не «улучшает» график — он меняет вопрос, на который тот отвечает.

Разрыв оси допустим как крайняя мера для выбросов, с явными метками разрыва. Для столбцов — недопустим: он ломает длину. **Две оси Y** на одном графике почти всегда создают ложную корреляцию: две произвольно масштабированные величины всегда можно «подогнать» так, чтобы линии пересеклись в нужном месте. Если без этого нельзя обойтись, кодируйте оси цветом, подписывайте единицы и объясняйте, почему две панели хуже.

Пропорции. Для временных рядов удачный приём — «banking to 45°»: выбирать соотношение сторон так, чтобы типичный наклон тренда был около 45°. Слишком широкий график сглаживает изменения, слишком узкий — драматизирует. Для сравнения наклонов в scatter-plot полезна квадратная область.

1.2.4 Неопределённость, распределение и *n*

Столбик со средним и «усиками» — не универсальный график. У него есть презрительное, но точное название — *dynamite plot*: он скрывает форму распределения, число наблюдений и выбросы. Weissgerber и соавторы (2015) показали, как часто такие графики искажают картину в биомедицинских статьях.

Что показывать:

- ***n* для каждой группы** — в подписи или на оси.
- **Разброс**: отдельные точки при небольшом *n*, box/violin или strip при большем, SD/CI — как дополнение, а не замена.
- **Определение ошибок**: SD, SEM и 95 % ДИ — разные вещи.

Обозначение	Что характеризует	Как читать
SD	разброс наблюдений вокруг среднего	«насколько разные пациенты»
SEM	точность выборочного среднего, SD/√*n*	«насколько точно измерено среднее», не разброс
95 % ДИ	неопределённость среднего	при повторных выборках накрывал бы истинное среднее в 95 % случаев

Частая ошибка — подписать «mean ± SEM», а в тексте интерпретировать как «разброс». Ещё чаще — использовать 95 % ДИ как «диапазон, в котором лежат 95 % данных»: это неверно, для этого нужен интервал предсказания или перцентили.

Для парных измерений (до/после у одного пациента) столбики независимых групп теряют связь между наблюдениями. Показывайте пары: slope chart или paired dot plot. Для скошенных данных — медиана и межквартильный интервал, а не среднее и SD.

И наконец: **эффект и его неопределённость важнее p-значения**. «$p < 0{,}05$» не говорит, насколько велик эффект и насколько он клинически значим. Показывайте разницу средних, отношение рисков, hazard ratio — с 95 % ДИ.

1.2.5 Контекст и воспроизводимость

График без контекста — головоломка. Минимальный набор:

- единицы измерения на осях и в подписи;
- *n* и способ формирования групп;
- что означают ошибки/полосы;
- статистический тест или модель, если они упомянуты;
- программное обеспечение и версия (для воспроизводимости);
- доступность данных и кода, если это допускает журнал.

Дополнительно:

- **Согласованность групп.** Один и тот же цвет и порядок групп во всех рисунках статьи. Читатель не должен каждый раз заново расшифровывать легенду.
- **Нормализация.** «Относительно контроля» — относительно какого контроля, что именно делили, что делать с нулями? Всё это — в подпись.
- **Пропуски.** Если данные исключены, покажите сколько и почему.
- **Версии.** «Построено в Python 3.12, matplotlib 3.11, seaborn 0.13» — дешёвая и полезная строка в подписи или supplementary.

1.2.6 Иерархия, минимализм и декор

Эдвард Тафти ввёл два полезных понятия: **data-ink ratio** (доля «чернил», которая кодирует данные) и **chartjunk** (декор, не несущий информации). Практический вывод: убирайте всё, что не помогает читать данные.

Что обычно лишнее:

- тени, псевдо-3D, градиенты, не кодирующие величину;
- тяжёлая сетка по обеим осям и полная рамка;
- легенда, дублирующая подписи оси;
- декоративные иконки, фоны, текстуры;
- подписи «Рисунок 1» внутри изображения;
- несколько акцентных цветов без семантики.

Но минимализм — не самоцель. Убрать единицы, *n* или подпись оси — это не минимализм, а потеря информации. Хороший график не «пустой», а **иерархичный**:

1. данные — самый контрастный слой;
2. оси, подписи, аннотации — средний;
3. сетка, рамки, фон — самый бледный.

Полезные приёмы:

- **прямые подписи** вместо легенды, если серий немного;
- **один акцентный цвет** для главного вывода, серый — для контекста;
- **лёгкая сетка** только по той оси, где она помогает читать значения;
- **белое пространство** как способ группировки, а не «пустота».

1.2.7 Доступность

Около 8 % мужчин европейского происхождения имеют нарушения цветового зрения (протанопия или дейтеранопия); среди женщин доля ниже, но не нулевая. В зале на 250 человек, по оценке Color Universal Design, может быть больше десяти человек с дальтонизмом. Рецензент тоже может быть одним из них.

Правила:

- **Не кодировать смысл только цветом.** Дублируйте формой маркера, типом линии, прямой подписью, штриховкой.
- **Использовать палитры, проверенные на дальтонизм**: Okabe–Ito, Paul Tol, viridis/cividis для последовательных шкал.
- **Проверять в оттенках серого.** Если после обесцвечивания серии неразличимы — добавить форму или подпись.
- **Контраст.** Для текста — не ниже 4,5:1, для графических объектов — не ниже 3:1 (WCAG 2.1).
- **Кегль в конечном размере.** Шрифт 6 pt, который «нормально смотрится» на экране в 200 %, в журнале превратится в нечитаемую полосу.
- **Alt-текст** для веб-версий и доступных PDF.

1.2.8 Согласованность

Серия рисунков в статье должна выглядеть как один документ, а не как коллаж из разных статей. Единый визуальный язык:

- одна гарнитура и 2–3 кегля;
- одна палитра и одно соответствие «цвет → группа»;
- одинаковые толщины линий, размеры маркеров, стиль сетки;
- одинаковое расположение меток панелей (A, B, C) — слева сверху;
- одинаковый десятичный разделитель и формат дат;
- одинаковые единицы и сокращения.

Если на рисунке 1 плацебо серое, на рисунке 2 оно тоже серое. Если на рисунке 3 появился новый препарат — он получает новый цвет, а не переиспользует цвет старого.

1.2.9 Проверка «пять секунд — тридцать секунд — пять минут»

Быстрый тест перед отправкой:

1. **Пять секунд.** Что читатель понял? Если ответ «какие-то столбики» — график не работает.

2. **Тридцать секунд.** Можно ли прочитать значения, единицы, *n* и понять, что означают усы? Если нет — не хватает подписей.
3. **Пять минут.** Можно ли восстановить, как получены данные, что такое ошибки, есть ли выбросы и не противоречит ли график тексту? Если нет — подпись не самодостаточна.

1.3 Нормативы и оформление

1.3.1 Какие документы задают правила

Иерархия проста: **требования журнала важнее ГОСТ**, если вы отправляете статью. ГОСТ и локальные шаблоны — для диссертаций, отчётов о НИР и внутренних документов.

Документ	Что регулирует	Комментарий
Гайд журнала (Instructions for Authors)	размеры, шрифты, форматы, число рисунков, captions	всегда проверяйте перед отправкой
ICMJE Recommendations	общие нормы медицинских журналов, подготовка рукописи	icmje.org
EQUATOR Network	отчётные стандарты (CONSORT, STROBE, PRISMA, ARRIVE)	equator-network.org
COPE	публикационная этика, целостность изображений	publicationethics.org
ГОСТ 7.32-2017	отчёт о НИР: структура, рисунки, подписи	docs.cntd.ru
ГОСТ 2.105-95	ЕСКД: общие требования к текстовым документам	docs.cntd.ru
ГОСТ 8.417-2002	единицы величин	docs.cntd.ru

Отчётные стандарты важны не только для текста. CONSORT требует схему потока участников, STROBE — аккуратного описания выборки, PRISMA — блок-схему отбора исследований, ARRIVE — деталей экспериментов на животных. Это тоже «научная графика», и к ней предъявляются те же требования.

Целостность изображений. Нельзя selectively enhance, замазывать, склеивать фрагменты без явных границ, менять яркость так, чтобы исчезали детали. Любая обработка — в подписи или supplementary. Это прямая норма COPE и ICMJE, а не «стилистика».

1.3.2 Размер, разрешение, формат

Проектируйте в конечном размере. Если рисунок будет шириной 85 мм, не рисуйте его в 16 дюймов и не уменьшайте в Word: шрифты и толщины превратятся в лотерею.

Параметр	Типичное требование	Комментарий
Ширина	85–90 мм (1 колонка), 170–183 мм (2 колонки)	Nature: 89 и 183 мм
Шрифт	sans-serif, 7–10 pt в конечном размере	нижняя граница 5–7 pt у отдельных журналов
Линии	0,25–1 pt	тоньше 0,25 pt может исчезнуть при печати
Растр	300 dpi для фото, 600–1200 dpi для штриховых	TIFF/PNG, без JPEG для линий
Вектор	PDF, EPS, SVG, AI	предпочтительно для графиков и схем
Цвет	RGB/sRGB для онлайн, CMYK для печати	конвертировать в конце, проверять gamut
Поля	3–5 мм	чтобы подписи не обрезались

Практические следствия:

- **Не скриншот.** Экспорт из Python, R, GraphPad, Origin — но не снимок экрана: скриншот теряет вектор и разрешение.
- **Шрифты — в кривые или встраивать.** Для SVG удобно `svg.fonttype = "path"`; для PDF — `pdf.fonttype = 42`, чтобы текст оставался редактируемым, но не подменялся при просмотре.
- **Не масштабировать непропорционально.** Растянутый по ширине график меняет восприятие наклонов и пропорций.
- **Проверять в 100 %.** Откройте итоговый PDF при реальном размере и посмотрите, читаются ли деления и легенда.

1.3.3 Шрифты

Для рисунков почти всегда лучше **sans-serif**: Arial, Helvetica, Liberation Sans, DejaVu Sans. Они плотнее и лучше читаются в мелком кегле, чем засечные гарнитуры.

Элемент	Ориентир
Заголовок внутри рисунка	9–10 pt
Подписи осей	8–9 pt
Деления и подписи делений	7–8 pt
Легенда	7–8 pt
Подпись к рисунку (caption)	8–9 pt, обычно в тексте, не в изображении

Правила:

- одна гарнитура на весь рисунок и, желательно, на всю статью;
- не писать подписи КАПСОМ — это замедляет чтение;
- не делать всё жирным: жирный — только для акцента;
- не использовать тонкие начертания (Light, Thin) в мелком кегле;
- проверить кириллицу и специальные символы: μ, ±, ≥, ≤, →, °C;
- математические переменные — курсивом (*p*, *n*, *M*), единицы — прямым;
- не смешивать в одном рисунке разные семейства шрифтов без причины.

1.3.4 Цвет

Цвет должен **кодировать смысл**, а не оживлять картинку.

Три типа палитр:

- **качественная** — для категорий (группы, препараты, регионы);
- **последовательная** — для упорядоченных значений (концентрация, время);
- **дивергентная** — для отклонений от нуля/нормы (изменение, разница).

Базовый набор, который стоит запомнить, — палитра Okabe–Ito:

Цвет	HEX	Разумная роль
оранжевый	`#E69F00`	категория 1
небесно-голубой	`#56B4E9`	категория 2
сине-зелёный	`#009E73`	категория 3
жёлтый	`#F0E442`	категория 4 (только с тёмным контуром)
синий	`#0072B2`	основной результат
вермилион	`#D55E00`	акцент/второй результат
красновато-фиолетовый	`#CC79A7`	категория 5
чёрный	`#000000`	текст, оси, а не серии

Правила:

- не больше 6–8 категориальных цветов; больше — объединяйте или делайте small multiples;
- не используйте «радугу» и `jet`: она создаёт ложные границы и не воспринимается равномерно;
- не кодируйте противоположные категории только красным и зелёным;
- серый — для контроля, фона и «прочего»; он не должен конкурировать с данными;
- проверяйте рисунок в градациях серого и через симулятор дальтонизма;
- фон — белый (для печати), без тёмных тем;
- контраст графических объектов — не ниже 3:1.

Для последовательных шкал используйте `viridis`, `cividis`, `Blues`, `Greens`; для дивергентных — `RdBu_r`, `PuOr`, `BrBG` с симметричным диапазоном относительно нуля. Центр дивергентной шкалы должен совпадать с содержательным нулём, а не с серединой диапазона данных.

1.3.5 Единицы, числа, статистика

- **СИ и общепринятые медицинские единицы.** «мм рт. ст.» — внесистемная, но допустимая в медицине единица; «мг/кг», «ммоль/л», «уд/мин».

- **Пробел между числом и единицей:** 8,9 мм рт. ст., 10 мг, 5 %, 37 °C. Исключения — знаки градусов угла и некоторые типографские случаи.
- **Десятичный разделитель.** В русском тексте — запятая, в англоязычных журналах — точка. Главное — единообразие в пределах работы. В коде и CSV обычно точка; в подписях рисунка — по языку публикации.
- **Ведущий ноль:** 0,05, а не ,05.
- **Тысячи:** 12 000, а не 12000, в тексте; в осях можно 12 000 или 12 тыс.
- **Средние:** M ± SD; медиана и IQR: Me [Q1; Q3]; доли: n (%).
- **p-значение:** p = 0,032, а не «p<0.05» без точного значения, если журнал не требует иначе. Курсив для p, n, M.
- **Сокращения** расшифровывайте при первом упоминании в подписи.

1.3.6 Подписи к рисункам

Подпись — не «название файла», а самостоятельный текст. Хорошая структура:

1. **Что показано** — одно предложение с выводом или темой.
2. **Как показано** — группы, n, что означают точки/столбцы/усы.
3. **Определения** — ошибки, сокращения, статистический тест.
4. **Источник/ПО** — данные, код, версия, при необходимости.

Плохо:

> Рисунок 1. Результаты.

Хорошо:

> **Рисунок 1.** Снижение систолического АД через 12 недель терапии. Точки — индивидуальные значения пациентов, маркеры — среднее, усы — 95 % доверительный интервал (t-распределение). Плацебо — n = 48, препарат А 10 мг — n = 51, препарат В 20 мг — n = 49. Штриховая линия — отсутствие изменения. Данные синтетические; код — `01_principles/scripts/good_plot.py`.

Формальные детали:

- в ГОСТ 7.32 подпись обычно начинается с «Рисунок 1 — Название» (с тире);
- в англоязычных журналах — «Figure 1. …»;
- подпись располагается под рисунком, а не внутри изображения;
- точка в конце подписи — по стилю журнала;
- ссылка в тексте — до появления рисунка: «(рисунок 1)» или «(Fig. 1)».

1.3.7 Чек-лист перед отправкой

- ☐ Заголовок/подпись сообщают вывод, а не «результаты».
- ☐ Тип графика соответствует задаче и структуре данных.
- ☐ Столбцы начинаются с нуля; обрезка осей объяснена.
- ☐ Логарифмическая шкала подписана.
- ☐ Нет двух осей Y без крайней необходимости.
- ☐ Показаны n, разброс и определение ошибок.
- ☐ Единицы указаны на осях и в подписи.
- ☐ Цвета различимы при дальтонизме и в градациях серого.
- ☐ Шрифт ≥ 7 pt в конечном размере; кириллица и символы не потеряны.
- ☐ Ширина соответствует колонке журнала (85/170 мм или гайд).
- ☐ Вектор или растр ≥ 300 dpi; нет скриншотов.
- ☐ Верхняя и правая рамки, тяжёлая сетка, тени и 3D убраны.
- ☐ Легенда не дублирует подписи и не закрывает данные.
- ☐ Подпись самодостаточна: группы, n, тест, сокращения.
- ☐ Рисунок согласован с другими рисунками по палитре и шрифтам.
- ☐ Нет искажений изображения и необъявленной обработки.
- ☐ Файлы названы по схеме журнала; формат и цветовой профиль проверены.
- ☐ Рисунок проверен в PDF при 100 % масштабе.

1.4 Один результат — два графика

Ниже — один и тот же набор данных: 148 пациентов, три группы, изменение САД через 12 недель. Слева — «плохая» версия, справа — «правильная». Обе построены по одному CSV; различается только код визуализации.

1.4.1 Плохой график

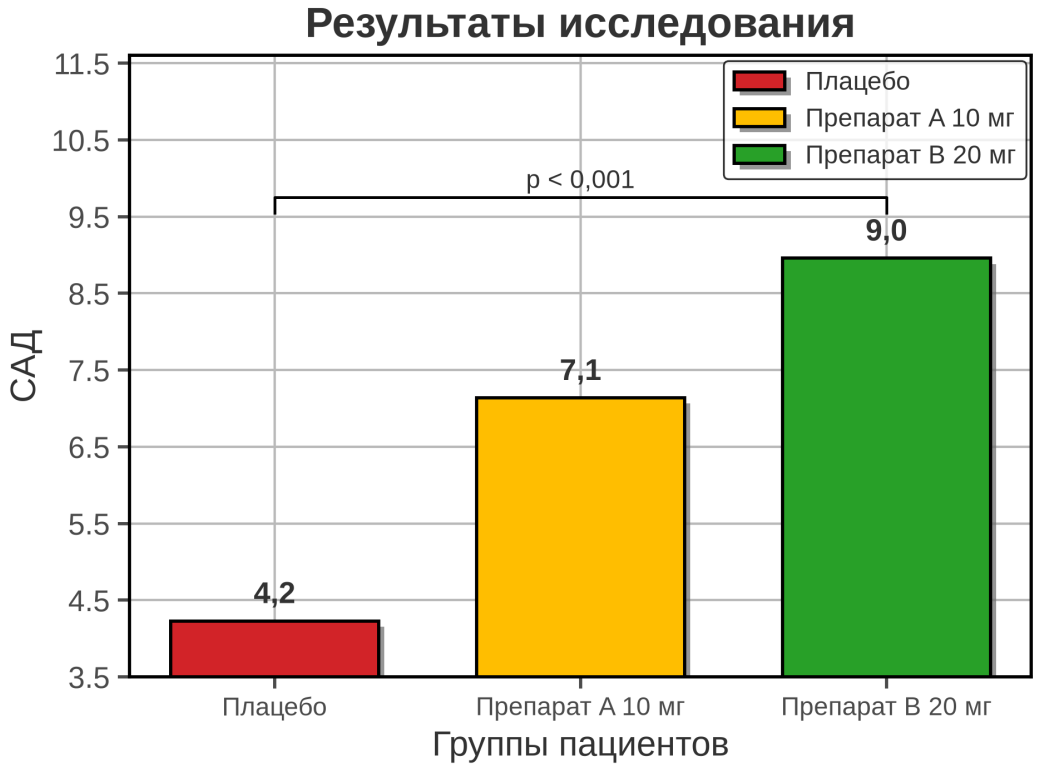


Рисунок 1.1. Плохой график: обрезанная ось, светофорная палитра, тени, тяжёлая сетка и легенда внутри поля данных.

Код: `01_principles/scripts/bad_plot.py`. Данные: `data/00_dataset.csv`.

1.4.2 Что с ним не так

1. **Обрезанная ось.** Столбцы начинаются с 3,5 мм рт. ст., а не с нуля. Визуальное отношение В/плацебо — около 7,5, реальное — 2,1. Lie factor ≈ 3,5.
2. **Светофорная палитра.** Красный — жёлтый — зелёный не только неразличим при протанопии/дейтеранопии, но и навязывает оценку «плохо — средне — хорошо», которой в данных нет.
3. **Тени и псевдо-3D.** Тень не кодирует ни одну переменную; она лишь утяжеляет нижнюю часть столбцов и мешает сравнивать высоту.
4. **Тяжёлая сетка по обеим осям.** Сетка конкурирует с данными; вертикальные линии вообще не помогают читать столбцы.
5. **Полная рамка и жирные линии.** Визуальный шум, который не несёт смысла.
6. **Легенда дублирует подписи.** Названия групп уже написаны под столбцами; легенда занимает место и закрывает часть данных.
7. **Заголовок «Результаты исследования».** Он не сообщает, что именно показано и какой вывод должен сделать читатель.
8. **Нет единиц, *n*, разброса и определения ошибок.** «САД» — это что: исходное, конечное, изменение? В каких единицах? Сколько пациентов?
9. **Только средние.** Без индивидуальных точек и ДИ нельзя понять, насколько велик разброс и насколько устойчива разница.
10. **p < 0,001 без теста и эффекта.** Значимость не заменяет величину эффекта; не указано, какой тест применялся и какие группы сравнивались.

1.4.3 Правильный график

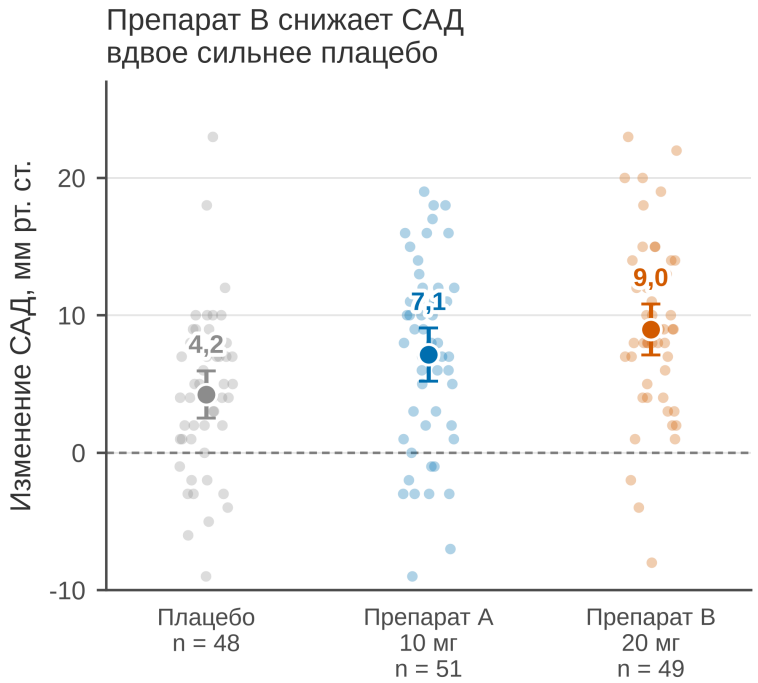


Рисунок 1.2. Правильный график: индивидуальные точки, среднее и 95 % ДИ, нулевая линия, палитра Okabe–Ito, прямые подписи.

Код: `01_principles/scripts/good_plot.py`.

1.4.4 Что улучшено

1. **Точечная оценка вместо длины.** Средние показаны точками, а не столбцами; обрезать ось больше не нужно, ложной разницы не возникает.
2. **Нулевая линия.** Штриховая линия на нуле показывает отсутствие эффекта и помогает оценить клиническую значимость.
3. **Индивидуальные наблюдения.** Полупрозрачные точки показывают разброс, выбросы и то, что у части пациентов САД выросло.
4. **Среднее и 95 % ДИ.** Видна неопределённость оценки; в подписи указано, что это t-интервал.
5. **Семантическая палитра.** Серый — контроль, синий — препарат A, вермилион — препарат B. Цвета различимы при дальтонизме, а подписи групп дублируют цвет.
6. **Прямые подписи и *n*.** Названия групп и число пациентов — прямо под осью; легенда не нужна.
7. **Заголовок-вывод.** «Препарат B снижает САД вдвое сильнее плацебо» сразу задаёт вопрос, на который отвечает график.
8. **Единицы и десятичная запятая.** «Изменение САД, мм рт. ст.» — без догадок; числа в русской типографике.
9. **Иерархия.** Лёгкая сетка только по Y, нет верхней и правой рамок, данные контрастнее осей.
10. **Журнальный размер.** 85 мм в ширину, кегли 7–9,5 pt; рисунок спроектирован в конечном размере, а не уменьшен из «слайда».

1.4.5 Сопоставление

Что было	Почему плохо	Что сделано
ось Y от 3,5	длина столбца искажена, LF ≈ 3,5	точки + нулевая линия
красный/жёлтый/зелёный	ложная семантика, CVD	Okabe–Ito: серый/синий/вермилион
тени, 3D	декор, искажает площадь	плоские маркеры
сетка по X и Y	шум, конкуренция с данными	сетка только по Y, бледная
полная рамка	визуальный шум	только левая и нижняя оси
легенда	дублирует подписи, закрывает данные	прямые подписи под осью
«Результаты исследования»	нет сообщения	заголовок-вывод
нет единиц и *n*	невозможно прочитать	единицы, *n* в подписях
только средние	скрыт разброс	точки + среднее + 95 % ДИ
p < 0,001	нет теста и эффекта	эффект и ДИ; тест — в подписи

Пара честных оговорок:

- График показывает изменение от исходного уровня, но не заменяет статистическую модель. Для сравнения групп с поправкой на исходное САД нужен ANCOVA или смешанная модель; рисунок этого не «исправляет».
- При $n \approx 50$ точек на группу strip plot может выглядеть шумно. Альтернативы — box/violin с точками, half-violin, или среднее с ДИ на фоне распределения. Выбор зависит от сообщения и от того, что важнее: форма распределения или компактность.

1.4.6 Как воспроизвести

```
# из корня репозитория
uv sync
uv run python 01_principles/scripts/make_data.py
uv run python 01_principles/scripts/bad_plot.py
uv run python 01_principles/scripts/good_plot.py
```

Ключевой фрагмент «правильного» кода:

```
from goodgraph import apply_style, figure_size, save_figure

apply_style()
fig, ax = plt.subplots(
    figsize=figure_size("single", ratio=0.90),
    layout="constrained",
)

# ... точки, средние, 95 % ДИ ...

ax.set_ylabel("Изменение САД, мм рт. ст.")
ax.set_title("Препарат В снижает САД\nвдвое сильнее плацебо", loc="left")
save_figure(fig, "01_good_dot_ci")  # images/01_good_dot_ci.svg + .png
```

Доверительный интервал считается через t-распределение, а не «среднее ± 2 SE»:

```
from scipy import stats

se = sd / np.sqrt(n)
half_width = stats.t.ppf(0.975, df=n - 1) * se
ci_low, ci_high = mean - half_width, mean + half_width
```

Для больших n разница с нормальным приближением мала, но t-интервал корректнее при $n \approx 50$ и менее.

1.5 Итоги раздела

Десять тезисов, которые стоит запомнить:

1. График — аргумент, а не украшение; сначала сообщение, потом код.
2. Тип графика определяется задачей и структурой данных.
3. Столбцы — с нуля; точки и линии — могут без нуля, но с объяснением.
4. Логарифм, разрыв оси и две оси Y — только осознанно и с подписями.
5. Показывайте n, разброс и неопределённость; определяйте, что такое усы.
6. Эффект и 95 % ДИ важнее p-значения.
7. Убирайте chartjunk, но не путайте минимализм с потерей информации.
8. Цвет — смысл; палитра должна работать при дальтонизме и в сером.
9. Подпись самодостаточна; рисунок согласован с остальными.
10. Проектируйте в конечном размере и проверяйте в PDF при 100 %.

Дальше — инструменты. В разделе 2 разберём, как это реализуется в Python: matplotlib, seaborn, plotnine, настройка среды через uv и типичные архитектурные решения для воспроизводимых графиков.

Источники к разделу

- Tufte E. R. *The Visual Display of Quantitative Information*. Graphics Press, 1983. — edwardtufte.com
- Cleveland W. S., McGill R. Graphical Perception: Theory, Experimentation, and Application to the Development of Graphical Methods // *JASA*. 1984. Vol. 79, № 387. P. 531–554. — doi:10.1080/01621459.1984.10478080
- Wilke C. O. *Fundamentals of Data Visualization*. O’Reilly, 2019. — clauswilke.com/dataviz
- Cairo A. *The Truthful Art: Data, Charts, and Maps for Communication*. New Riders, 2016. — thefunctionalart.com
- Schwabish J. *Better Data Visualizations: A Guide for Scholars, Researchers, and Wonks*. Columbia University Press, 2021. — policyviz.com
- Okabe M., Ito K. Color Universal Design (CUD): How to Make Figures and Presentations that are Friendly to Colorblind People. 2008. — jfly.uni-koeln.de/color
- ColorBrewer 2.0 — colorbrewer2.org
- Weissgerber T. L. et al. Beyond Bar and Line Graphs: Time for a New Data Presentation Paradigm // *PLoS Biology*. 2015. Vol. 13, № 4. e1002128. — doi:10.1371/journal.pbio.1002128
- ICMJE Recommendations — icmje.org
- EQUATOR Network — equator-network.org
- Nature. Formatting guide — nature.com
- W3C. WCAG 2.1, Understanding SC 1.4.11 Non-text Contrast — w3.org
- ГОСТ 7.32-2017 — docs.cntd.ru
- ГОСТ 2.105-95 — docs.cntd.ru
- ГОСТ 8.417-2002 — docs.cntd.ru

Раздел 2. Python-инструментарий и настройка среды

В разделе 1 мы договорились, каким должен быть график: честным, читаемым, доступным и воспроизводимым. Теперь — чем его рисовать. Задача этого раздела — не выучить все функции matplotlib, а понять, **как устроен стек** и **как получить воспроизводимый результат** из любого места: с ноутбука, из CI, с другого компьютера.

Хорошая новость: инструменты не определяют качество графика. Плохой график можно сделать и в matplotlib, и в ggplot2. Но разные библиотеки по-разному заставляют думать о данных. Matplotlib даёт полный контроль и требует дисциплины. Seaborn берёт на себя статистику и группы. Plotnine заставляет описать график как композицию слоёв. Выбор — не религия, а вопрос задачи.

> Все примеры раздела используют собственный набор `data/02_python_dataset.csv` (HbA1c, 132 пациента). Данные синтетические: раздел про инструменты, а не про новую клиническую гипотезу.

2.1 Карта экосистемы

Инструмент	Роль	Документация	Когда нужен
Python 3.12	язык и рантайм	docs.python.org	всегда
uv	окружения, зависимости, версии Python	docs.astral.sh/uv	всегда
NumPy	массивы, векторизованная математика	numpy.org/doc	расчёты, генерация данных
pandas	таблицы, groupby, CSV	pandas.pydata.org	загрузка и агрегация
SciPy	статистика, распределения, тесты	docs.scipy.org	доверительные интервалы, тесты
matplotlib	рендеринг, Figure/Axes, artists	matplotlib.org	полный контроль, финальная правка
seaborn	статистические графики, long-format	seaborn.pydata.org	EDA, группы, распределения
plotnine	грамматика ggplot2, фасеты, слои	plotnine.org	многопанельные и декларативные графики
adjustText	подписи без наложений	adjusttext.readthedocs.io	точечные подписи
Pillow	растр, композит, конвертация	pillow.readthedocs.io	сборка панелей, проверка PNG

Стек удобно представлять так:

```
numpy / pandas / scipy
        ↓  данные и статистика
matplotlib (Figure, Axes, artists)
        ↓  рендеринг
seaborn / plotnine
        ↓  грамматика, статистика, фасеты
goodgraph (rcParams, палитры, размеры, save)
        ↓
SVG / PNG / PDF
```

Ключевой факт: **seaborn и plotnine в итоге рисуют через matplotlib**. Поэтому понимание `Figure`/`Axes`, `rcParams` и `savefig` полезно даже тем, кто пишет только на plotnine. И наоборот: matplotlib не мешает использовать seaborn для статистики, а потом дорабатывать оси вручную.

2.2 Три подхода к одному графику

2.2.1 matplotlib: императивный контроль

Matplotlib — низкоуровневый движок. Вы создаёте `Figure` (холст), `Axes` (область с осями) и добавляете artists: линии, точки, текст, стрелки, патчи. Каждый элемент — объект с координатами и свойствами.

```
import matplotlib.pyplot as plt

fig, ax = plt.subplots(figsize=(3.35, 2.8), layout="constrained")

for group, part in df.groupby("group"):
    ax.scatter(
        part["baseline_hba1c_pct"],
        part["followup_hba1c_pct"],
        s=12,
        alpha=0.5,
        label=group,
    )

ax.set_xlabel("HbA1c до, %")
ax.set_ylabel("HbA1c после, %")
ax.legend(frameon=False)
fig.savefig("scatter.svg")
```

Сильные стороны:

- полный контроль над каждым элементом;
- аннотации, врезки, стрелки, произвольные artists;
- предсказуемое поведение при экспорте;
- огромная экосистема примеров.

Слабые стороны:

- многословно;
- статистика и группировка — вручную;
- легко получить несогласованные рисунки, если каждый скрипт настраивает оси по-своему;
- глобальное состояние `pyplot` (`plt.plot`, `plt.xlim`) может «протечь» из одного рисунка в другой.

Практическое правило: в скриптах используйте **объектный API** (`fig, ax = plt.subplots()`), а не `plt.plot`. Глобальный `pyplot` удобен в интерактивной консоли, но плохо предсказуем в воспроизводимом пайплайне.

2.2.2 seaborn: данные и статистика

Seaborn — надстройка над matplotlib, ориентированная на таблицы данных. Вы передаёте `data=` и имена колонок, а не массивы; `hue`, `style`, `size`, `col`, `row` автоматически кодируют группы и создают фасеты.

```
import seaborn as sns

sns.scatterplot(
    data=df,
    x="baseline_hba1c_pct",
    y="followup_hba1c_pct",
    hue="group",
    style="group",
    ax=ax,
)
```

Сильные стороны:

- статистические преобразования «из коробки»: средние, доверительные интервалы, регрессии, KDE;
- аккуратные умолчания для категориальных групп;
- быстрый EDA и разведочные графики;
- интеграция с matplotlib через `ax=`.

Слабые стороны:

- меньше контроля над отдельными artists;
- темы seaborn (`sns.set_theme`) **перезаписывают** rcParams matplotlib;
- API статистики менялся между версиями (`ci` → `errorbar`), поэтому примеры из старых статей могут не работать;
- легко получить «красиво, но не по журнальному»: крупные шрифты, лишние линии, тени.

Практическое правило: seaborn — для исследования и быстрых статистических сводок; финальную правку удобнее делать в matplotlib.

2.2.3 plotnine: грамматика графики

Plotnine — реализация грамматики графики (Wilkinson; ggplot2) для Python. График описывается декларативно: данные → эстетические отображения → геометрия → шкалы → координаты → фасеты → тема.

```
from plotnine import *

(
    ggplot(df, aes("baseline_hba1c_pct", "followup_hba1c_pct", color="group"))
    + geom_point(alpha=0.5)
    + labs(x="HbA1c до, %", y="HbA1c после, %")
    + theme_bw()
)
```

Сильные стороны:

- декларативность: вы описываете **что**, а не **как**;
- фасеты (`facet_wrap`, `facet_grid`) и согласованные шкалы;
- легко менять геометрию, не переписывая код;
- хорошо ложится на многопанельные статьи и воспроизводимые отчёты.

Слабые стороны:

- требует tidy/long-формата данных;
- меньше контроля над отдельными artists, чем в matplotlib;
- своя система тем, не полностью совпадающая с rcParams;
- часть возможностей ggplot2 отличается или называется иначе;
- ошибки в слоях иногда появляются только на этапе отрисовки.

Практическое правило: plotnine — для структурированных многопанельных графиков и случаев, где важна декларативная воспроизводимость.

2.2.4 Сравнение

Критерий	**matplotlib**	**seaborn**	**plotnine**
Уровень	низкий	средний	высокий
Стиль	императивный	дата-ориентированный	декларативный
Контроль над artists	максимальный	средний	средний/низкий
Статистика «из коробки»	нет	да	частично
Фасеты	вручную	`col`/`row`	`facet_wrap`/`facet_grid`
Кривая обучения	средняя	низкая	средняя
Лучше всего для	финальной правки, аннотаций	EDA, групп, распределений	структуры, multi-panel

Это не «или». Типичный пайплайн: seaborn или plotnine для черновика, matplotlib для финальной правки, `goodgraph` — для единого стиля.

2.3 Один набор данных — три библиотеки

Чтобы сравнение не осталось теоретическим, один и тот же набор (HbA1c до и после 12 недель, 132 пациента) построен трижды. Код — `02_python/scripts/compare_libraries.py`.

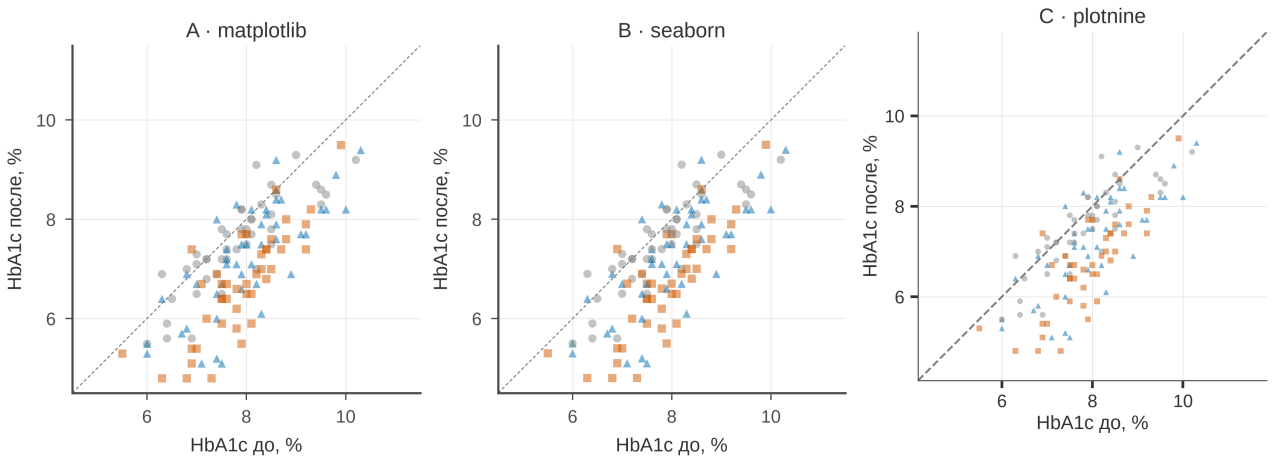


Рисунок 2.1. Один и тот же набор данных в трёх библиотеках: A — matplotlib, B — seaborn, C — plotnine. Серые круги — плацебо, синие треугольники — препарат A 10 мг, вермилионовые квадраты — препарат B 20 мг; штриховая линия — равенство HbA1c до и после. Данные — `data/02_python_dataset.csv`.

Что здесь важно:

- **Общие пределы и деления.** Все панели используют `xlim/ylim = 4,5–11,5` и деления 6/8/10. Иначе сравнение было бы нечестным.
- **Общая палитра и формы.** Цвет и форма маркера заданы один раз и повторены во всех библиотеках. Это принцип согласованности из раздела 1.
- **Разный объём кода.** Matplotlib требует явного цикла по группам; seaborn — одного вызова с `hue`/`style`; plotnine — описания слоёв и темы. Но результат один и тот же, потому что стиль вынесен наружу.
- **Размер панели 54 × 62 мм.** Три панели по 54 мм с промежутками дают ширину около 170 мм. Это пример проектирования в конечном размере, а не «нарисуем большое и уменьшим».

Ключевые фрагменты:

```
# matplotlib: цикл по группам
for group in GROUP_ORDER:
    part = df.loc[df["group"] == group]
    ax.scatter(part["baseline_hba1c_pct"], part["followup_hba1c_pct"],
               marker=GROUP_MARKERS[group], color=GROUP_COLORS[group])

# seaborn: одна функция, группы через hue/style
sns.scatterplot(data=df, x="baseline_hba1c_pct", y="followup_hba1c_pct",
                hue="group", style="group", ax=ax)

# plotnine: слои через «+»
(
    ggplot(df, aes("baseline_hba1c_pct", "followup_hba1c_pct",
                   color="group", shape="group"))
    + geom_point(alpha=0.5)
    + geom_abline(slope=1, intercept=0, linetype="dashed")
    + coord_fixed(ratio=1, xlim=(80, 215), ylim=(80, 215))
    + theme_bw()
)
```

2.4 uv: окружение и воспроизводимость

2.4.1 Что такое uv

`uv` — менеджер пакетов и окружений от Astral, написанный на Rust. Он заменяет связку `pip` + `venv` + `pip-tools` + `pyenv` и умеет:

- создавать виртуальные окружения;
- разрешать и фиксировать зависимости (`uv.lock`);
- скачивать и переключать версии Python;

- запускать скрипты и инструменты (`uv run`, `uvx`);
- работать в CI и на чужих машинах.

Документация: docs.astral.sh/uv. В этом репозитории используется uv 0.12 и Python 3.12; точные версии пакетов зафиксированы в `uv.lock`.

2.4.2 Установка

```
# Linux / macOS
curl -LsSf https://astral.sh/uv/install.sh | sh

# Windows PowerShell
powershell -c "irm https://astral.sh/uv/install.ps1 | iex"

# Если уже есть pipx или Homebrew
pipx install uv
brew install uv

uv --version
```

Если нужной версии Python нет:

```
uv python install 3.12
uv python list
```

`uv` скачает интерпретатор в свой каталог и не тронет системный Python.

2.4.3 Новый проект

```
mkdir my-figure && cd my-figure
uv init --python 3.12
uv add matplotlib seaborn plotnine pandas numpy scipy
uv add --dev ruff pytest
uv run python -c "import matplotlib; print(matplotlib.__version__)"
```

Что появилось:

- `pyproject.toml` — метаданные проекта и зависимости;
- `.python-version` — закреплённая версия Python;
- `uv.lock` — точное дерево зависимостей с хешами;
- `.venv/` — виртуальное окружение (не коммитится).

`uv add` одновременно обновляет `pyproject.toml`, `uv.lock` и окружение. `uv sync` приводит окружение в соответствие с lock-файлом.

2.4.4 `pyproject.toml` этого репозитория

Сокращённый вид:

```
[project]
name = "goodgraph"
version = "0.1.0"
requires-python = ">=3.12,<3.13"
dependencies = [
    "numpy>=2.0",
    "pandas>=2.2",
    "matplotlib>=3.9",
    "seaborn>=0.13",
    "plotnine>=0.13",
    "scipy>=1.13",
]

[dependency-groups]
dev = ["ruff>=0.6", "pytest>=8.0"]

[tool.uv]
package = true
```

Полная версия с `[build-system]` и `[tool.hatch.build.targets.wheel]` — в `pyproject.toml`.

Что здесь важно:

- `requires-python` задаёт **диапазон**, а `.python-version` — конкретную версию для разработки;
- `uv.lock` фиксирует точные версии; его нужно коммитить;
- `[tool.uv] package = true` и `src/`-layout означают, что пакет `goodgraph` устанавливается в окружение редактируемым (`pip install -e`);
- `[dependency-groups] dev` — инструменты разработки, которые не нужны читателю в рантайме.

2.4.5 Повседневные команды

Команда	Что делает
`uv sync`	создаёт/обновляет `.venv` по `uv.lock`
`uv sync --frozen`	не меняет lock, падает при расхождении — для CI
`uv add pandas`	добавляет зависимость и обновляет lock
`uv add --dev ruff`	добавляет в dev-группу
`uv remove pandas`	удаляет зависимость
`uv lock`	пересчитывает lock
`uv lock --upgrade`	обновляет версии в пределах ограничений
`uv run python script.py`	запускает в окружении проекта
`uv run --with rich script.py`	добавляет пакет только на запуск

Команда	Что делает
`uv python pin 3.12`	фиксирует версию Python
`uv tree`	показывает дерево зависимостей
`uv pip list`	список установленного
`uvx ruff check .`	запускает инструмент без установки в проект

`uv run` не требует активации окружения. Если привычнее `source .venv/bin/activate`, это тоже работает; но в скриптах и CI `uv run` надёжнее — он гарантирует нужное окружение.

2.4.6 Одноразовые скрипты и PEP 723

Если скрипт не входит в проект, зависимости можно объявить прямо в нём:

```
# /// script
# requires-python = ">=3.12"
# dependencies = ["matplotlib", "pandas"]
# ///

import matplotlib.pyplot as plt
import pandas as pd
```

Запуск:

```
uv run plot.py
```

`uv` создаст временное окружение с указанными пакетами и выполнит скрипт. Это удобно для примеров в статье или для утилиты, которую не хочется тащить в основной `pyproject.toml`. Спецификация — PEP 723.

2.4.7 Воспроизводимость и кеш

Правила:

- коммитить `pyproject.toml`, `uv.lock`, `.python-version`;
- не коммитить `.venv/`;
- в CI использовать `uv sync --frozen` и `uv run ...`;
- обновлять зависимости осознанно: `uv lock --upgrade`, затем прогнать тесты и пересобрать рисунки;
- фиксировать системные зависимости отдельно: шрифты, Cairo, LaTeX, Graphviz — uv их не устанавливает.

В песочнице или CI с read-only домашним каталогом задайте локальные пути:

```
export UV_CACHE_DIR="$PWD/.uv-cache"
export UV_PYTHON_INSTALL_DIR="$PWD/.uv-python"
export MPLCONFIGDIR="$PWD/.mplconfig"
```

В этом репозитории такие каталоги уже добавлены в `.gitignore`.

2.5 Анатомия воспроизводимого графика

2.5.1 Четыре слоя

```
data/02_python_dataset.csv
      ↓  make_data.py: seed, генерация, CSV
      ↓  plot.py: pandas/scipy, агрегация
      ↓  goodgraph.style: rcParams, палитра, размер
      ↓  matplotlib / seaborn / plotnine
      ↓  save_figure: SVG + PNG
images/01_good_dot_ci.svg, .png
```

Принципы:

1. **Данные не знают о графике.** `make_data.py` пишет CSV и не импортирует matplotlib.
2. **График не генерирует данные.** `plot.py` читает CSV; если данных нет — падает с понятной ошибкой.

3. **Стиль — отдельный слой.** Один `apply_style()` и одна палитра на всю методичку.
4. **Экспорт — отдельная функция.** `save_figure()` сохраняет SVG и PNG, закрывает фигуру и печатает пути.

2.5.2 Каркас скрипта

```python
from __future__ import annotations

import matplotlib

matplotlib.use("Agg")  # без дисплея

import matplotlib.pyplot as plt

from goodgraph import apply_style, figure_size, save_figure
from goodgraph.paths import DATA_DIR

apply_style()
fig, ax = plt.subplots(
    figsize=figure_size("single", ratio=0.8),
    layout="constrained",
)
# ... данные и слои ...
save_figure(fig, "02_example")
```

`figure_size("single")` возвращает размер в дюймах для 85 мм; `save_figure` сохраняет `images/02_example.svg` и `images/02_example.png` с dpi 600 и закрывает фигуру. Если нужен точный физический размер, не включайте `tight=True`: обрезка полей меняет ширину.

2.5.3 Что задаёт `apply_style`

Параметр	Значение	Зачем
`font.family`	Liberation Sans, Arial, DejaVu Sans	кириллица, метрики Arial
`font.size`	9 pt (paper)	журнальный кегль
`axes.spines.top/right`	False	меньше визуального шума
`axes.grid`	True, только Y	помогает читать значения
`grid.color`	`#E6E6E6`	сетка не конкурирует с данными
`axes.prop_cycle`	Okabe–Ito	доступная палитра по умолчанию
`svg.fonttype`	`path`	текст не «поплывёт» в SVG
`pdf.fonttype`	42	TrueType в PDF, текст редактируем
`savefig.dpi`	600	достаточный растр
`axes.unicode_minus`	False	совместимость со шрифтами

2.5.4 Порядок применения стилей

Порядок важен, потому что настройки перекрывают друг друга:

1. значения по умолчанию matplotlib;
2. `plt.style.use("...")`, если он используется;
3. `sns.set_theme(...)` — **сбрасывает** многие rcParams;
4. `apply_style(...)` — должен идти последним;
5. точечные переопределения в конкретном графике.

Если вызвать `sns.set_theme()` после `apply_style()`, шрифты, рамки и сетка могут вернуться к умолчаниям seaborn. Если нужна тема seaborn — передайте её параметры в `apply_style` или настройте rcParams после `set_theme`.

Plotnine живёт в своей системе тем. `theme(text=element_text(...))` не читает все rcParams matplotlib; задавайте шрифт и размеры явно.

2.6 Разбор `compare_libraries.py`

Скрипт `02_python/scripts/compare_libraries.py` устроен так:

1. **Общие константы.** `WIDTH_MM = 54`, `HEIGHT_MM = 62`, `LIM_MIN = 80`, `LIM_MAX = 215`, `TICKS = [80, 120, 160, 200]`. Одинаковые пределы — обязательное условие честного сравнения.
2. **Палитра и формы.** `GROUP_COLORS` и `GROUP_MARKERS` заданы один раз; цвет дублируется формой, чтобы панели читались в сером.
3. **`load_data()`.** Читает `data/02_python_dataset.csv` и проверяет, что все группы на месте.
4. **`style_axes()`.** Общая функция для matplotlib и seaborn: пределы, деления, линия равенства, подписи, сетка, аспект.
5. **Три функции построения.** `plot_matplotlib`, `plot_seaborn`, `plot_plotnine` — каждая самодостаточна и сохраняет свою пару SVG/PNG.
6. **`main()`.** Последовательно вызывает три функции.

Почему это важно: если каждая панель настраивает пределы сама, сравнение превращается в сравнение разных графиков. Общая функция `style_axes` фиксирует контракт.

2.7 Типичные ошибки и как их исправить

2.7.1 `plt.show()` в скрипте

```
# плохо: скрипт зависит от дисплея
plt.show()

# хорошо: Agg + сохранение
matplotlib.use("Agg")
fig.savefig("figure.png", dpi=600)
```

`show()` полезен в интерактивной консоли; в скрипте, CI и на сервере он либо блокирует выполнение, либо падает без дисплея.

2.7.2 Глобальное состояние `pyplot`

```
# плохо: неясно, какая фигура сохраняется
plt.plot(x, y)
plt.title("...")
plt.savefig("a.png")
plt.plot(x2, y2)
plt.savefig("b.png")  # на самом деле обе линии на одной фигуре

# хорошо: явные объекты
fig, ax = plt.subplots()
ax.plot(x, y)
fig.savefig("a.png")
plt.close(fig)
```

2.7.3 `sns.set_theme()` после `apply_style()`

```
# плохо: тема seaborn перезапишет шрифты и рамки
apply_style()
sns.set_theme(style="whitegrid")

# хорошо: сначала тема, потом свой стиль
sns.set_theme(style="whitegrid")
apply_style()
```

2.7.4 `tight_layout` и `constrained_layout` вместе

```
# плохо: конфликтующие движки компоновки
fig, ax = plt.subplots(layout="constrained")
fig.tight_layout()

# хорошо: один движок
fig, ax = plt.subplots(layout="constrained")
```

2.7.5 `bbox_inches="tight"` и точная ширина

```
# плохо для журнальной ширины: итоговый размер может отличаться от 85 мм
fig.savefig("figure.svg", bbox_inches="tight")

# хорошо: размер задан figsize, поля — полями
fig.savefig("figure.svg")
```

`tight` удобен для слайдов и препринтов, но не для точного соответствия колонке журнала.

2.7.6 Шрифт не найден

```
from matplotlib import font_manager

print(font_manager.findfont("Liberation Sans"))
```

Если шрифт не найден, matplotlib молча подставит DejaVu Sans и предупредит. Проверяйте `findfont` и наличие кириллицы. В Linux установите `fonts-liberation`, в Windows используйте Arial.

2.7.7 SVG с текстом или с кривыми

- `svg.fonttype = "path"` — текст превращается в кривые: вид стабилен, но текст нельзя редактировать.
- `svg.fonttype = "none"` — текст остаётся текстом: удобно для правки, но зависит от шрифтов у читателя.

Для журнала обычно выбирают `path`; для внутренней правки — `none`. В этом проекте по умолчанию `path`.

2.7.8 Единицы plotnine

```
# плохо: дюймы и миллиметры перепутаны
plot.save("figure.png", width=85, height=60)

# хорошо: перевести миллиметры в дюймы
plot.save("figure.png", width=85 / 25.4, height=60 / 25.4, dpi=600)
```

`plotnine.save` принимает ширину и высоту в дюймах, как и matplotlib.

2.7.9 Данные не в tidy-формате

Plotnine ожидает long-формат: одна строка — одно наблюдение, колонки — переменные. Широкая таблица `group, before, after` подойдёт для matplotlib, но для plotnine её нужно привести к `group, time, value` через `melt`.

2.7.10 DPI и цветовой профиль

- DPI влияет только на растр; для SVG/PDF он не важен.
- RGB → CMYK лучше конвертировать в конце, после утверждения макета; проверьте, что цвета не «провалились» в печати.
- Прозрачный фон (`transparent=True`) почти никогда не нужен для журнала: белый фон предсказуемее.

2.8 Чек-лист раздела 2

- ☐ `uv sync --frozen` работает на чистой машине.
- ☐ `pyproject.toml`, `uv.lock`, `.python-version` закоммичены.
- ☐ `.venv/` не закоммичен.
- ☐ Скрипт использует `matplotlib.use("Agg")`.
- ☐ Данные и построение разделены: `make_data.py` ≠ `plot.py`.
- ☐ `apply_style()` вызывается один раз и последним.
- ☐ Нет `sns.set_theme()` после `apply_style()`.
- ☐ Пределы осей и палитра заданы явно, а не «по умолчанию».
- ☐ Сохраняются SVG и PNG; размер — в миллиметрах, не «как получилось».
- ☐ Шрифт найден, кириллица и символы (μ, ±, ≥) отображаются.
- ☐ `uv run python ...` работает из корня репозитория.
- ☐ `uv run ruff check .` проходит.
- ☐ Повторный запуск даёт те же данные и рисунки (фиксированный seed).

2.9 Итоги

- **matplotlib** — фундамент и полный контроль; используйте объектный API.
- **seaborn** — быстрый доступ к статистике и группам; не заменяет matplotlib, а дополняет его.
- **plotnine** — грамматика графики и фасеты; требует tidy-данных и отдельной темы.
- **uv** — воспроизводимость: версия Python, lock-файл, `uv run`, `uv sync --frozen`.
- **goodgraph** — единый стиль и экспорт; это контракт между разделами.

Дальше — раздел 3: требования к цвету, шрифтам, размерам и форматам. Там мы разберём палитры подробнее, научимся проверять рисунок на дальтонизм и печать и соберём таблицу «параметр → значение → источник».

Источники к разделу

- Matplotlib documentation — matplotlib.org
- Matplotlib: Quick start guide — matplotlib.org
- Matplotlib: Artists — matplotlib.org
- Seaborn documentation — seaborn.pydata.org
- Seaborn tutorial — seaborn.pydata.org/tutorial
- Plotnine documentation — plotnine.org
- Plotnine reference — plotnine.org/reference
- uv documentation — docs.astral.sh/uv
- uv: Working on projects — docs.astral.sh/uv/guides/projects
- uv: Running scripts — docs.astral.sh/uv/guides/scripts
- PEP 723: Inline script metadata — peps.python.org/pep-0723
- Wilkinson L. *The Grammar of Graphics*. 2nd ed. Springer, 2005. — doi:10.1007/0-387-28695-0
- ggplot2 documentation — ggplot2.tidyverse.org
- Rougier N. P., Droettboom M., Bourne P. E. Ten Simple Rules for Better Figures // *PLoS Computational Biology*. 2014. Vol. 10, № 9. e1003833. — doi:10.1371/journal.pcbi.1003833
- pandas documentation — pandas.pydata.org
- NumPy documentation — numpy.org/doc
- SciPy documentation — docs.scipy.org
- adjustText documentation — adjusttext.readthedocs.io
- Pillow documentation — pillow.readthedocs.io

Раздел 3. Требования к научной графике: цвет, шрифты, размеры и форматы

В разделе 1 мы сформулировали принципы, в разделе 2 — выбрали инструменты. Теперь наступает самая практичная часть: **конкретные требования**, которые можно проверить до отправки статьи. Не «сделайте красиво», а «ширина 85 мм, кегль не меньше 7 pt, контраст не ниже 3:1, шрифт встроен».

Требования удобно разделить на три уровня:

1. **Смысл** — что именно кодирует цвет, размер, положение.
2. **Доступность** — увидят ли это при дальтонизме, в сером, на печати.
3. **Производство** — дойдёт ли файл до редакции без потерь.

Гайд журнала всегда важнее любых рекомендаций ниже. Если журнал требует RGB, 300 dpi и TIFF — делайте RGB, 300 dpi и TIFF, даже если раздел советует вектор. Но если гайд молчит, значения по умолчанию из этого раздела помогут не изобретать велосипед.

3.1 Цвет: язык, а не украшение

3.1.1 Что кодирует цвет

Цвет в научном графике выполняет одну из четырёх ролей:

- **категория** — группа, препарат, регион, тип события;
- **величина** — концентрация, время, доза, интенсивность;
- **отклонение** — разница с нулём, нормой или контролем;
- **акцент** — главный вывод на фоне серого контекста.

Цвет — мощный, но неточный канал. Точные значения читаются по положению и длине, а цвет хорош для **группировки** и **поиска**. Поэтому не стоит кодировать цветом то, что читатель должен сравнивать количественно: для этого есть оси, точки и подписи.

Три практических следствия:

- цвет должен иметь смысл: если убрать цвет, график не должен потерять информацию (или должен потерять только второстепенную);
- одно и то же соответствие «цвет → группа» сохраняется во всех рисунках;
- цвет не единственный носитель смысла: форма, тип линии, подпись дублируют его.

3.1.2 Три типа палитр

Тип	Вопрос	Примеры	Правило
Качественная	«Какая это категория?»	Okabe–Ito, Paul Tol bright/muted, ColorBrewer Set2	6–8 цветов, без порядка, без радуги
Последовательная	«Насколько велика величина?»	viridis, cividis, Blues, Greens	монотонная светлота, равномерные шаги
Дивергентная	«Насколько отличается от нуля?»	RdBu_r, PuOr, BrBG	два полюса, нейтральная середина в смысловом нуле

Типичная ошибка — использовать последовательную шкалу для категорий («группа 1 — светло-синяя, группа 2 — тёмно-синяя»): читатель начинает искать порядок и величину там, где их нет. Обратная ошибка — раскрасить упорядоченную величину качественными цветами: пропадает направление изменения.

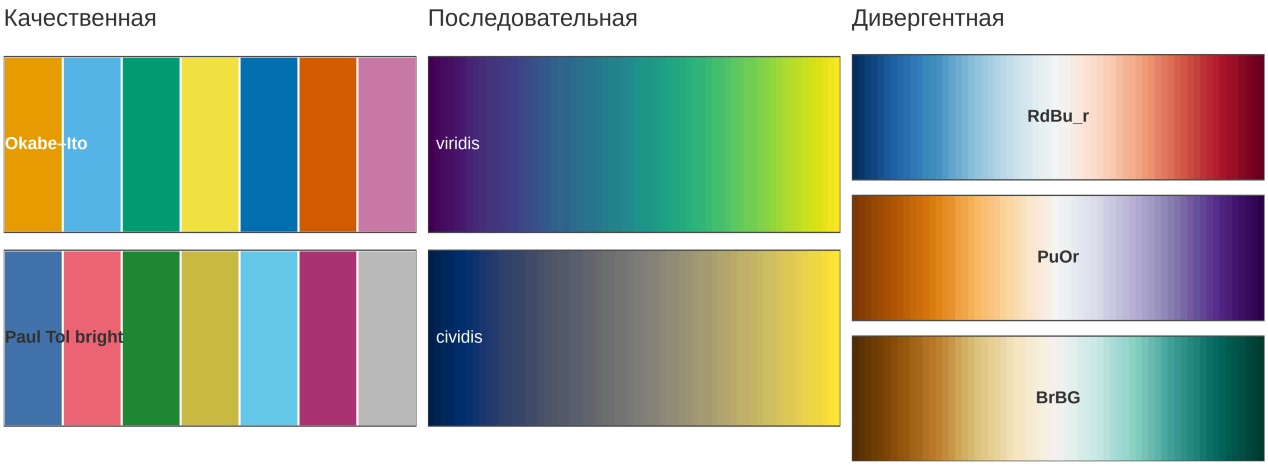


Рисунок 3.1. Три типа палитр: качественная (Okabe–Ito, Paul Tol bright), последовательная (viridis, cividis) и дивергентная (RdBu_r, PuOr, BrBG). Качественная отвечает на вопрос «кто это», последовательная — «сколько», дивергентная — «насколько отличается от нуля».

3.1.3 Качественные палитры

Базовый набор — **Okabe–Ito**. Он различим при протанопии и дейтеранопии и хорошо работает в полиграфии.

Цвет	HEX	Роль
оранжевый	`#E69F00`	категория 1
небесно-голубой	`#56B4E9`	категория 2
сине-зелёный	`#009E73`	категория 3
жёлтый	`#F0E442`	категория 4, только с тёмным контуром
синий	`#0072B2`	основной результат
вермилион	`#D55E00`	акцент/второй результат
красновато-фиолетовый	`#CC79A7`	категория 5
чёрный	`#000000`	текст, оси, а не серии

Дополнительные варианты:

- **Paul Tol bright/muted** — спокойные наборы для больших заливок и слайдов;
- **ColorBrewer** — проверенные качественные, последовательные и дивергентные схемы, в том числе для печати;
- **табличные** палитры (например, `tab10`) удобны, но не оптимизированы под дальтонизм; не полагайтесь на них в финальной версии.

Правила:

- не больше 6–8 категориальных цветов; больше — объединяйте редкие категории в «прочее» или делайте small multiples;
- серый — для контроля, фона и «прочего»; он не должен конкурировать с данными;
- один акцентный цвет на главный вывод; остальное — сдержанное;
- не используйте красный и зелёный как единственную пару «плохо/хорошо»;
- проверяйте палитру в сером и через симулятор дальтонизма.

3.1.4 Последовательные и дивергентные шкалы

Последовательная шкала должна:

- монотонно менять светлоту — тогда она читается в сером;
- быть равномерной по восприятию — без ложных границ;
- подходить для дальтоников;
- иметь подписанную цветовую шкалу с единицами.

`viridis` и `cividis` — хорошие значения по умолчанию. `cividis` специально спроектирован для дальтонизма. `Blues` и `Greens` хороши для печати, но следите за контрастом крайних значений.

```python
import matplotlib as mpl

cmap = mpl.colormaps["viridis"]
# Для дискретных значений:
cmap = mpl.colormaps["viridis"].resampled(5)
```

Почему не `jet` и не «радуга»:

- светлота меняется немонотонно, возникают ложные границы;
- разные шаги данных выглядят как разные по величине;
- жёлтый и голубой на белом фоне теряют контраст;
- шкала плохо читается при дальтонизме и в сером.

Дивергентная шкала нужна, когда есть **смысловой ноль**: изменение, разница, отклонение от нормы. Правила:

- центр шкалы — ровно ноль (или другая содержательная точка);
- пределы симметричны: −3…+3, а не −1…+5;
- два полюса разного цвета, середина — нейтральная;
- не используйте дивергентную шкалу для данных без нуля.

Белая середина `RdBu_r` на белом фоне может «исчезнуть». Если это мешает, добавьте тонкую контурную линию или выберите середину с лёгким оттенком.

3.1.5 Доступность: дальтонизм и серый

Около 8 % мужчин европейского происхождения имеют нарушения цветового зрения; среди женщин доля ниже, но не нулевая. Наиболее часты протанопия и дейтеранопия (красный/зелёный), реже — тританопия (синий/жёлтый).

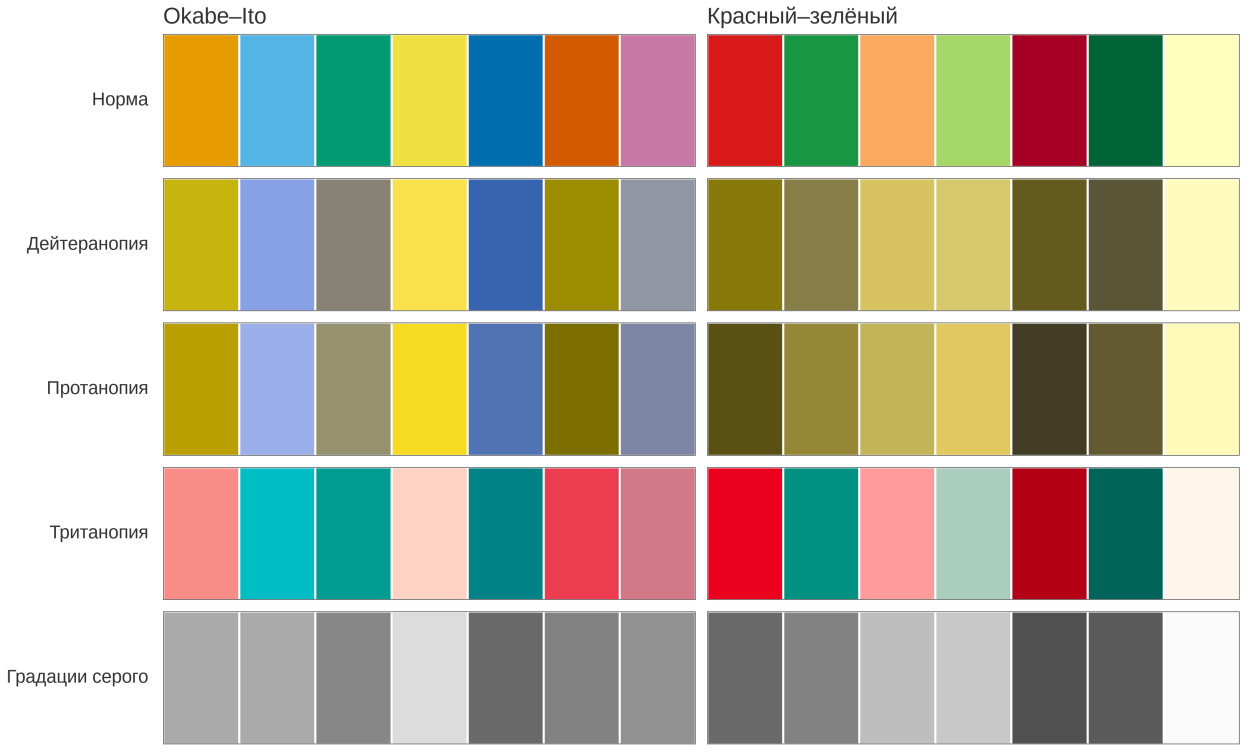


Рисунок 3.2. Симуляция дальтонизма (Machado et al., 2009; severity 100 %). Слева — Okabe–Ito, справа — палитра «красный–зелёный». В нижних рядах видно, что красные и зелёные пары сливаются, а Okabe–Ito сохраняет больше различий. В сером ряду цвет исчезает полностью — форму и подписи нужно дублировать.

Что делать:

- **дублируйте цвет формой, типом линии, штриховкой или прямой подписью**;
- не кодируйте противоположные категории только красным и зелёным;
- проверяйте рисунок в градациях серого;
- проверяйте контраст: текст — не ниже 4,5:1, графические объекты — не ниже 3:1 (WCAG 2.1);

- используйте симуляторы (Coblis, Color Oracle, Photoshop, матрицы Machado) и, в идеале, покажите рисунок человеку с дальтонизмом.

Серый — не «отсутствие цвета», а полноценный канал. В сером графике работают положение, форма, толщина линии и подписи. Если после обесцвечивания серии неразличимы — добавьте форму или подпись.

3.1.6 Цвет в печати

Экран и бумага — разные устройства.

- **sRGB** — для онлайн-публикации и большинства журнальных PDF.
- **CMYK** — для офсетной печати; охват уже, насыщенные зелёные и синие могут «провалиться».
- Конвертируйте в CMYK **в конце**, после утверждения макета, и проверяйте цветопробу.
- Не полагайтесь на светлые оттенки для тонких линий: на бумаге они исчезают.
- Мелкий текст — 100 % K, а не составной «богатый чёрный»: иначе возможны проблемы с приводкой.
- Не используйте прозрачность как единственный способ показать неопределённость: при печати она может стать грязной.

3.1.7 Чек-лист цвета

- ☐ Цвет кодирует смысл, а не украшает.
- ☐ Тип палитры соответствует задаче: категория / величина / отклонение.
- ☐ Категориальных цветов не больше 6–8.
- ☐ Нет радуги и `jet`; последовательная шкала монотонна по светлоте.
- ☐ Дивергентная шкала центрирована в смысловом нуле и симметрична.
- ☐ Красный и зелёный не единственные носители смысла.
- ☐ Рисунок читается в градациях серого.
- ☐ Контраст текста ≥ 4,5:1, графики ≥ 3:1.
- ☐ Цвета согласованы между рисунками.
- ☐ Проверена цветопроба или CMYK-версия, если журнал печатный.

3.2 Шрифты

3.2.1 Гарнитура

Для рисунков почти всегда лучше **sans-serif**: Arial, Helvetica, Liberation Sans, DejaVu Sans. Они плотнее и лучше читаются в мелком кегле, чем засечные гарнитуры. Основной текст статьи может быть serif — это нормально; важно, чтобы рисунок не спорил с текстом.

Правила:

- одна гарнитура на рисунок, максимум две на статью;
- не использовать декоративные и рукописные шрифты;
- проверять метрическую совместимость: Liberation Sans близок к Arial, поэтому вёрстка не «поедет» при замене;
- встраивать шрифт в PDF или переводить текст в кривые в SVG.

3.2.2 Кегли

Кегль задаётся **в конечном физическом размере**. Если рисунок будет 85 мм, не рисуйте его в 16 дюймов и не уменьшайте в Word: 9 pt превратятся в лотерею.

Элемент	**Ориентир**
Заголовок внутри рисунка	9–10 pt
Подписи осей	8–9 pt
Деления и подписи делений	7–8 pt
Легенда	7–8 pt
Метки панелей A/B/C	9–10 pt, bold
Подпись к рисунку (caption)	8–9 pt, в тексте

Практический минимум — **7 pt**. Некоторые журналы допускают 5–7 pt, но это уже риск: в печати и на плохом экране такой текст расплывается. 6 pt — ниже практического минимума; используйте только как крайнюю меру.



Рисунок 3.3. Один и тот же текст при 6–12 pt в конечном размере 85 мм. В PDF рисунок показан 1:1; в HTML он может масштабироваться, поэтому ориентируйтесь на подписи кеглей, а не на размер картинки на экране.

3.2.3 Начертания, регистр, математика

- Regular — по умолчанию; bold — только для акцента.
- Не писать подписи КАПСОМ: это замедляет чтение.
- Не подчёркивать и не добавлять тени/обводки ради «красоты».
- Математические переменные — курсивом: *p*, *n*, *M*, *SD*.
- Единицы — прямым: мм рт. ст., мг, %, °C.
- Не смешивать курсив и прямой шрифт в одном обозначении без причины.
- Десятичный разделитель — по языку публикации: запятая в русском тексте, точка в англоязычном; главное — единообразие.

3.2.4 Кириллица и специальные символы

Проверяйте не только буквы, но и символы:

- μ, ±, ≥, ≤, →, ≈, ×, Δ, °C;
- минус и дефис — разные символы; в осях допустим обычный минус, но он не должен превращаться в дефис;
- неразрывный пробел между числом и единицей: 8,9 мм, 10 мг, 5 %.

Если шрифт не найден, matplotlib молча подставит DejaVu Sans и предупредит. Проверяйте:

```
from matplotlib import font_manager

print(font_manager.findfont("Liberation Sans"))
```

Для проверки глифов в шрифте можно использовать `fontTools`:

```
from fontTools.ttLib import TTFont

font = TTFont("path/to/font.ttf")
cmap = font.getBestCmap()
print(all(ord(ch) in cmap for ch in "μ±≥≤→≈×Δ°C"))
```

3.2.5 Композиция текста

- Подписи осей — параллельно осям, не под углом 45° без необходимости.
- Единицы — в подписи оси: «САД, мм рт. ст.», а не «САД (мм рт. ст.)» и не отдельной строкой в легенде.
- Деления не должны налезать друг на друга; при необходимости уменьшите их число, а не кегль.
- Легенда — тем же кеглем, что и деления; без рамки, если позволяют оси.
- Прямые подписи лучше легенды, если серий немного.
- Не располагайте подпись поверх данных без белой подложки или ореола.

3.2.6 Чек-лист шрифтов

- ☐ Одна гарнитура, sans-serif для рисунка.
- ☐ Кегли 7–10 pt в конечном размере.
- ☐ Нет КАПСА и декоративных эффектов.
- ☐ Математика курсивом, единицы прямым.
- ☐ Кириллица и символы (μ, ±, ≥, →, °C) отображаются.
- ☐ Десятичный разделитель единообразен.
- ☐ Подписи не налезают друг на друга и не обрезаны.
- ☐ Шрифт встроен в PDF или переведён в кривые в SVG.

3.3 Размеры и композиция

3.3.1 Ширина колонки

Ширина	Типичное применение
85 мм	одна колонка
114 мм	полторы колонки
170 мм	две колонки
180 мм	максимальная ширина полосы

Nature ориентирует на 89 и 183 мм; другие журналы — на 85–90 и 170–183 мм. Проверяйте гайд. Проектируйте сразу в конечной ширине: `figsize` в matplotlib задаётся в дюймах, поэтому 85 мм = 3,35 дюйма, 170 мм = 6,69.

3.3.2 Поля и отступы

- Внешние поля — 3–5 мм, чтобы подписи не обрезались.
- Внутренние отступы между панелями — 2–4 мм.
- Не используйте `bbox_inches="tight"` для журнального рисунка: он меняет физический размер.
- `layout="constrained"` предпочтительнее ручного `subplots_adjust`, если нет особых требований.
- Проверяйте, что подписи осей и легенда не выходят за холст.

3.3.3 Пропорции

- Временной ряд — широкий: 16:9 или 3:2, чтобы тренд читался.
- Scatter — ближе к квадрату, особенно если сравниваете наклоны.
- Столбцы — не слишком широкие: расстояние между ними важнее толщины.
- Не растягивайте рисунок непропорционально: это меняет восприятие наклонов и площадей.
- Для временных рядов полезно «banking to 45°»: подобрать аспект так, чтобы типичный наклон был около 45°.

3.3.4 Панели и выравнивание

- Метки A, B, C — слева сверху, одним кеглем и в одном месте.
- Одинаковые пределы осей, если панели сравниваются.
- Общая легенда — для всех панелей, а не отдельная в каждой.
- Выравнивайте области построения, а не только внешние рамки.
- Не дублируйте подписи осей на каждой панели, если они общие.

3.3.5 Чек-лист размеров

- ☐ Ширина соответствует колонке журнала.
- ☐ Рисунок спроектирован в конечном размере, а не уменьшен.
- ☐ Поля 3–5 мм, ничего не обрезано.
- ☐ Панели выровнены, метки A/B/C на месте.
- ☐ Пропорции не искажены.
- ☐ `bbox_inches="tight"` не используется для точной ширины.

3.4 Форматы и разрешение

3.4.1 Вектор или растр

Формат	Тип	Когда использовать	Ограничения
PDF	вектор	графики, схемы, финальная отправка	проверьте встраивание шрифтов
SVG	вектор	веб, правка в Inkscape/Illustrator	текст может стать кривыми

Формат	Тип	Когда использовать	Ограничения
EPS	вектор	старые редакции, LaTeX	устаревает, проверяйте шрифты
AI	вектор	правка в Illustrator	не все журналы принимают
TIFF	растр	фото, микроскопия	большой файл; LZW без потерь
PNG	растр	веб, скриншоты	не для печати больших фото
JPEG	растр	только фото	артефакты на линиях и тексте

Правило: **линии, текст и графики — вектор; фото — растр**. Не вставляйте скриншот графика в статью: это растр с потерями и без масштабирования.

3.4.2 Разрешение

- Фото и микроскопия — 300 dpi в конечном размере.
- Штриховая графика, если журнал требует растр, — 600–1200 dpi.
- Эффективное разрешение = пиксели / дюймы конечного размера. Например, 2000 px при ширине 3,35″ дают ≈ 597 dpi.
- Не увеличивайте растр интерполяцией: это не добавляет деталей.
- Проверяйте, что после масштабирования в Word разрешение не упало.

3.4.3 Цветовые профили

- sRGB IEC61966-2.1 — безопасный профиль для онлайн-публикации.
- Adobe RGB — шире, но не все редакции его принимают.
- CMYK — для печати; конвертируйте в конце и проверяйте цветопробу.
- Встраивайте профиль в TIFF/JPEG; для PDF используйте OutputIntent, если журнал просит.
- Не конвертируйте RGB → CMYK → RGB многократно: цвета деградируют.

3.4.4 Шрифты в файлах

- PDF: `pdf.fonttype = 42` — TrueType, текст остаётся текстом и встроен.
- SVG: `svg.fonttype = "path"` — текст в кривые, вид стабилен; `"none"` — текст остаётся текстом, но зависит от шрифтов.
- EPS: проверяйте, что шрифты встроены или заменены.
- Перед отправкой откройте PDF в другом просмотрщике и проверьте, что шрифты не подменились.

3.4.5 Метаданные и именование

- Имена файлов — по схеме журнала: `Figure1.pdf`, `fig_01.svg` и т. п.
- Не включайте дату и версию в имя финального файла, если журнал просит иначе; версию храните в репозитории.
- Подпись — отдельным текстом, не внутри изображения.
- Удаляйте дату из SVG-метаданных, если готовите воспроизводимый архив: иначе файл меняется при каждом сохранении.
- Для архивации подходит PDF/A-2b, если журнал его принимает.

3.4.6 Чек-лист форматов

- ☐ Вектор для линий и текста, растр для фото.
- ☐ 300 dpi для фото, 600–1200 dpi для штриховки.
- ☐ Нет JPEG для графиков и текста.
- ☐ Шрифты встроены или переведены в кривые.
- ☐ Цветовой профиль соответствует журналу.
- ☐ Нет скриншотов и апскейла.
- ☐ Имя файла и формат соответствуют требованиям.
- ☐ PDF проверен в другом просмотрщике.

3.5 Сводная таблица требований

Параметр	Значение по умолчанию	Как проверить
Ширина	85 / 114 / 170 мм	`figsize`, PDF при 100 %
Кегль	7–10 pt	линейка в PDF, `fontsize`
Линии	0,25–1 pt	PDF при 100 %
Растр	300 dpi фото, 600+ dpi штрих	размер в пикселях / дюймы
Вектор	PDF/SVG/EPS	текст и линии не пиксельные

Параметр	Значение по умолчанию	Как проверить
Цвет	sRGB онлайн, CMYK печать	профиль, цветопроба
Поля	3–5 мм	PDF, отсутствие обрезки
Контраст	4,5:1 текст, 3:1 графика	WCAG-калькулятор
Подпись	вне изображения, самодостаточная	чтение без текста статьи
Единицы	СИ, пробел перед единицей	вычитка

3.6 Чек-лист раздела 3

- ☐ Палитра соответствует задаче и проверена на дальтонизм.
- ☐ В сером графике сохраняется смысл.
- ☐ Контраст текста и графики достаточен.
- ☐ Шрифт sans-serif, кегли 7–10 pt.
- ☐ Кириллица и специальные символы отображаются.
- ☐ Ширина соответствует журналу; поля не обрезаны.
- ☐ Панели выровнены, метки A/B/C на месте.
- ☐ Вектор/растр выбран по типу содержимого.
- ☐ Разрешение достаточно; нет апскейла и скриншотов.
- ☐ Шрифты встроены; PDF проверен в другом просмотрщике.
- ☐ Цветовой профиль соответствует требованиям.
- ☐ Подпись самодостаточна и не встроена в изображение.

3.7 Итоги

- Цвет — это канал кодирования, а не декор: тип палитры зависит от задачи.
- Качественная палитра — 6–8 цветов, без радуги, с проверкой на CVD.
- Последовательная шкала — монотонная светлота; дивергентная — ноль в центре.
- Шрифт — sans-serif, 7–10 pt в конечном размере, без КАПСА и эффектов.
- Ширина — 85/114/170 мм; проектируйте сразу в конечном размере.
- Вектор для линий и текста, растр для фото; 300/600+ dpi.
- Шрифты встраиваются, профиль проверяется, подпись остаётся текстом.

Дальше — раздел 4: основные виды научных графиков и области их применения. Там мы соберём таблицу «задача → график → ограничения» и перейдём к практике в разделе 5.

Источники к разделу

- Okabe M., Ito K. Color Universal Design (CUD) — jfly.uni-koeln.de/color
- Paul Tol’s colour schemes — personal.sron.nl/ pault
- ColorBrewer 2.0 — colorbrewer2.org
- Viridis colormap — bids.github.io/colormap
- Matplotlib: Choosing colormaps — matplotlib.org
- Machado G. M., Oliveira M. M., Fernandes L. A. F. A Physiologically-based Model for Simulation of Color Vision Deficiency // *IEEE TVCG*. 2009. Vol. 15, № 6. P. 1291–1298. — doi:10.1109/TVCG.2009.113
- W3C. WCAG 2.1: Contrast (Minimum) — w3.org
- W3C. WCAG 2.1: Non-text Contrast — w3.org
- Wilke C. O. *Fundamentals of Data Visualization*. O’Reilly, 2019. — clauswilke.com/dataviz
- Cairo A. *The Truthful Art*. New Riders, 2016. — thefunctionalart.com
- Nature. Formatting guide — nature.com
- ICMJE Recommendations — icmje.org
- ГОСТ 7.32-2017 — docs.cntd.ru
- ГОСТ 8.417-2002 — docs.cntd.ru
- Matplotlib: Fonts — matplotlib.org
- FontTools documentation — fonttools.readthedocs.io

Раздел 4. Основные виды научных графиков и области применения

Выбор графика — первый проектный шаг, и его почти нельзя исправить оформлением. Если для сравнения групп выбран график распределения, читатель не увидит сравнения; если для динамики — столбцы по категориям, он не увидит времени. Этот раздел — **карта**, а не учебник: здесь мы разбираем семейства графиков, их вопросы и ограничения, а подробные разборы с данными, «плохими» и «правильными» версиями будут в разделе 5.

> В разделе 5 каждый **отдельный график** получит свою папку, свой генератор `make_data.py` и свой набор `data/NN_dataset.csv`. Один «вид» на карте — это семейство; внутри него несколько графиков (например, линия, step, area и small multiples), и каждый станет отдельным разделом. Данные одного графика не переиспользуются в другом.

4.1 Пять вопросов перед выбором графика

Полезно задать себе пять вопросов — в этом порядке.

1. **Какой вопрос я задаю?** Сравнить группы, описать распределение, показать связь, динамику, состав, структуру, время до события, качество теста?
2. **Какие переменные?** Категориальные, непрерывные, временные, парные, цензурированные?
3. **Сколько наблюдений и групп?** 10 точек или 10 000? Одна группа или двадцать?
4. **Что важнее читателю?** Точное значение, ранг, форма распределения, неопределённость, наличие выбросов?
5. **Что читатель должен уметь прочитать?** Величину эффекта, разброс, доверительный интервал, порог, число рисков?

Если ответ на первый вопрос не формулируется, график, скорее всего, не нужен: данные лучше показать таблицей.

4.2 Карта семейств

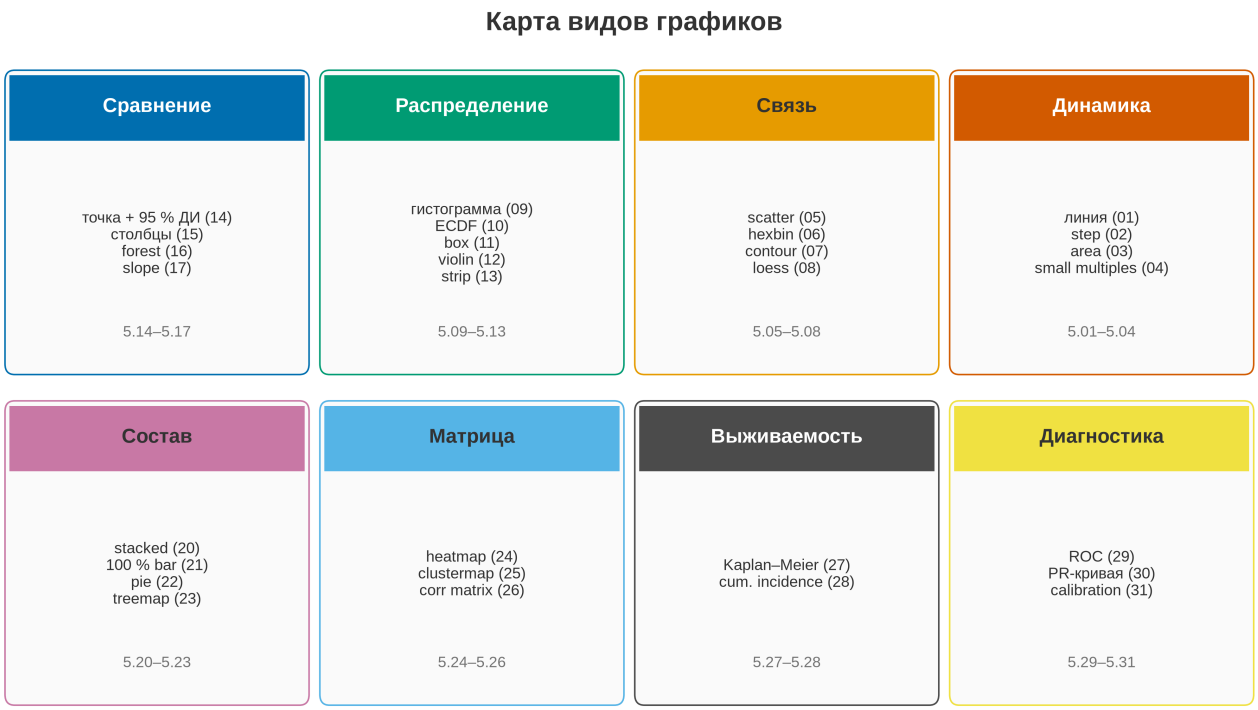


Рисунок 4.1. Карта семейств: вопрос, примеры графиков и номер раздела 5, где вид будет разобран подробно. Карта не заменяет таблицу выбора — она показывает связи между вопросами и формами.

Семейство	Вопрос	Графики (раздел 5)	Ограничения
Сравнение	«Кто больше и насколько?»	точка + 95 % ДИ (5.14), столбцы (5.15), forest (5.16), slope (5.17)	столбцы скрывают распределение; нужна нулевая база
Распределение	«Как устроена выборка?»	гистограмма (5.09), ECDF (5.10), box (5.11), violin (5.12), strip (5.13)	ширина бинов; box скрывает бимодальность; violin требует *n*
Связь	«Есть ли зависимость?»	scatter (5.05), hexbin (5.06), contour (5.07), loess (5.08)	overplotting; корреляция ≠ причинность
Динамика	«Как меняется во времени?»	линия (5.01), step (5.02), area (5.03), small multiples (5.04)	нерегулярные интервалы; нельзя соединять категории
Состав	«Из чего состоит целое?»	stacked bar (5.20), 100 % bar (5.21), pie (5.22), treemap (5.23)	части должны суммироваться; pie — максимум 5 долей
Матрица	«Где значения велики или малы?»	heatmap (5.24), clustermap (5.25), correlation matrix (5.26)	масштаб, кластеризация, colorbar
Выживаемость	«Когда происходит событие?»	Kaplan–Meier (5.27), cumulative incidence (5.28)	цензурирование, at-risk, конкурирующие риски
Диагностика	«Насколько хорош тест?»	ROC (5.29), precision–recall (5.30), calibration (5.31)	prevalence, порог, доверительные интервалы
Парные измерения	«Как меняется у каждого?»	slope chart (5.17), paired dot (5.18), Bland–Altman (5.19)	парность, пропущенные пары
Оценки эффекта	«Какой эффект и насколько он точен?»	forest (5.16), caterpillar (5.32), funnel (5.33)	лог-шкала для отношений, гетерогенность

4.3 Семейства подробнее

4.3.1 Сравнение

Вопрос: «Кто больше, насколько и насколько уверенно?»

Хорошие формы:

- **точка + 95 % ДИ** — лучше столбцов, потому что положение читается точнее длины, а интервал показывает неопределённость;
- **forest plot** — для нескольких оценок и эффектов;
- **slope chart** — для парных измерений;
- **столбцы** — только если нулевая база обязательна и распределение не главное.

Что важно: показывать эффект и ДИ, а не только *p*; не обрезать ось у столбцов; не скрывать *n* и разброс. Подробно — 5.14, 5.15, 5.16, 5.17.

4.3.2 Распределение

Вопрос: «Как устроена выборка: центр, разброс, форма, выбросы?»

Формы:

- **гистограмма** — форма распределения, но зависит от ширины бинов;
- **ECDF** — точное чтение квантилей и сравнение выборок;
- **box** — компактно, но скрывает бимодальность и размер выборки;
- **violin** — форма, но требует достаточного *n* и может вводить в заблуждение при малых группах;
- **strip / swarm** — отдельные точки, лучше при малых *n*;
- **raincloud** — комбинация, но не для каждого журнала.

Подробно — 5.09–5.13.

4.3.3 Связь

Вопрос: «Меняется ли одна величина вместе с другой?»

Формы:

- **scatter** — базовая форма; при больших *n* — **hexbin** или **contour**;
- **loess/regression** — тренд, но не заменяет точки;
- **log-шкалы** — если связь мультипликативная;
- **small multiples** — если есть третья категориальная переменная.

Что важно: не путать корреляцию с причинностью, показывать *n* и выбросы, не использовать две оси Y. Подробно — 5.05–5.08.

4.3.4 Динамика

Вопрос: «Как величина меняется во времени?»

Формы:

- **линия** — регулярные интервалы, одна или несколько серий;
- **step** — измерения «до/после» или дискретные события;
- **area** — накопленный итог, но не для сравнения многих серий;
- **small multiples** — много серий или групп;
- **individual trajectories** — если важна гетерогенность.

Что важно: время — по оси X; не соединяйте линии через категории; показывайте пропуски и нерегулярность; не начинайте ось с произвольного значения без объяснения. Подробно — 5.01–5.04.

4.3.5 Состав

Вопрос: «Из чего состоит целое и как доли меняются?»

Формы:

- **stacked bar** — состав по группам;
- **100 % bar** — сравнение долей;
- **pie** — только 3–5 долей, и только если сумма долей действительно 100 %;
- **treemap** — иерархический состав;
- **alluvial/Sankey** — потоки, но требуют осторожности.

Что важно: части должны суммироваться в целое; круговая диаграмма плохо читается при многих долях и почти всегда проигрывает полосам. Подробно — 5.20–5.23.

4.3.6 Матрица и многомерность

Вопрос: «Где значения велики, где структура, где корреляции?»

Формы:

- **heatmap** — матрица значений; обязательна цветовая шкала с единицами;
- **clustermap** — порядок строк/столбцов подсказывает структуру, но кластеризация субъективна;
- **correlation matrix** — только как дополнение, не как доказательство;
- **PCA/biplot** — уменьшение размерности, но интерпретация меняется;
- **small multiples / parallel coordinates** — альтернатива «радуге».

Подробно — 5.24–5.26.

4.3.7 Выживаемость

Вопрос: «Когда происходит событие и как различаются группы?»

Формы:

- **Kaplan–Meier** — кривые выживаемости;
- **cumulative incidence** — конкурирующие риски;
- **forest plot** — hazard ratio;
- **at-risk table** — число под риском по времени.

Что важно: цензурирование, число рисков, доверительные интервалы, log-rank/Cox, проверка пропорциональности. Кривые без at-risk table и без числа событий читаются плохо. Подробно — 5.27–5.28.

4.3.8 Диагностика

Вопрос: «Насколько хорош тест и при каком пороге?»

Формы:

- **ROC** — чувствительность/специфичность, но зависит от prevalence;
- **precision–recall** — лучше при сильном дисбалансе классов;
- **calibration** — соответствие предсказанных и наблюдаемых вероятностей;
- **decision curve** — клиническая полезность.

Что важно: указывать prevalence, порог, ДИ, число наблюдений; AUROC — не единственная метрика. Подробно — 5.29–5.31.

4.3.9 Парные измерения

Вопрос: «Как меняется каждый объект?»

Формы:

- **slope chart** — линии «до/после» для каждого пациента;
- **paired dot plot** — пары точек;
- **Bland–Altman** — согласие методов, а не корреляция.

Что важно: не анализировать парные данные как независимые группы; показывать пропущенные пары. Подробно — 5.17–5.19.

4.3.10 Оценки эффекта и неопределённость

Вопрос: «Какой эффект и насколько он точен?»

Формы:

- **forest plot** — оценки и ДИ для нескольких групп/исследований;
- **caterpillar** — много оценок;
- **funnel** — публикационное смещение, но только при достаточном числе исследований.

Что важно: эффект + ДИ, лог-шкала для отношений (OR, RR, HR), гетерогенность, а не только *p*. Подробно — 5.16, 5.32–5.33.

4.4 Когда таблица лучше графика

График не всегда выигрывает. Таблица лучше, если:

- значений мало (3–8) и нужна точная выборка;
- единицы разные и график требует нескольких осей;
- важны точные цифры, а не форма;
- категорий слишком много для читаемой палитры;
- данные неполные или несопоставимые.

Практическое правило: **если таблица отвечает на вопрос быстрее и точнее, делайте таблицу**. График — для закономерностей, сравнений и формы, а не для переписывания чисел.

4.5 Антипаттерны выбора

Антипаттерн	Почему плохо	Альтернатива
3D-столбцы и 3D-круг	перспектива искажает длину/площадь	2D
Круговая с 8–12 долями	углы и площади читаются плохо	полосы, stacked bar
Столбцы с SD/SEM	скрывают распределение и *n*	точки, box, violin
Обрезанная ось у столбцов	искажает длину	нулевая база или точки
Линия по категориям	навязывает порядок	столбцы/точки
Две оси Y	ложная корреляция	две панели или индекс
Scatter на 100 000 точек	overplotting	hexbin, density, contour
ROC без prevalence	AUROC не отражает клиническую пользу	PR, calibration
Kaplan–Meier без at-risk	хвост кривой не интерпретируется	at-risk table
Heatmap без шкалы	цвет не читается	colorbar, contour
Radar chart	площадь/угол искажают	small multiples, bar
Word cloud	площадь не пропорциональна	bar
100 % stacked на 20 категорий	невозможно сравнить	small multiples

4.6 Что дальше: как устроен раздел 5

Раздел 5 — практическая часть. Каждый вид графика живёт в своей папке:

```
05_charts/01_line/
├── README.md
├── line.md
├── line.typ
└── scripts/
    ├── make_data.py   # свой генератор → data/01_dataset.csv
    ├── bad_plot.py    # неудачный график → images/05_01_bad_line.*
    └── good_plot.py   # правильный график → images/05_01_good_line.*
```

В каждом разборе будет:

1. сфера применения и типичные вопросы;
2. реалистичные синтетические данные с единицами и диапазонами;
3. неудачный график и разбор ошибок;
4. правильный график и объяснение улучшений;
5. чек-лист и связь с нормативами.

План:

Семейство	**Разделы 5**
Динамика	5.01 линия, 5.02 step, 5.03 area, 5.04 small multiples
Связь	5.05 scatter, 5.06 hexbin, 5.07 contour, 5.08 loess
Распределение	5.09 гистограмма, 5.10 ECDF, 5.11 box, 5.12 violin, 5.13 strip
Сравнение	5.14 точка + ДИ, 5.15 столбцы, 5.16 forest, 5.17 slope
Состав	5.20 stacked bar, 5.21 100 % bar, 5.22 pie, 5.23 treemap
Матрица	5.24 heatmap, 5.25 clustermap, 5.26 correlation matrix
Выживаемость	5.27 Kaplan–Meier, 5.28 cumulative incidence
Диагностика	5.29 ROC, 5.30 precision–recall, 5.31 calibration
Парные	5.17 slope, 5.18 paired dot, 5.19 Bland–Altman
Оценки эффекта	5.16 forest, 5.32 caterpillar, 5.33 funnel

Полный индекс с папками и данными — в `05_charts/README.md`. Порядок может меняться по запросу. Каждый график получит **свой** генератор и **свой** датасет; переиспользование CSV между графиками запрещено.

4.7 Чек-лист выбора графика

- ☐ Вопрос сформулирован одним предложением.
- ☐ Тип переменных определён: категориальные, непрерывные, время, парные, цензурированные.
- ☐ Известны n и число групп.
- ☐ Понятно, что важнее: точное значение, форма, неопределённость.
- ☐ Выбрано семейство, а не «любимый тип графика».
- ☐ Проверены ограничения семейства.
- ☐ Рассмотрена альтернатива в виде таблицы.
- ☐ Цвет и форма не единственные носители смысла.
- ☐ График выдержит конечную ширину и печать.
- ☐ Указан раздел 5, где вид будет разобран подробно.

4.8 Итоги

- Тип графика определяется вопросом и структурой данных, а не привычкой.
- Сравнение, распределение, связь, динамика, состав, матрица, выживаемость, диагностика, парные измерения и оценки эффекта — разные семейства с разными ограничениями.
- Столбцы — не универсальный график; круговая — не универсальный график состава.
- Если таблица точнее и быстрее, выбирайте таблицу.
- Раздел 5 даст полный цикл для каждого из 33 графиков: данные → плохо → разбор → хорошо, с отдельным генератором и датасетом.

Источники к разделу

- Wilke C. O. *Fundamentals of Data Visualization*. O’Reilly, 2019. — clauswilke.com/dataviz
- Cairo A. *The Truthful Art*. New Riders, 2016. — thefunctionalart.com
- Tufte E. R. *The Visual Display of Quantitative Information*. Graphics Press, 1983. — edwardtufte.com
- Cleveland W. S., McGill R. Graphical Perception: Theory, Experimentation, and Application to the Development of Graphical Methods // *JASA*. 1984. Vol. 79, № 387. P. 531–554. — doi:10.1080/01621459.1984.10478080
- Weissgerber T. L. et al. Beyond Bar and Line Graphs: Time for a New Data Presentation Paradigm // *PLoS Biology*. 2015. Vol. 13, № 4. e1002128. — doi:10.1371/journal.pbio.1002128
- From Data to Viz — data-to-viz.com
- Financial Times Visual Vocabulary — github.com/Financial-Times/chart-doctor
- Data Viz Project — datavizproject.com
- CONSORT 2010 — consort-statement.org
- STROBE — strobe-statement.org
- PRISMA — prisma-statement.org

5.01 Линейный график: динамика во времени

Линейный график — самый частый в научных статьях и один из самых обманчивых. Он кажется простым: время по X, значение по Y, точки соединили. Но именно здесь легко спрятать неопределённость, раздуть эффект масштабом и потерять внимание читателя к главному.

Этот раздел — первый практический разбор. Данные, «плохая» и «правильная» версии используют один и тот же CSV; различается только визуализация.

5.01.1 Сфера применения

Линейный график отвечает на вопрос: **как величина меняется во времени или вдоль упорядоченной оси?**

Типичные случаи:

- повторные измерения у одних и тех же пациентов (до/через 4/8/12 недель);
- динамика биомаркеров, АД, ЧСС, глюкозы, HbA1c;
- кривые роста и дозозависимые эффекты;
- временные ряды в эпидемиологии и организации здравоохранения;
- сравнение нескольких групп во времени.

Когда линия **не** подходит:

- ось X — неупорядоченные категории (пол, регион, препарат): линия навязывает порядок и расстояние;
- серий слишком много (больше 5–7): лучше small multiples;
- интервалы времени неравномерны, а вы строите равномерные позиции — это искажает скорость изменения;
- показаны только средние, а разброс и *n* важны для вывода;
- данные цензурированы (выживаемость) — нужен Kaplan–Meier, а не линия.

5.01.2 Данные

Сценарий: гипотетическое 12-недельное исследование, 120 пациентов с артериальной гипертензией, три группы. САД измеряют на 0, 4, 8 и 12-й неделе.

Колонка	Смысл	Единица
`patient_id`	идентификатор пациента	—
`group`	группа терапии	—
`week`	неделя измерения (0, 4, 8, 12)	недели
`sbp_mm_hg`	систолическое АД	мм рт. ст.

n = 40 в каждой группе, 480 строк в long-формате. Данные синтетические, но правдоподобные по единицам и величинам: плацебо снижает САД примерно до 148, препарат A — до 139, препарат B — до 132 мм рт. ст.

Генератор: `05_charts/01_line/scripts/make_data.py → data/01_dataset.csv`.

5.01.3 Плохой график

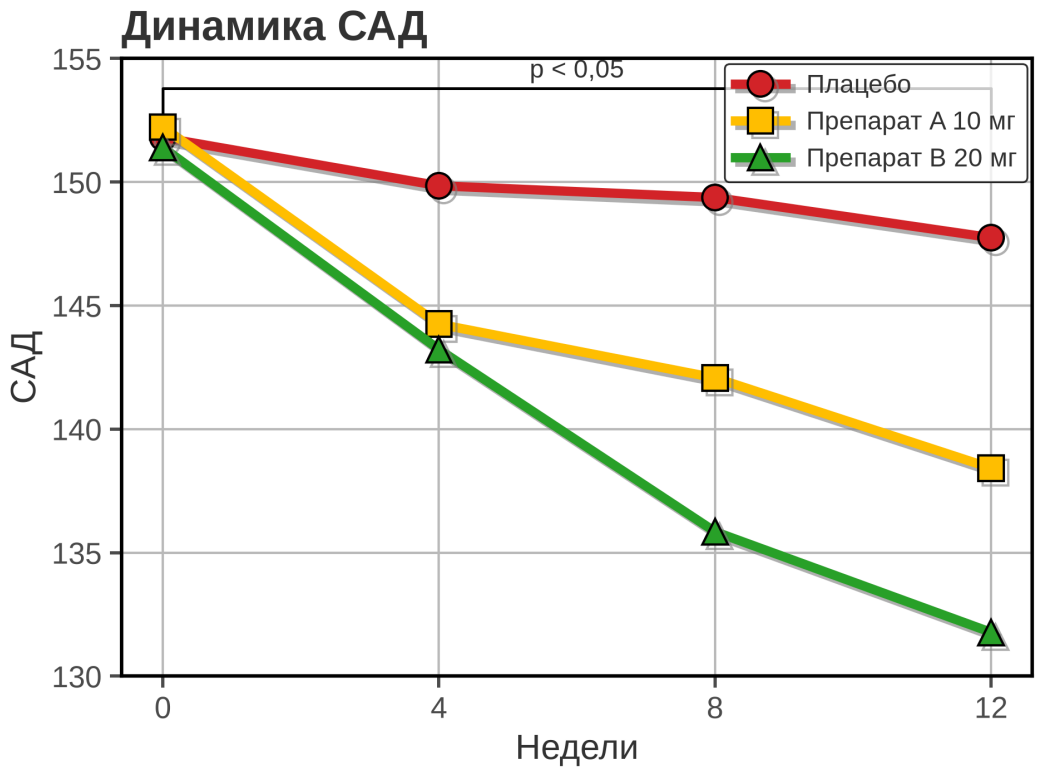


Рисунок 5.1.1. Плохой линейный график: обрезанная ось, светофорные цвета, тени, тяжёлая сетка и легенда поверх данных.

Код: `05_charts/01_line/scripts/bad_plot.py`.

Что с ним не так:

1. **Обрезанная ось Y (130–155).** Для линии нулевая база не обязательна, но диапазон не должен обрезать данные и создавать ложный драматизм. Здесь препарат В почти упирается в нижнюю границу, а плацебо выглядит почти плоским; читатель переоценивает разницу.
2. **Светофорная палитра.** Красный — жёлтый — зелёный неразличим при протанопии/дейтеранопии и навязывает оценку «плохо — средне — хорошо».
3. **Толстые линии, тени и крупные маркеры.** Тень не кодирует данные; она утяжеляет линии и мешает сравнивать наклоны.
4. **Тяжёлая сетка по обеим осям и полная рамка.** Сетка конкурирует с данными, вертикальные линии не помогают читать недели.
5. **Заголовок «Динамика САД».** Он не сообщает, что именно произошло и какой вывод должен сделать читатель.
6. **Нет единиц, *n* и неопределённости.** «САД» — это что: исходное, конечное, среднее? В каких единицах? Сколько пациентов?
7. **Только средние.** Без доверительных интервалов или полос разброса нельзя понять, насколько устойчива разница.
8. **Легенда внутри поля данных.** Она дублирует подписи и закрывает часть линий.
9. **Брекет «p < 0,05» без теста и эффекта.** Значимость не заменяет величину эффекта; не указано, какой тест и какие группы сравнивались.

Дополнительно: равномерные позиции 0/4/8/12 здесь корректны, потому что интервалы равны. Если бы интервалы были неравными (0, 2, 12, 52 недели), точки нужно ставить по реальному времени, а не через равные шаги.

5.01.4 Правильный график

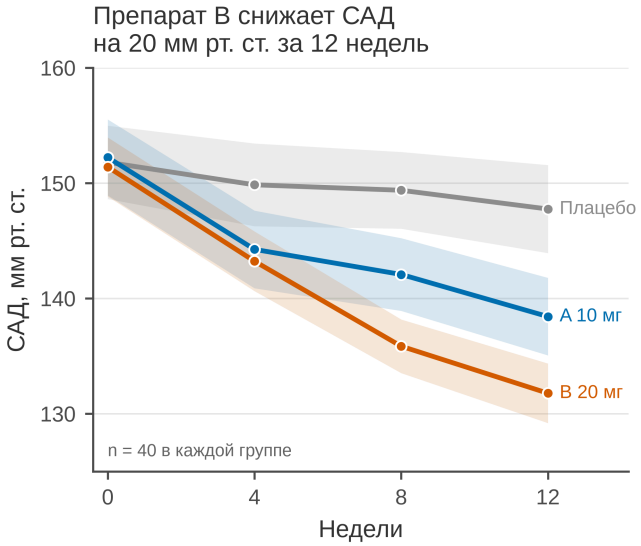


Рисунок 5.1.2. Правильный линейный график: среднее и 95 % ДИ, палитра Okabe–Ito, прямые подписи и заголовок-вывод.

Код: `05_charts/01_line/scripts/good_plot.py`.

Что улучшено:

1. **Ширина 85 мм, высота 72 мм.** Рисунок спроектирован в конечном журнальном размере, а не уменьшен из слайда.
2. **Среднее и 95 % ДИ.** Полосы показывают неопределённость; видно, где различия уверенные, а где интервалы пересекаются.
3. **Палитра Okabe–Ito.** Серый — контроль, синий — препарат A, вермилион — препарат B; цвета различимы при дальтонизме.
4. **Прямые подписи в конце линий.** Легенда не нужна; читатель сразу видит, какая линия какой группе соответствует.
5. **Заголовок-вывод.** «Препарат B снижает САД на 20 мм рт. ст. за 12 недель» — сразу понятно, что читать.
6. **Единицы и *n*.** «САД, мм рт. ст.» и «n = 40 в каждой группе»; в подписи можно добавить определение ДИ.
7. **Ось Y 125–160.** Достаточный контекст: видны исходный уровень, конечные значения и величина снижения, без обрезки «под эффект».
8. **Лёгкая сетка только по Y.** Верхняя и правая рамки убраны; данные контрастнее осей.
9. **Маркеры только в измеренных точках.** Линия соединяет реальные недели 0/4/8/12, а не произвольные позиции.

5.01.5 Сопоставление

Что было	Почему плохо	Что сделано
ось Y 130–155	масштаб раздувает различия	125–160, виден контекст
красный/жёлтый/зелёный	ложная семантика, CVD	Okabe–Ito: серый/синий/вермилион
тени, толстые линии	декор, мешает сравнивать наклоны	линии 1,8 pt, маркеры 4 pt
сетка по X и Y	шум	сетка только по Y
полная рамка	визуальный шум	только левая и нижняя оси
легенда	дублирует подписи	прямые подписи
«Динамика САД»	нет сообщения	заголовок-вывод
нет единиц и *n*	невозможно прочитать	единицы, *n*
только средние	скрыта неопределённость	среднее + 95 % ДИ
p < 0,05	нет теста и эффекта	эффект и ДИ; тест — в подписи

5.01.6 Чек-лист линейного графика

- ☐ Время (или упорядоченная ось) — по X, значения — по Y.

- ☐ Интервалы на оси X соответствуют реальному времени.
- ☐ Ось Y не обрезает данные и не создаёт ложного драматизма.
- ☐ Показаны среднее и 95 % ДИ (или individual trajectories).
- ☐ Указаны *n* и единицы.
- ☐ Цвет не единственный носитель смысла.
- ☐ Легенда не закрывает данные; лучше прямые подписи.
- ☐ Заголовок сообщает вывод, а не «динамику».
- ☐ Нет 3D, теней и тяжёлой сетки.
- ☐ Рисунок проверен в конечном размере 85 мм.

5.01.7 Как воспроизвести

```
uv sync
uv run python 05_charts/01_line/scripts/make_data.py
uv run python 05_charts/01_line/scripts/bad_plot.py
uv run python 05_charts/01_line/scripts/good_plot.py
```

Ключевой фрагмент «правильного» кода:

```
fig, ax = plt.subplots(
    figsize=figure_size("single", height_mm=72),
    layout="constrained",
)
ax.fill_between(x, part["ci_low"], part["ci_high"], color=color, alpha=0.15)
ax.plot(x, part["mean"], color=color, marker="o", linewidth=1.8)
ax.annotate(GROUP_SHORT[group], (x[-1] + 0.08, part["mean"].iloc[-1]))
save_figure(fig, "05_01_good_line")
```

5.01.8 Что дальше

Следующий график — **5.02 step**: ступенчатая функция для событий, измерений «до/после» и дискретных изменений. У него будет свой генератор и свой `data/02_dataset.csv`.

Источники

- Cleveland W. S., McGill R. Graphical Perception // *JASA*. 1984. — doi:10.1080/01621459.1984.10478080
- Weissgerber T. L. et al. Beyond Bar and Line Graphs // *PLoS Biology*. 2015. — doi:10.1371/journal.pbio.1002128
- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz

5.02 Ступенчатый график: события и дискретные изменения

Ступенчатый график — это линия, у которой значение **сохраняется** между событиями и меняется скачком в момент события. Он нужен там, где процесс по своей природе дискретен: доза препарата, скорость инфузии, статус, тариф, число коек, порог.

Главная ошибка — соединить такие точки наклонной линией. Тогда читатель видит плавное изменение, которого в данных не было.

5.02.1 Сфера применения

Ступенчатая функция отвечает на вопрос: **в какой момент значение изменилось и каким оно оставалось до следующего события?**

Типичные случаи:

- титрование дозы препарата (варфарин, инсулин, антибиотик);
- скорость инфузии (мкг/кг/мин, мл/ч);
- изменение статуса (госпитализирован/выписан, жив/умер — но для выживаемости нужен Kaplan–Meier);
- тарифы, оклады, налоговые ставки;
- число занятых коек или доступных аппаратов;
- ступенчатые протоколы и пороговые правила.

Когда ступенчатый график **не** подходит:

- величина меняется непрерывно (концентрация, температура, АД);
- ось X — неупорядоченные категории;
- нужно показать распределение или неопределённость, а не момент изменения;
- данных слишком мало для шага — тогда лучше точки.

5.02.2 Данные

Сценарий: три пациента на варфарине, 12 недель. Дозу меняют на визитах раз в неделю, шагом 0,5 мг/сут; INR измеряют на каждом визите, целевой диапазон — 2,0–3,0.

Колонка	Смысл	Единица
`patient_id`	идентификатор пациента	—
`week`	неделя визита (0–12)	недели
`dose_mg`	доза варфарина	мг/сут
`inr`	международное нормализованное отношение	—

39 строк: 3 пациента × 13 визитов. Дозы — 3,0–7,5 мг/сут; у P01 доза стабильна, у P02 и P03 — титруется. Это не исследование, а иллюстрация индивидуального титрования; для групповых выводов нужны другие графики и статистика.

Генератор: `05_charts/02_step/scripts/make_data.py → data/02_dataset.csv`.

5.02.3 Плохой график

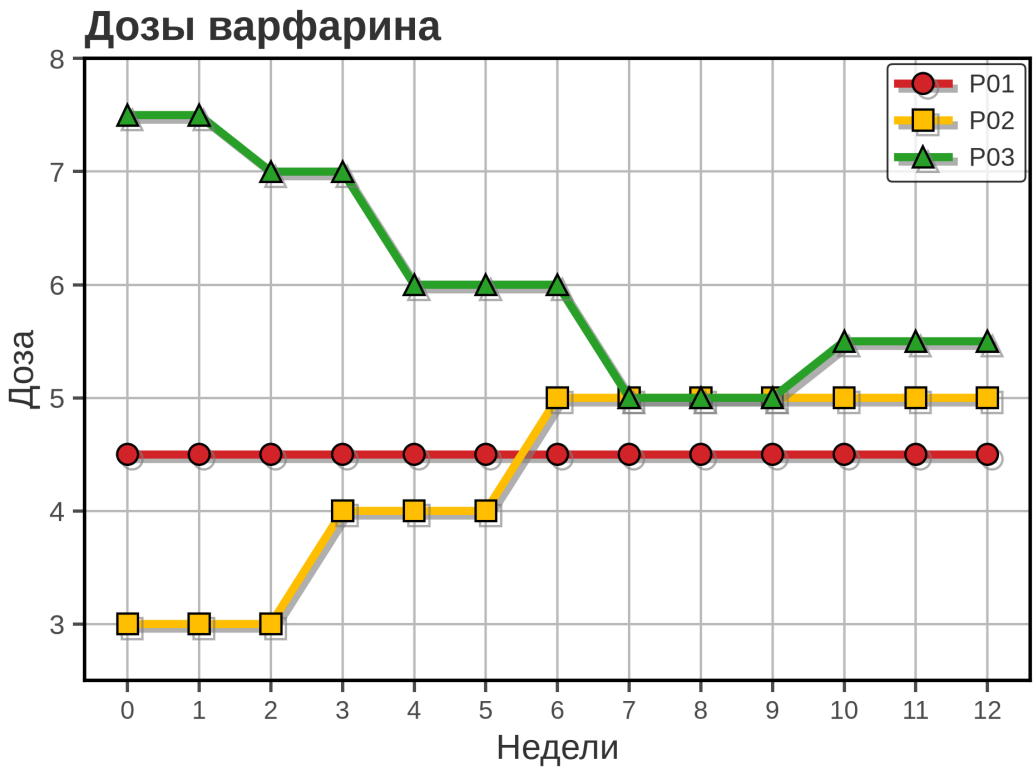


Рисунок 5.2.1. Плохой ступенчатый график: наклонные линии вместо ступеней, обрезанная ось, светофорные цвета и тени.

Код: `05_charts/02_step/scripts/bad_plot.py`.

Что с ним не так:

1. **Наклонные линии вместо ступеней.** Доза не меняется плавно между визитами; `ax.plot` создаёт ложное впечатление непрерывного титрования. Это главная ошибка.
2. **Обрезанная ось Y (2,5–8).** Масштаб раздувает различия; нулевая база для дозы не обязательна, но диапазон должен показывать реальный масштаб.
3. **Светофорная палитра.** Красный — жёлтый — зелёный неразличим при протанопии/дейтеранопии и навязывает оценку «плохо — средне — хорошо».
4. **Толстые линии, тени и крупные маркеры.** Декор мешает видеть моменты изменения.
5. **Тяжёлая сетка по обеим осям и полная рамка.** Шум, который конкурирует с данными.
6. **Заголовок «Дозы варфарина».** Нет сообщения: что происходит с дозами и почему это важно.
7. **Нет единиц, числа пациентов и контекста INR.** «Доза» — в чём? Сколько пациентов? Почему дозу меняли?
8. **Легенда внутри поля данных.** Она дублирует подписи и закрывает линии.

5.02.4 Правильный график

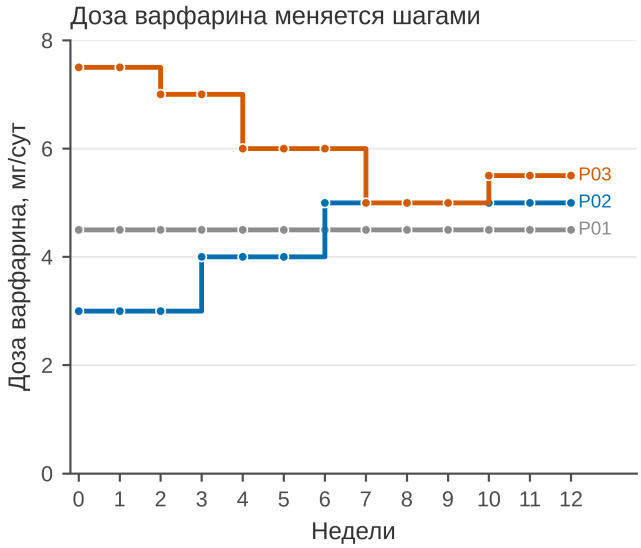


Рисунок 5.2.2. Правильный ступенчатый график: steps-post, маркеры визитов, прямые подписи и ось 0–8 мг/сут.

Код: `05_charts/02_step/scripts/good_plot.py`.

Что улучшено:

1. **`ax.step(..., where="post")`.** Доза сохраняется до следующего визита; вертикальные сегменты показывают скачок, горизонтальные — период постоянной дозы.
2. **Маркеры в моменты визитов.** Видно, где именно измеряли и меняли дозу, а не абстрактную кривую.
3. **Прямые подписи P01/P02/P03.** Легенда не нужна; конец линии сразу подписан.
4. **Ось Y 0–8 мг/сут.** Виден реальный масштаб доз, без обрезки «под эффект».
5. **Единицы и недели.** «Доза варфарина, мг/сут», недели 0–12.
6. **Заголовок-вывод.** «Доза варфарина меняется шагами» объясняет, что читать.
7. **Палитра Okabe–Ito.** Серый — P01, синий — P02, вермилион — P03.
8. **Лёгкая сетка только по Y.** Верхняя и правая рамки убраны.
9. **85 мм в ширину.** Рисунок спроектирован в конечном размере.

INR не вынесен на вторую ось: две оси Y создают ложную корреляцию. Если INR важен, сделайте отдельную панель или таблицу; в подписи укажите целевой диапазон 2,0–3,0.

5.02.5 Сопоставление

Что было	Почему плохо	Что сделано
`ax.plot`	плавное изменение, которого не было	`ax.step(where="post")`
ось Y 2,5–8	масштаб раздувает различия	0–8 мг/сут
красный/жёлтый/зелёный	ложная семантика, CVD	Okabe–Ito
тени, толстые линии	декор	линии 1,8 pt, маркеры 3,5 pt
сетка по X и Y	шум	сетка только по Y
полная рамка	визуальный шум	только левая и нижняя оси
легенда	дублирует подписи	прямые подписи
«Дозы варфарина»	нет сообщения	заголовок-вывод
нет единиц и *n*	невозможно прочитать	единицы, число пациентов в подписи
INR на второй оси	ложная корреляция	INR в подписи/отдельной панели

5.02.6 Чек-лист ступенчатого графика

- ☐ Величина действительно постоянна между событиями.
- ☐ Использован `step`, а не `plot` с наклонными линиями.
- ☐ Выбрано `where="post"` или `where="pre"` осознанно.
- ☐ Маркеры стоят в моменты измерения/изменения.
- ☐ Ось Y показывает реальный масштаб, без обрезки «под эффект».
- ☐ Указаны единицы, число пациентов и контекст.

- ☐ Прямые подписи лучше легенды.
- ☐ Нет двух осей Y.
- ☐ Цвет не единственный носитель смысла.
- ☐ Рисунок проверен в конечном размере 85 мм.

5.02.7 Как воспроизвести

```
uv sync
uv run python 05_charts/02_step/scripts/make_data.py
uv run python 05_charts/02_step/scripts/bad_plot.py
uv run python 05_charts/02_step/scripts/good_plot.py
```

Ключевой фрагмент:

```
ax.step(
    weeks,
    doses[patient].to_numpy(),
    where="post",
    color=color,
    linewidth=1.8,
    marker="o",
    markersize=3.5,
)
```

`where="post"` означает: значение `y[i]` держится от `x[i]` до `x[i+1]`, затем происходит скачок. Если событие фиксируется в конце интервала, проверьте, не нужен ли `where="pre"`.

5.02.8 Что дальше

Следующий график — **5.03 area**: область под линией для накопленных и составных величин. У него будет свой генератор и свой `data/03_dataset.csv`.

Источники

- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Matplotlib: `step` — matplotlib.org
- Tufte E. R. *The Visual Display of Quantitative Information*. 1983. — edwardtufte.com

5.03 Area chart: площадь как величина

Area chart — это линия с заливкой под ней. Он оправдан только тогда, когда **площадь является смыслом**: площадь под кривой концентрации (AUC), накопленная экспозиция, суммарная нагрузка, cumulative burden. Если заливка просто «украшает» линию, она добавляет чернила, но не информацию.

Главное правило: **заливка area chart должна начинаться с нуля**. Иначе площадь перестаёт быть пропорциональна величине, которую она якобы кодирует.

5.03.1 Сфера применения

Area chart отвечает на вопрос: **какая суммарная величина накоплена за период?**

Типичные случаи:

- площадь под кривой концентрация–время (AUC) в фармакокинетике;
- накопленная экспозиция лекарства или излучения;
- суммарная нагрузка (число случаев, койко-дни, затраты) за период;
- cumulative incidence, если это не кривая выживаемости (для выживаемости — Kaplan–Meier, 5.27);
- stacked area для состава во времени, но с осторожностью: наложение областей затрудняет сравнение (для состава чаще лучше stacked bar, 5.20).

Когда area chart **не** подходит:

- площадь не несёт смысла, а заливка нужна «для красоты» — используйте линию;
- несколько перекрывающихся областей: одна заливка закрывает другую;
- ось Y не начинается с нуля;
- нужно точное сравнение значений — линия или точки читаются лучше;
- категории по X не упорядочены.

5.03.2 Данные

Сценарий: 40 пациентов получают условный препарат внутрь в дозе 500 мг. Концентрацию в плазме измеряют через 0, 1, 2, 4, 6, 8, 12 и 24 часа. AUC 0–24 — интегральная экспозиция, мг·ч/л.

Колонка	Смысл	Единица
`patient_id`	идентификатор пациента	—
`time_h`	время после приёма	часы
`conc_mg_l`	концентрация в плазме	мг/л

320 строк: 40 пациентов × 8 моментов. Средний AUC 0–24 — 80,7 ± 18,2 мг·ч/л; пик концентрации — около 8–9 мг/л через 1–2 часа; к 24 часам — около 0,5 мг/л.

Генератор: `05_charts/03_area/scripts/make_data.py → data/03_dataset.csv`.

5.03.3 Плохой график

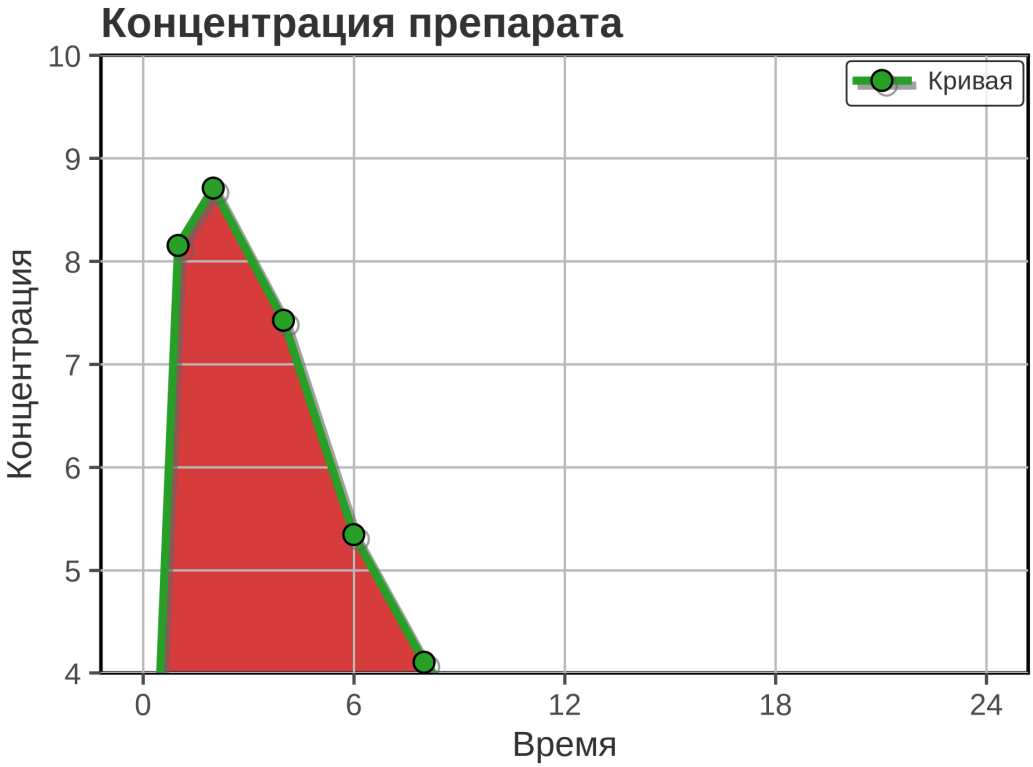


Рисунок 5.3.1. Плохой area chart: заливка от 4 вместо нуля, обрезанная ось, красная заливка и зелёная линия, тени, тяжёлая сетка.

Код: `05_charts/03_area/scripts/bad_plot.py`.

Что с ним не так:

1. **Заливка начинается с y = 4, а не с нуля.** Площадь больше не пропорциональна AUC; график показывает не интеграл, а обрезок. Это главная ошибка.
2. **Обрезанная ось Y (4–10).** Пик и хвост искажены; нижняя часть кривой и базовая линия скрыты.
3. **Красная заливка и зелёная линия.** Светофорная пара неразличима при протанопии/дейтеранопии; тёмная заливка конкурирует с линией.
4. **Тени и крупные маркеры.** Декор, который не кодирует данные.
5. **Тяжёлая сетка по обеим осям и полная рамка.** Сетка просвечивает через заливку и создаёт шум.
6. **Заголовок «Концентрация препарата».** Не сообщает, что площадь — это экспозиция и какова её величина.
7. **Нет единиц, *n* и AUC.** «Концентрация» — в чём? Сколько пациентов? Чему равна площадь?
8. **Легенда из одной строки «Кривая».** Она не несёт информации.

5.03.4 Правильный график

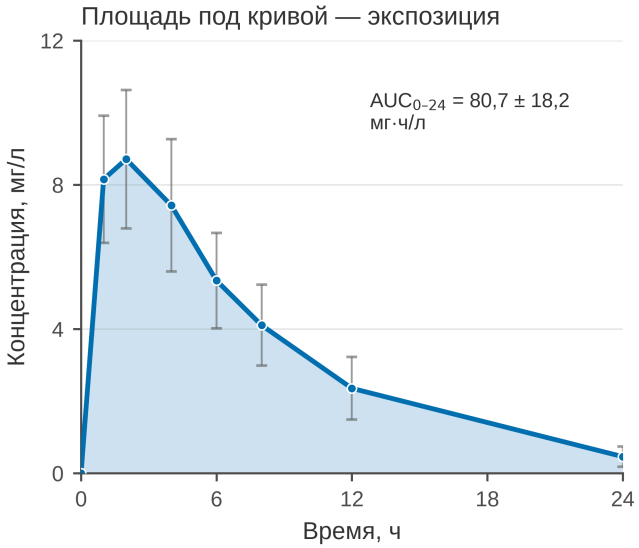


Рисунок 5.3.2. Правильный area chart: заливка от нуля, подпись AUC, среднее ± SD, палитра Okabe–Ito, ось 0–12 мг/л.

Код: `05_charts/03_area/scripts/good_plot.py`.

Что улучшено:

1. **Заливка от 0.** Площадь под кривой действительно равна AUC; базовая линия видна.
2. **Подпись AUC 0–24 = 80,7 ± 18,2 мг·ч/л.** Площадь превращается в число, которое можно интерпретировать.
3. **Ось Y 0–12 мг/л.** Видны пик, хвост и нулевая база; нет обрезки «под эффект».
4. **Среднее ± SD в точках.** Видна неопределённость; заливка показывает интеграл, а не заменяет разброс.
5. **Палитра Okabe–Ito.** Один синий цвет для одной серии; ничего лишнего.
6. **Единицы и *n*.** «Концентрация, мг/л», «Время, ч», *n* = 40 в подписи.
7. **Заголовок-вывод.** «Площадь под кривой — экспозиция» объясняет, зачем здесь заливка.
8. **Лёгкая сетка только по Y, без верхней и правой рамок.**
9. **85 мм в ширину.** Рисунок спроектирован в конечном размере.

Если площадь не нужна, эти же данные лучше показать линией без заливки: меньше чернил, та же информация. Area chart — не «линия с красивым фоном», а график интеграла.

5.03.5 Сопоставление

Что было	Почему плохо	Что сделано
заливка от 4	площадь не равна AUC	заливка от 0
ось Y 4–10	обрезаны пик и хвост	0–12 мг/л
красная заливка + зелёная линия	CVD, шум	один синий цвет
тени, крупные маркеры	декор	линия 1,8 pt, маркеры 3,5 pt
сетка по X и Y	шум	сетка только по Y
полная рамка	визуальный шум	только левая и нижняя оси
легенда «Кривая»	бесполезна	без легенды
«Концентрация препарата»	нет сообщения	заголовок-вывод
нет AUC и единиц	площадь не читается	AUC, мг·ч/л, *n*
только среднее	нет неопределённости	среднее ± SD

5.03.6 Чек-лист area chart

- ☐ Площадь действительно является смыслом (AUC, накопление).
- ☐ Заливка начинается с нуля.
- ☐ Ось Y не обрезает нижнюю часть площади.
- ☐ Подписана величина площади (AUC, сумма, интеграл).

- ☐ Показана неопределённость (SD/CI или отдельные кривые).
- ☐ Указаны единицы, *n*, время.
- ☐ Нет перекрывающихся непрозрачных областей.
- ☐ Заливка не конкурирует с линией и сеткой.
- ☐ Если площадь не нужна — выбран line chart.
- ☐ Рисунок проверен в конечном размере 85 мм.

5.03.7 Как воспроизвести

```
uv sync
uv run python 05_charts/03_area/scripts/make_data.py
uv run python 05_charts/03_area/scripts/bad_plot.py
uv run python 05_charts/03_area/scripts/good_plot.py
```

Ключевые фрагменты:

```
ax.fill_between(time, 0, mean, color=PRIMARY_BLUE, alpha=0.18, linewidth=0)
ax.plot(time, mean, color=PRIMARY_BLUE, marker="o", linewidth=1.8)

auc = np.trapezoid(part["conc_mg_l"], part["time_h"])
```

`np.trapezoid` считает площадь трапеций; единицы AUC — мг·ч/л, потому что концентрация в мг/л умножается на время в часах.

5.03.8 Что дальше

Следующий график — **5.04 small multiples**: несколько панелей с общей шкалой для многомерных данных. У него будет свой генератор и свой `data/04_dataset.csv`.

Источники

- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Matplotlib: `fill_between` — matplotlib.org
- NumPy: `trapezoid` — numpy.org
- Tufte E. R. *The Visual Display of Quantitative Information*. 1983. — edwardtufte.com

5.04 Small multiples: много панелей, одна логика

Small multiples (малые кратные) — это ряд небольших графиков с одинаковой структурой и, как правило, общей шкалой. Вместо того чтобы рисовать шесть линий на одной оси и надеяться, что читатель их различит, мы показываем шесть панелей: сравнение идёт по форме и уровню, а не по цвету.

Принцип прост: **одна панель — одна серия; общая шкала — контракт сравнения.** Если у панелей разные оси, сравнение становится косметикой.

5.04.1 Сфера применения

Small multiples отвечают на вопрос: **как различаются группы, если смотреть на них по отдельности, но по одной шкале?**

Типичные случаи:

- динамика показателя по 5–20 отделениям, регионам, центрам;
- распределения по группам (гистограммы или box в facets);
- сезонность по месяцам для многих категорий;
- сравнение центров в многоцентровом исследовании;
- проверка согласованности трендов без наложения линий.

Когда small multiples **не** нужны:

- серий 2–3: обычная линия с прямыми подписями читается лучше;
- нужно точное сравнение двух значений — точки/таблица;
- панели не помещаются в журнальную ширину;
- шкалы всё равно придётся делать разными — тогда это уже не small multiples, а набор разных графиков.

5.04.2 Данные

Сценарий: шесть отделений больницы, 12 месяцев. Показатель — потребление антибиотиков в DDD на 100 койко-дней. Зимой потребление выше, летом ниже.

Колонка	Смысл	Единица
`department`	отделение	—
`month`	месяц (1–12)	—
`ddd_per_100_bed_days`	потребление антибиотиков	DDD/100 койко-дней

72 строки: 6 отделений × 12 месяцев. Средние уровни: ОРИТ — 109,4, пульмонология — 80,1, хирургия — 69,4, терапия — 55,9, урология — 49,3, кардиология — 45,7. ОРИТ потребляет в 2,4 раза больше кардиологии.

Генератор: `05_charts/04_small_multiples/scripts/make_data.py` → `data/04_dataset.csv`.

5.04.3 Плохой график

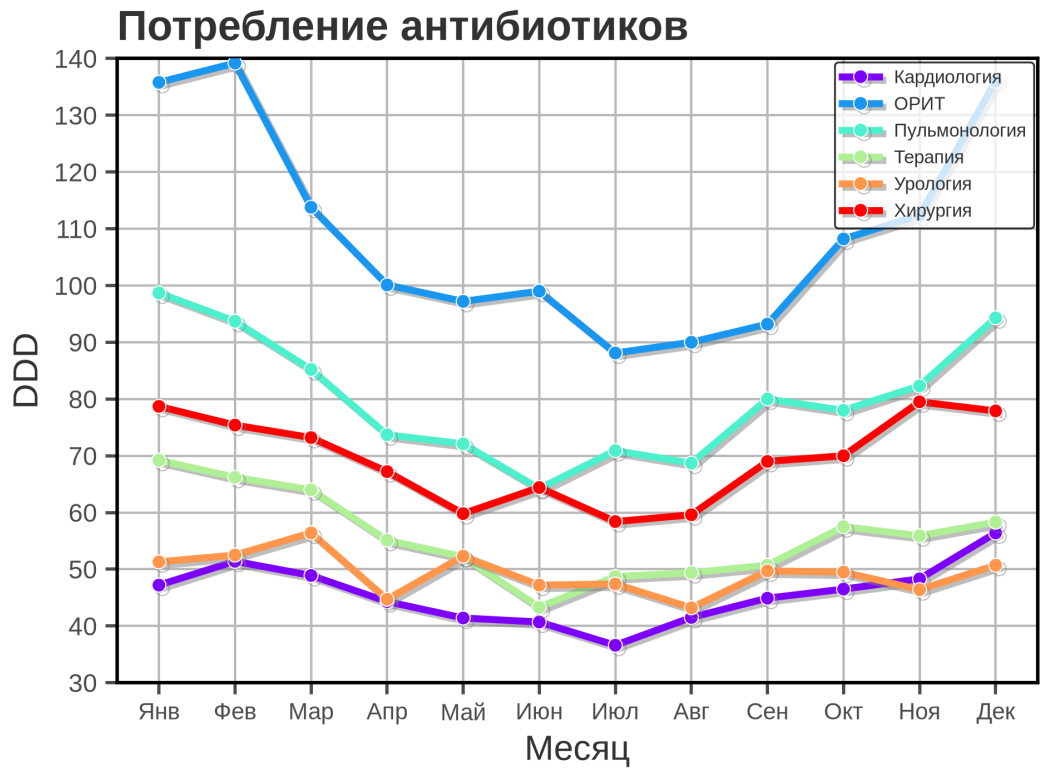


Рисунок 5.4.1. Плохой график: шесть отделений на одной оси, радужная палитра, обрезанная ось, тяжёлая сетка.

Код: `05_charts/04_small_multiples/scripts/bad_plot.py`.

Что с ним не так:

1. **Шесть серий на одной оси.** Линии перекрываются, особенно в области 45–80 DDD; сравнить отделения невозможно.
2. **Радужная палитра.** Шесть цветов неразличимы при дальтонизме, а легенда заставляет постоянно переводить взгляд.
3. **Обрезанная ось Y (30–140).** Низкие значения искажены; разница между кардиологией и урологией выглядит больше, чем есть.
4. **Толстые линии, тени и крупные маркеры.** Декор усиливает overplotting.
5. **Тяжёлая сетка по обеим осям и полная рамка.** Сетка конкурирует с шестью линиями.
6. **Заголовок «Потребление антибиотиков».** Не сообщает, что сравниваются отделения и кто лидирует.
7. **Нет единиц и n.** «DDD» — это что? Сколько отделений и месяцев?
8. **Легенда из шести строк** закрывает верхнюю часть данных.

5.04.4 Правильный график

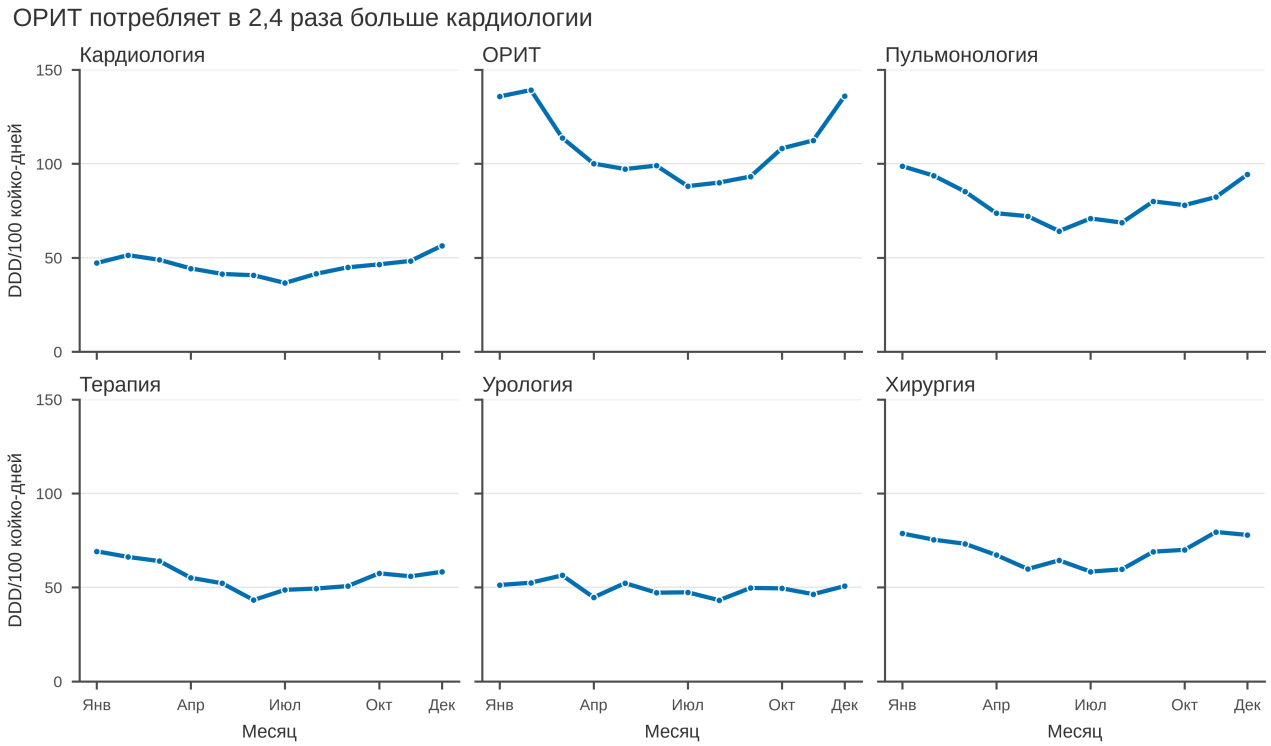


Рисунок 5.4.2. Правильные малые кратные: 2×3 панели, общая ось 0–150, один цвет, подписи отделений.

Код: `05_charts/04_small_multiples/scripts/good_plot.py`.

Что улучшено:

1. **2×3 панели.** Каждое отделение — своя панель; линии не перекрываются.
2. **Общая ось Y 0–150.** Панели честно сравнимы; видно, что ОРИТ выше всех, а кардиология ниже всех.
3. **Один цвет.** Сравнение идёт по форме и уровню, а не по легенде.
4. **Общие деления X.** Янв/Апр/Июл/Окт/Дек; подписи только на нижнем ряду, чтобы не дублировать.
5. **Подписи осей по краям.** «DDD/100 койко-дней» — только слева, «Месяц» — только снизу.
6. **Заголовок-вывод.** «ОРИТ потребляет в 2,4 раза больше кардиологии» сразу задаёт сообщение.
7. **Лёгкая сетка по Y, без верхней и правой рамок.**
8. **170 мм.** Две журнальные колонки; панели не сжаты в одну.

Порядок панелей — по алфавиту; если нужен содержательный порядок (например, по уровню потребления), задайте его явно и сохраняйте во всех рисунках.

5.04.5 Сопоставление

Что было	Почему плохо	Что сделано
6 линий на одной оси	overplotting	2×3 панели
радужная палитра	CVD, легенда	один синий цвет
ось Y 30–140	искажает низкие значения	0–150
толстые линии, тени	декор	линии 1,6 pt, маркеры 2,6 pt
сетка по X и Y	шум	сетка только по Y
полная рамка	визуальный шум	только левая и нижняя оси
легенда	закрывает данные	подписи панелей
«Потребление антибиотиков»	нет сообщения	заголовок-вывод
нет единиц и *n*	невозможно прочитать	единицы, 6 отделений × 12 месяцев
разные шкалы	нельзя сравнивать	общая шкала

5.04.6 Чек-лист small multiples

- ☐ Панели действительно сравнимы: общая шкала X и Y.
- ☐ Одна панель — одна серия; нет перекрытия.

- ☐ Порядок панелей осмысленный и одинаковый во всех рисунках.
- ☐ Подписи осей не дублируются на каждой панели.
- ☐ Один цвет, если нет смыслового повода для разных.
- ☐ Заголовки панелей короткие и однозначные.
- ☐ Есть общий заголовок-вывод.
- ☐ Указаны единицы и *n*.
- ☐ Панели не сжаты: минимум 45–50 мм на панель.
- ☐ Если серий 2–3, рассмотрена обычная линия.

5.04.7 Как воспроизвести

```
uv sync
uv run python 05_charts/04_small_multiples/scripts/make_data.py
uv run python 05_charts/04_small_multiples/scripts/bad_plot.py
uv run python 05_charts/04_small_multiples/scripts/good_plot.py
```

Ключевой фрагмент:

```
fig, axes = plt.subplots(
    2, 3,
    figsize=figure_size("double", height_mm=100),
    sharex=True,
    sharey=True,
    layout="constrained",
)
for ax, department in zip(axes.ravel(), departments, strict=True):
    ax.plot(x, pivot[department], color=PRIMARY_BLUE)
    ax.set_title(department, loc="left")
```

`sharex=True` и `sharey=True` — это и есть контракт сравнения. Если приходится делать `sharey=False`, подпишите разные шкалы явно и объясните, почему они разные.

5.04.8 Что дальше

Следующий график — **5.05 scatter**: связь двух непрерывных величин, выбросы и плотность. У него будет свой генератор и свой `data/05_dataset.csv`.

Источники

- Tufte E. R. *The Visual Display of Quantitative Information*. 1983. — edwardtufte.com
- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Cairo A. *The Truthful Art*. New Riders, 2016. — thefunctionalart.com
- Matplotlib: `subplots` — matplotlib.org

5.05 Scatter: связь двух непрерывных величин

Scatter plot — базовая форма для связи двух непрерывных переменных. Он показывает не только тренд, но и разброс, выбросы, гетерогенность и плотность наблюдений. Именно поэтому scatter честнее коэффициента корреляции: коэффициент сжимает всю картину в одно число.

Правило: **точки важнее линии.** Линия регрессии — дополнение к данным, а не замена им. Если на графике видны только линия и *r*, читатель не увидит ни формы, ни выбросов.

5.05.1 Сфера применения

Scatter отвечает на вопрос: **связаны ли две непрерывные величины и как выглядит эта связь?**

Типичные случаи:

- связь биомаркера и клинического показателя (BMI и глюкоза, CRP и тяжесть);
- корреляция двух методов измерения (но для согласия — Bland–Altman, 5.19);
- зависимость дозы и эффекта;
- поиск выбросов и гетерогенности;
- проверка линейности перед регрессией.

Когда scatter **не** подходит:

- одна из переменных категориальная — нужны точки/столбцы;
- время по X — нужна линия (5.01);
- точек слишком много — overplotting, нужны hexbin (5.06), contour (5.07) или плотность;
- нужно показать согласие методов, а не корреляцию — Bland–Altman (5.19);
- обе переменные — доли, сумма которых фиксирована (compositional data).

5.05.2 Данные

Сценарий: 180 взрослых на профилактическом осмотре. Измерены BMI (кг/м²) и глюкоза натощак (ммоль/л).

Колонка	Смысл	Единица
`patient_id`	идентификатор пациента	—
`bmi_kg_m2`	индекс массы тела	кг/м²
`glucose_mmol_l`	глюкоза натощак	ммоль/л

Средний BMI — 27,5 ± 4,1 кг/м²; глюкоза — 5,7 ± 1,0 ммоль/л; корреляция Пирсона $r = 0{,}52$ ($p < 0{,}001$). Связь положительная, но не жёсткая: вокруг линии большой разброс.

Генератор: `05_charts/05_scatter/scripts/make_data.py` → `data/05_dataset.csv`.

5.05.3 Плохой график

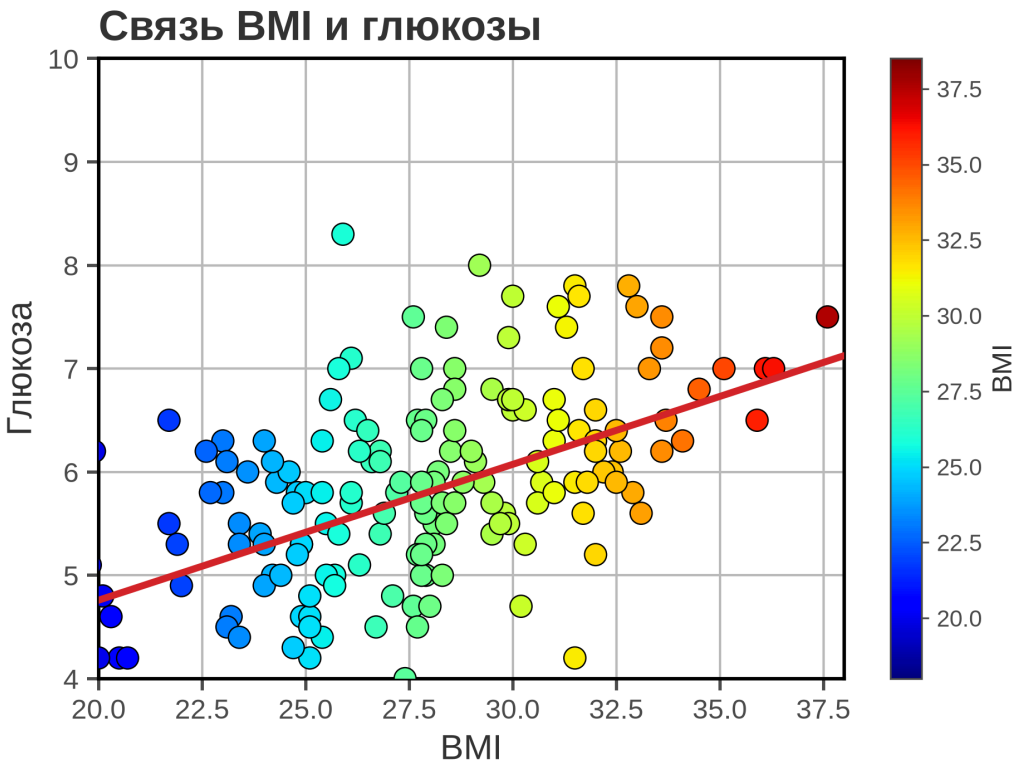


Рисунок 5.5.1. Плохой scatter: обрезанные оси, точки окрашены по BMI, крупные маркеры, линия без статистики.

Код: `05_charts/05_scatter/scripts/bad_plot.py`.

Что с ним не так:

1. **Обрезанные оси (20–38 и 4–10).** Часть точек и хвосты скрыты; форма связи и выбросы искажены.
2. **Цвет точек по BMI.** BMI уже на оси X; цвет дублирует ось и добавляет радужную шкалу, которая не несёт новой информации.
3. **Крупные непрозрачные маркеры с чёрной обводкой.** Overplotting: в плотных областях точки сливаются, нельзя оценить плотность.
4. **Красная линия регрессии без доверительной полосы и статистики.** Не указаны *r*, *n*, наклон; линия выглядит как «истина».
5. **Тяжёлая сетка по обеим осям и полная рамка.** Шум, который конкурирует с точками.
6. **Заголовок «Связь BMI и глюкозы».** Не сообщает направление и силу связи.
7. **Нет единиц и *n*.** «BMI» и «Глюкоза» — в чём? Сколько людей?
8. **Цветовая шкала BMI** дублирует ось X и занимает место.

5.05.4 Правильный график

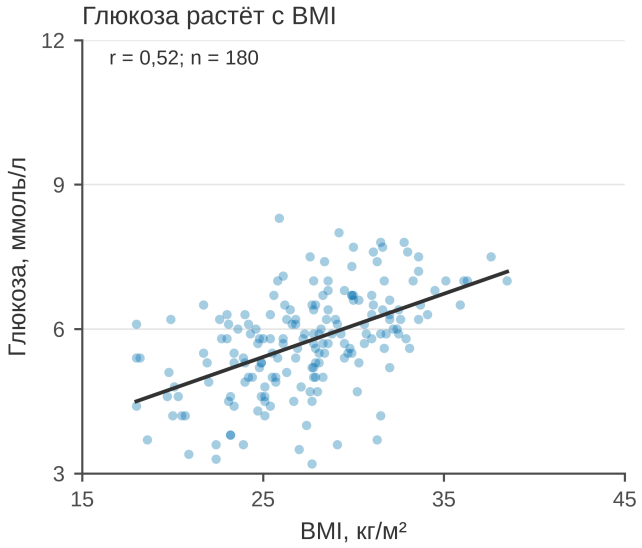


Рисунок 5.5.2. Правильный scatter: полный диапазон, полупрозрачные точки, линия регрессии, r и n.

Код: `05_charts/05_scatter/scripts/good_plot.py`.

Что улучшено:

1. **Полный диапазон осей.** 15–45 кг/м² и 3–12 ммоль/л; все точки видны, включая хвосты.
2. **Полупрозрачные точки одного цвета.** `alpha=0.35`, размер 12: видна плотность и не теряются отдельные наблюдения.
3. **Линия регрессии только в диапазоне данных.** Без экстраполяции за пределы наблюдений.
4. **Подпись *r* = 0,52; *n* = 180.** Связь quantified; читатель видит и форму, и число.
5. **Единицы на осях.** «BMI, кг/м²», «Глюкоза, ммоль/л».
6. **Заголовок-вывод.** «Глюкоза растёт с BMI» задаёт направление.
7. **Лёгкая сетка только по Y, без верхней и правой рамок.**
8. **85 мм.** Рисунок спроектирован в конечном размере.

Корреляция не равна причинности: BMI и глюкоза могут быть связаны через возраст, питание, физическую активность. Scatter показывает ассоциацию, а не механизм.

5.05.5 Сопоставление

Что было	Почему плохо	Что сделано
оси 20–38 / 4–10	точки и хвосты обрезаны	15–45 / 3–12
цвет по BMI	двойное кодирование, радуга	один синий цвет
крупные непрозрачные точки	overplotting	s=12, alpha=0,35
линия без статистики	не quantifies связь	r, n, линия в диапазоне
сетка по X и Y	шум	сетка только по Y
полная рамка	визуальный шум	только левая и нижняя оси
«Связь BMI и глюкозы»	нет сообщения	заголовок-вывод
нет единиц и *n*	невозможно прочитать	единицы, *n*
colorbar BMI	дублирует ось	без colorbar

5.05.6 Чек-лист scatter

- ☐ Обе переменные непрерывные.
- ☐ Оси не обрезают данные без объяснения.
- ☐ Есть *n* и единицы.
- ☐ Точки не сливаются: alpha/размер/hexbin.
- ☐ Линия регрессии не выходит за диапазон данных.
- ☐ Указаны *r* (или наклон) и неопределённость.
- ☐ Цвет не дублирует ось без смысла.
- ☐ Выбросы видны, а не скрыты.

- ☐ Корреляция не подана как причинность.
- ☐ Рисунок проверен в конечном размере 85 мм.

5.05.7 Как воспроизвести

```
uv sync
uv run python 05_charts/05_scatter/scripts/make_data.py
uv run python 05_charts/05_scatter/scripts/bad_plot.py
uv run python 05_charts/05_scatter/scripts/good_plot.py
```

Ключевой фрагмент:

```
ax.scatter(x, y, s=12, color=PRIMARY_BLUE, alpha=0.35, linewidths=0)
slope, intercept, r_value, p_value, _ = stats.linregress(x, y)
line_x = np.array([x.min(), x.max()])
ax.plot(line_x, intercept + slope * line_x, color="#333333", linewidth=1.4)
```

Если точек станет больше нескольких тысяч, scatter превратится в сплошное пятно; тогда нужны hexbin или contour.

5.05.8 Что дальше

Следующий график — **5.06 hexbin**: плотность тысяч точек без overplotting. У него будет свой генератор и свой `data/06_dataset.csv`.

Источники

- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Cleveland W. S., McGill R. Graphical Perception // *JASA*. 1984. — doi:10.1080/01621459.1984.10478080
- Tufte E. R. *The Visual Display of Quantitative Information*. 1983. — edwardtufte.com
- Matplotlib: `scatter` — matplotlib.org

5.06 Hexbin: плотность тысяч точек

Hexbin — это scatter, у которого точки агрегированы в шестиугольные бины, а цвет показывает число наблюдений в бине. Он нужен там, где обычный scatter превращается в сплошное пятно: тысячи точек, плотное ядро, длинные хвосты.

Важно помнить: hexbin показывает **плотность**, а не отдельного пациента. Цвет — это число наблюдений в бине, а не значение признака.

5.06.1 Сфера применения

Hexbin отвечает на вопрос: **где наблюдений много, а где мало, и какова форма облака при больших n?**

Типичные случаи:

- 5 000–1 000 000 точек в scatter;
- плотность биомедицинских показателей (HbA1c и глюкоза, BMI и АД);
- кластеры и гетерогенность в больших когортах;
- проверка формы распределения перед регрессией;
- визуализация больших выгрузок без потери плотности.

Когда hexbin **не** нужен:

- точек мало (до нескольких сотен) — scatter честнее;
- нужно прочитать отдельное наблюдение;
- одна из переменных категориальная;
- важна точная форма хвоста, а бинование её огрубляет;
- нужна связь, а не плотность — scatter или contour.

5.06.2 Данные

Сценарий: 8 000 пациентов, HbA1c (%) и глюкоза натощак (ммоль/л). Связь сильная, но с разбросом; при 8 000 точек обычный scatter превращается в пятно.

Колонка	Смысл	Единица
`patient_id`	идентификатор пациента	—
`hba1c_pct`	гликированный гемоглобин	%
`glucose_mmol_l`	глюкоза натощак	ммоль/л

Средний HbA1c — 6,3 ± 0,9 %; глюкоза — 7,5 ± 1,8 ммоль/л; корреляция Пирсона r = 0,83.

Генератор: `05_charts/06_hexbin/scripts/make_data.py → data/06_dataset.csv`.

5.06.3 Плохой график

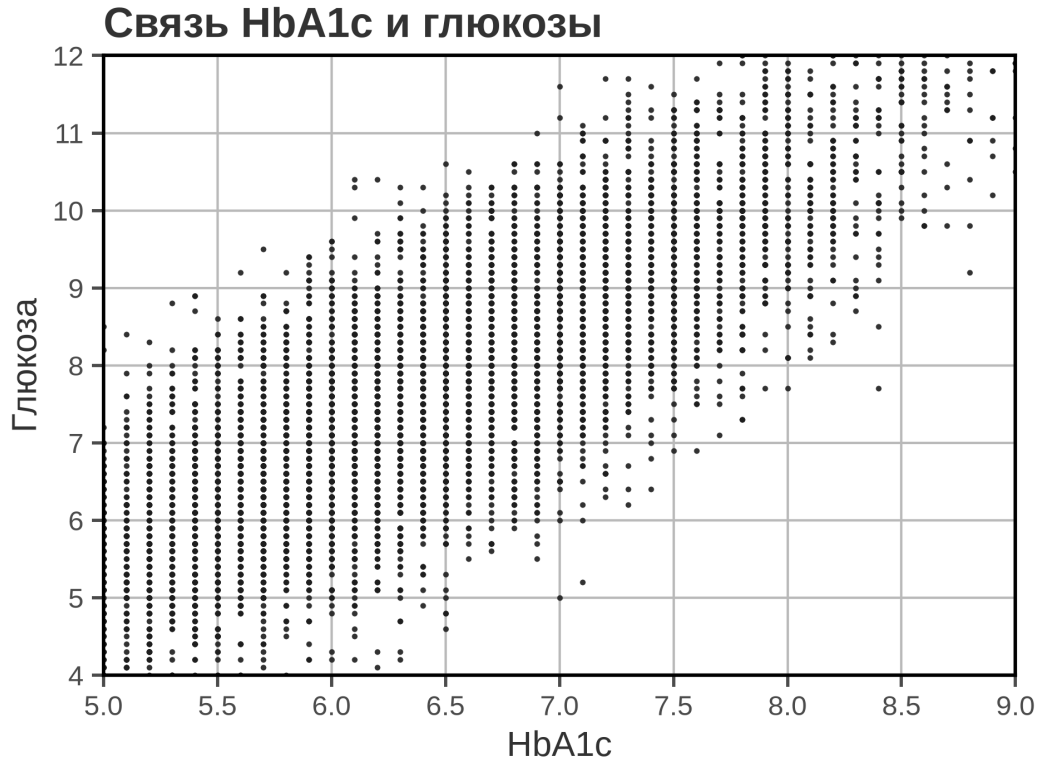


Рисунок 5.6.1. Плохой пример: 8 000 непрозрачных точек, overplotting, обрезанные оси, тяжёлая сетка.

Код: `05_charts/06_hexbin/scripts/bad_plot.py`.

Что с ним не так:

1. **8 000 непрозрачных точек.** Вместо плотности — чёрное пятно; в центре точки сливаются, хвосты теряются.
2. **Обрезанные оси (5–9 и 4–12).** Часть наблюдений и хвосты распределения скрыты.
3. **Тяжёлая сетка по обеим осям и полная рамка.** Сетка конкурирует с плотным облаком.
4. **Заголовок «Связь HbA1c и глюкозы».** Не сообщает, что важно именно распределение плотности.
5. **Нет единиц, n и r.** Непонятно, сколько наблюдений и какова сила связи.
6. **Чёрный цвет не кодирует плотность.** Читатель не видит, где наблюдений больше.

5.06.4 Правильный график

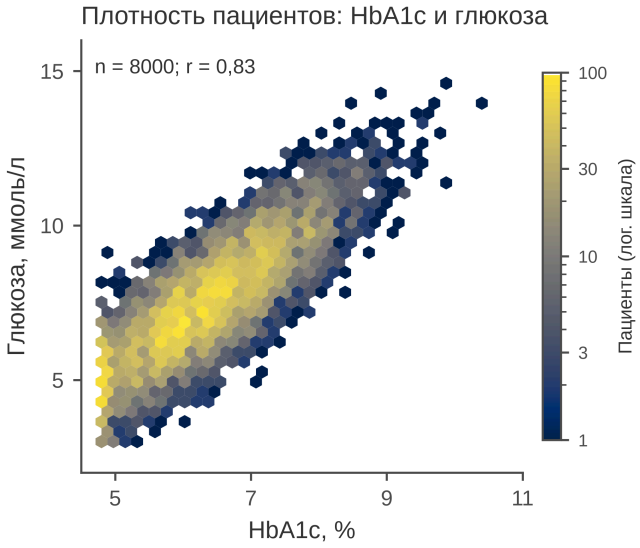


Рисунок 5.6.2. Правильный hexbin: плотность в логарифмической шкале, colorbar 1–100, полный диапазон, n и r.

Код: `05_charts/06_hexbin/scripts/good_plot.py`.

Что улучшено:

1. **Hexbin вместо scatter.** Цвет кодирует число пациентов в шестиугольнике; плотность видна.
2. **Логарифмическая шкала плотности.** Видны и плотное ядро, и разреженные хвосты; линейная шкала «съела» бы хвосты.
3. **`mincnt=1`.** Пустые бины остаются белыми, а не окрашиваются в цвет «нуля».
4. **Полный диапазон осей.** 4,5–11 % и 2–16 ммоль/л; данные не обрезаны.
5. **Подписанный colorbar.** «Пациенты (лог. шкала)», деления 1/3/10/30/100 — цвет читается как число.
6. **Единицы, n и r.** «HbA1c, %», «Глюкоза, ммоль/л», n = 8000, r = 0,83.
7. **`cividis`.** Последовательная шкала, читаемая при дальтонизме.
8. **85 мм.** Рисунок спроектирован в конечном размере.

Hexbin не заменяет scatter для отдельных наблюдений: он показывает плотность. Если нужен конкретный пациент или выброс, hexbin его не подпишет.

5.06.5 Сопоставление

Что было	Почему плохо	Что сделано
8 000 точек scatter	overplotting	hexbin
оси 5–9 / 4–12	хвосты обрезаны	4,5–11 / 2–16
чёрный цвет	не кодирует плотность	цвет = число пациентов
линейная шкала	хвосты не видны	лог. шкала
пустые бины окрашены	ложные «нули»	`mincnt=1`
сетка по X и Y	шум	без сетки
полная рамка	визуальный шум	только левая и нижняя оси
«Связь HbA1c и глюкозы»	нет сообщения	заголовок о плотности
нет единиц и n	невозможно прочитать	единицы, n, r
нет colorbar	цвет не читается	colorbar с делениями

5.06.6 Чек-лист hexbin

- ☐ Точек действительно много; scatter уже не читается.
- ☐ Понятно, что цвет кодирует число наблюдений, а не значение.
- ☐ Указаны единицы и n.
- ☐ Оси не обрезают данные.
- ☐ `mincnt=1`, чтобы пустые бины не выглядели «нулём».
- ☐ Шкала плотности (линейная/логарифмическая) подписана.
- ☐ Colorbar с делениями и единицами.
- ☐ `gridsize` не слишком крупный и не слишком мелкий.
- ☐ Для точных значений используется scatter/contour.
- ☐ Рисунок проверен в конечном размере 85 мм.

5.06.7 Как воспроизвести

```
uv sync
uv run python 05_charts/06_hexbin/scripts/make_data.py
uv run python 05_charts/06_hexbin/scripts/bad_plot.py
uv run python 05_charts/06_hexbin/scripts/good_plot.py
```

Ключевой фрагмент:

```
hexbin = ax.hexbin(
    x, y,
    gridsize=32,
    cmap="cividis",
    mincnt=1,
    bins="log",
    linewidths=0,
)
cbar = fig.colorbar(hexbin, ax=ax, fraction=0.05, pad=0.02, shrink=0.85)
cbar.set_label("Пациенты (лог. шкала)")
```

`bins="log"` включает логарифмическую нормализацию цвета; `mincnt=1` оставляет пустые бины белыми. Если нужно среднее значение в бине, используйте `reduce_C_function=np.mean` и подпишите, что кодирует цвет.

5.06.8 Что дальше

Следующий график — **5.07 contour**: изолинии плотности или поверхности отклика. У него будет свой генератор и свой `data/07_dataset.csv`.

Источники

- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Matplotlib: `hexbin` — matplotlib.org
- Tufte E. R. *The Visual Display of Quantitative Information*. 1983. — edwardtufte.com
- Cairo A. *The Truthful Art*. New Riders, 2016. — thefunctionalart.com

5.07 Contour: изолинии плотности

Contour plot рисует линии равного значения: плотности, вероятности, поверхности отклика. В отличие от hexbin, контурная карта выглядит гладкой и показывает форму облака, но именно поэтому она может «придумать» структуру, которой нет в данных.

Правило: **сначала плотность, потом линии.** Контурные линии — это изолинии оценки плотности; без colorbar и подписи уровней они ничего не значат.

5.07.1 Сфера применения

Contour отвечает на вопрос: **где плотность (или значение поверхности) одинакова и какова форма двумерного распределения?**

Типичные случаи:

- 2D-плотность больших выборок (возраст и САД, BMI и глюкоза);
- поверхность отклика (доза × время → эффект);
- доверительные области и эллипсы;
- топография/визуализация пространственных полей;
- сглаженная альтернатива hexbin.

Когда contour **не** нужен:

- точек мало — контурная оценка неустойчива;
- нужно прочитать отдельное наблюдение;
- важна локальная структура, а не гладкая форма — hexbin/scatter;
- уровни выбраны произвольно и не подписаны;
- сглаживание скрывает реальные разрывы.

5.07.2 Данные

Сценарий: 10 000 взрослых, возраст (лет) и систолическое АД (мм рт. ст.). САД растёт с возрастом, разброс тоже растёт.

Колонка	Смысл	Единица
`patient_id`	идентификатор пациента	—
`age_years`	возраст	лет
`sbp_mm_hg`	систолическое АД	мм рт. ст.

Средний возраст — 51,8 ± 14,7 лет; САД — 125,0 ± 17,3 мм рт. ст.; корреляция r = 0,49. Порог 140 мм рт. ст. отмечен на графике.

Генератор: `05_charts/07_contour/scripts/make_data.py` → `data/07_dataset.csv`.

5.07.3 Плохой график

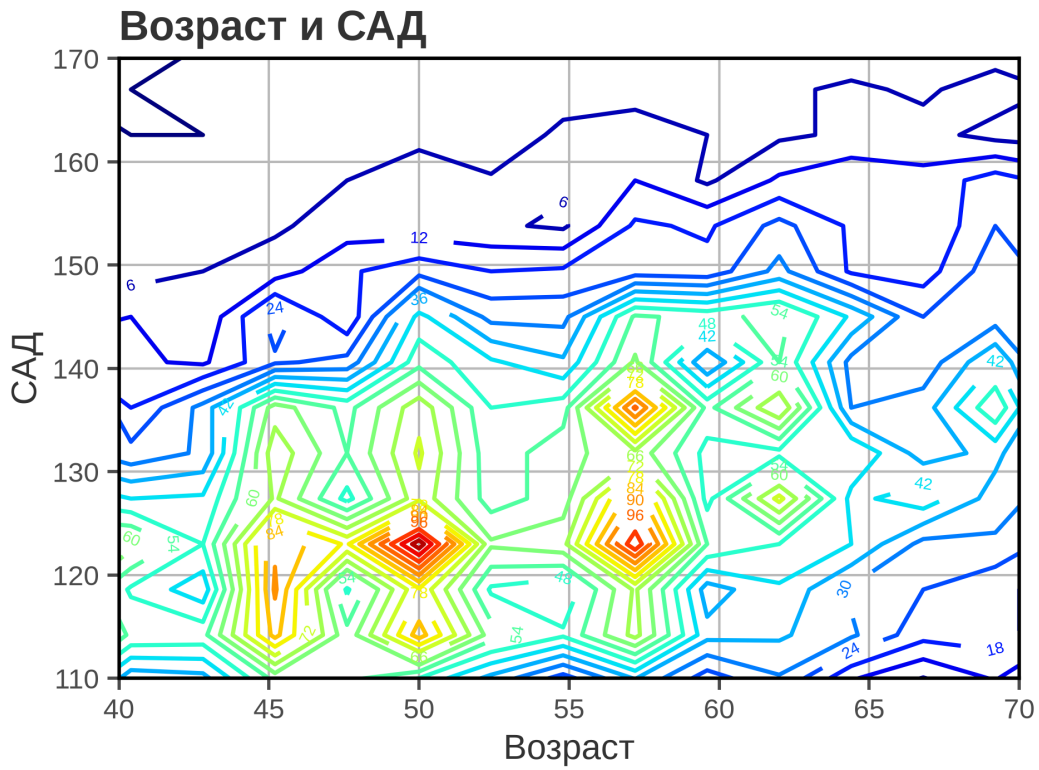


Рисунок 5.7.1. Плохой contour: радужная палитра, 20 уровней, налезающие подписи, обрезанные оси.

Код: `05_charts/07_contour/scripts/bad_plot.py`.

Что с ним не так:

1. **Палитра `jet` и 20 уровней.** Ложные границы, «радуга», неразличимая при дальтонизме.
2. **Подписи уровней налезают друг на друга.** Читать карту невозможно.
3. **Обрезанные оси (40–70 и 110–170).** Хвосты распределения скрыты.
4. **Тяжёлая сетка по обеим осям и полная рамка.** Шум поверх и без того шумной карты.
5. **Заголовок «Возраст и САД».** Не сообщает, что показана плотность и где порог.
6. **Нет единиц, *n*, colorbar и порога 140.** Цвет и уровни не читаются.
7. **Слишком мелкие бины.** Карта выглядит «рябой»: шум гистограммы принимается за структуру.

5.07.4 Правильный график

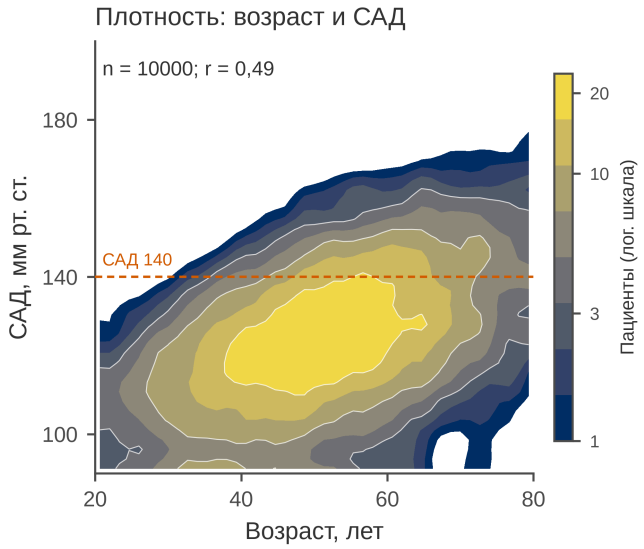


Рисунок 5.7.2. Правильный contour: сглаженная плотность, cividis, colorbar 1–20, порог 140, n и r.

Код: `05_charts/07_contour/scripts/good_plot.py`.

Что улучшено:

1. **Сглаженная 2D-плотность.** `gaussian_filter` убирает шум бинов, не стирая облако; структура читается.
2. **`cividis` и 9 уровней.** Последовательная доступная шкала, без ложных границ.
3. **Полный диапазон осей.** 20–80 лет и 90–200 мм рт. ст.
4. **Подписанный colorbar.** «Пациенты (лог. шкала)», деления 1/3/10/20.
5. **Порог 140 мм рт. ст.** Выделен пунктиром и подписью.
6. **Единицы, *n* и *r*.** «Возраст, лет», «САД, мм рт. ст.», $n = 10000$, $r = 0{,}49$.
7. **Без тяжёлой сетки.** Контурные линии — единственная вспомогательная графика.
8. **85 мм.** Рисунок спроектирован в конечном размере.

Контурная карта — это **оценка** плотности. Сглаживание и число уровней — параметры модели, а не «истина». Если структура важна, сравните contour с hexbin или scatter.

5.07.5 Сопоставление

Что было	Почему плохо	Что сделано
`jet`, 20 уровней	ложные границы, CVD	`cividis`, 9 уровней
подписи всех уровней	налезают	без подписей, colorbar
оси 40–70 / 110–170	хвосты обрезаны	20–80 / 90–200
мелкие бины	шум как структура	сглаживание
сетка по X и Y	шум	без сетки
полная рамка	визуальный шум	только левая и нижняя оси
«Возраст и САД»	нет сообщения	заголовок о плотности
нет единиц и *n*	невозможно прочитать	единицы, *n*, *r*
нет colorbar	цвет не читается	colorbar 1–20
нет порога 140	клинический контекст потерян	пунктир 140

5.07.6 Чек-лист contour

- ☐ Понятно, что такое «уровень» и что кодирует цвет.
- ☐ Указаны единицы и *n*.
- ☐ Оси не обрезают данные.
- ☐ Уровни подписаны или есть colorbar.
- ☐ Палитра последовательная, не `jet`.
- ☐ Сглаживание не уничтожает реальную структуру.
- ☐ Подписи уровней не налезают.
- ☐ Есть клинический/смысловой порог, если он важен.
- ☐ Для локальной структуры рассмотрен hexbin.
- ☐ Рисунок проверен в конечном размере 85 мм.

5.07.7 Как воспроизвести

```
uv sync
uv run python 05_charts/07_contour/scripts/make_data.py
uv run python 05_charts/07_contour/scripts/bad_plot.py
uv run python 05_charts/07_contour/scripts/good_plot.py
```

Ключевой фрагмент:

```
hist, xedges, yedges = np.histogram2d(
    age, sbp, bins=(45, 45), range=[[20, 80], [90, 200]]
)
smooth = gaussian_filter(hist, sigma=1.2)
levels = np.logspace(0, np.log10(smooth.max()), 9)
ax.contourf(xx, yy, smooth.T, levels=levels, cmap="cividis")
```

`sigma` и число уровней — параметры сглаживания. Меняйте их осознанно и проверяйте, что вывод не зависит от выбранного сглаживания.

5.07.8 Что дальше

Следующий график — **5.08 loess**: нелинейный тренд на scatter с доверительной полосой. У него будет свой генератор и свой `data/08_dataset.csv`.

Источники

- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Matplotlib: `contourf` — matplotlib.org
- SciPy: `gaussian_filter` — docs.scipy.org
- Tufte E. R. *The Visual Display of Quantitative Information*. 1983. — edwardtufte.com

5.08 LOESS: нелинейный тренд

LOESS (locally estimated scatterplot smoothing) — локальная регрессия: для каждой точки строится свой полином по соседям. Он не предполагает глобальной формы связи и поэтому хорошо показывает насыщение, пороги и изгибы, которые линейная прямая пропускает.

Но LOESS — это **описание тренда**, а не модель причинности. Он зависит от ширины окна (`frac`), плохо ведёт себя на краях и не годится для экстраполяции.

5.08.1 Сфера применения

LOESS отвечает на вопрос: **как выглядит нелинейный тренд, если не навязывать ему форму?**

Типичные случаи:

- доза–эффект с насыщением (статин и ЛПНП, препарат и АД);
- проверка линейности перед регрессией;
- нелинейные биомаркерные ассоциации;
- сглаживание временных рядов (но для времени чаще line/step);
- визуальная проверка порогов и плато.

Когда LOESS **не** нужен:

- точек мало (десятки) — сглаживание неустойчиво;
- нужна предсказательная модель или экстраполяция;
- важна причинная интерпретация;
- данные имеют резкие разрывы, которые нельзя сглаживать;
- `frac` выбран так, что исчезает реальная структура.

5.08.2 Данные

Сценарий: 300 пациентов, фиксированные дозы статина 0, 5, 10, 20, 40 и 80 мг/сут. Эффект — снижение ЛПНП (%), насыщается с ростом дозы.

Колонка	Смысл	Единица
`patient_id`	идентификатор пациента	—
`dose_mg`	доза статина	мг/сут
`ldl_reduction_pct`	снижение ЛПНП	%

Средние по дозам: 0 мг — 1,7 %, 5 мг — 17,6 %, 10 мг — 26,4 %, 20 мг — 34,5 %, 40 мг — 41,8 %, 80 мг — 47,7 %. Рост замедляется: это и есть насыщение.

Генератор: `05_charts/08_loess/scripts/make_data.py` → `data/08_dataset.csv`.

5.08.3 Плохой график

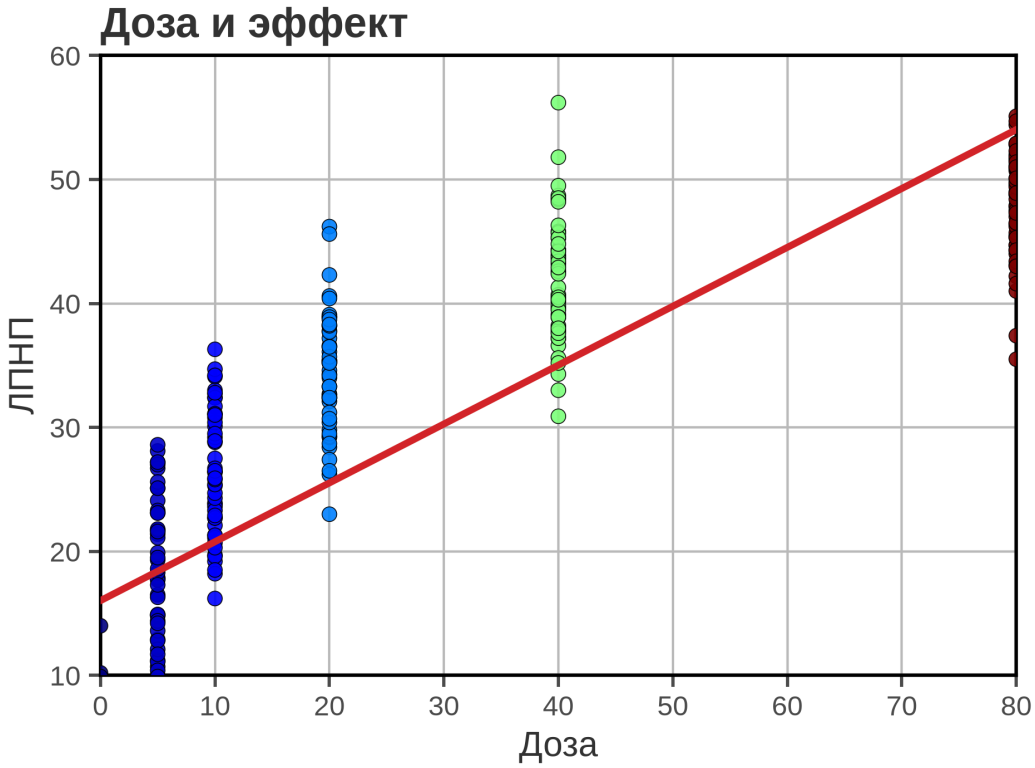


Рисунок 5.8.1. Плохой пример: линейная прямая на данных с насыщением, точки окрашены по дозе, обрезанная ось.

Код: `05_charts/08_loess/scripts/bad_plot.py`.

Что с ним не так:

1. **Линейная регрессия на нелинейных данных.** Прямая не описывает плато: на 80 мг она завышает эффект, на 10–20 мг — занижает.
2. **Цвет точек по дозе.** Доза уже на оси X; цвет дублирует ось и добавляет радужную шкалу.
3. **Обрезанная ось Y (10–60).** Низкие дозы и хвост скрыты.
4. **Крупные непрозрачные точки, тяжёлая сетка, полная рамка.**
5. **Заголовок «Доза и эффект».** Не сообщает, что эффект насыщается.
6. **Нет единиц, n, доверительной полосы и описания модели.**

5.08.4 Правильный график

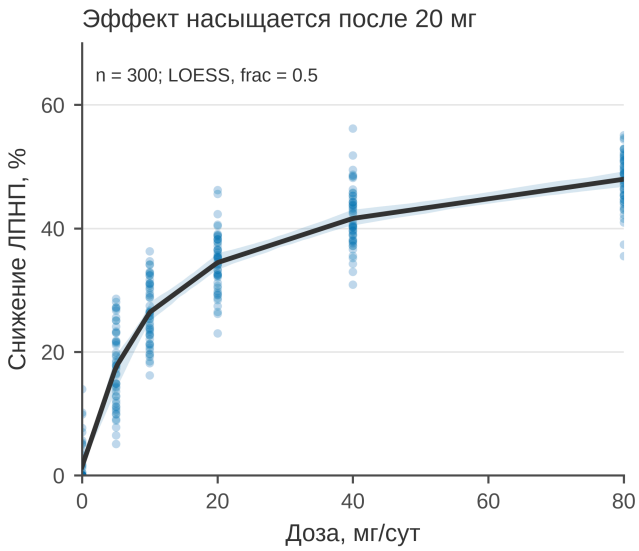


Рисунок 5.8.2. Правильный LOESS: точки, локальная кривая, bootstrap-полоса 95 %, полный диапазон.

Код: `05_charts/08_loess/scripts/good_plot.py`.

Что улучшено:

1. **LOESS вместо прямой.** Видно быстрое снижение ЛПНП до 20 мг и выполаживание после.
2. **Bootstrap-полоса 95 %.** Показана неопределённость кривой; на краях она шире.
3. **Полный диапазон осей.** 0–80 мг и 0–70 %.
4. **Полупрозрачные точки одного цвета.** Видна плотность, нет двойного кодирования.
5. **Единицы, n и `frac`.** «Доза, мг/сут», «Снижение ЛПНП, %», *n* = 300, `frac = 0.5`.
6. **Заголовок-вывод.** «Эффект насыщается после 20 мг» задаёт сообщение.
7. **Лёгкая сетка только по Y, без верхней и правой рамок.**
8. **85 мм.** Рисунок спроектирован в конечном размере.

`frac` — доля наблюдений в локальном окне. Маленький `frac` даёт извилистую кривую, большой — слишком гладкую. Показывайте выбранное значение и проверяйте устойчивость.

5.08.5 Сопоставление

Что было	Почему плохо	Что сделано
линейная прямая	не описывает плато	LOESS
цвет по дозе	двойное кодирование	один цвет
ось Y 10–60	низкие дозы обрезаны	0–70
крупные точки	шум	s=10, alpha=0,25
нет CI	не видна неопределённость	bootstrap 95 %
сетка по X и Y	шум	сетка только по Y
полная рамка	визуальный шум	только левая и нижняя оси
«Доза и эффект»	нет сообщения	заголовок-вывод
нет единиц и n	невозможно прочитать	единицы, n, frac

5.08.6 Чек-лист LOESS

- ☐ Понятно, что кривая — описание тренда, а не модель причинности.
- ☐ Указан `frac` (или span) и число точек.
- ☐ Показана неопределённость (bootstrap/CI).
- ☐ Оси не обрезают данные.
- ☐ Нет экстраполяции за пределы данных.
- ☐ Краевые эффекты не интерпретируются как реальные.
- ☐ Точки видны, а не закрыты линией.
- ☐ Есть единицы и *n*.
- ☐ Сравнение с линейной моделью/Spline/GAM осознано.
- ☐ Рисунок проверен в конечном размере 85 мм.

5.08.7 Как воспроизвести

```
uv sync
uv run python 05_charts/08_loess/scripts/make_data.py
uv run python 05_charts/08_loess/scripts/bad_plot.py
uv run python 05_charts/08_loess/scripts/good_plot.py
```

Ключевой фрагмент:

```
from statsmodels.nonparametric.smoothers_lowess import lowess

fit = lowess(y, x, frac=0.5, return_sorted=True)
grid = np.linspace(0, 80, 200)
mean_line = np.interp(grid, fit[:, 0], fit[:, 1])

# bootstrap-полоса
boots = []
for _ in range(200):
    idx = rng.integers(0, len(x), len(x))
    boot = lowess(y[idx], x[idx], frac=0.5, return_sorted=True)
    boots.append(np.interp(grid, boot[:, 0], boot[:, 1]))
low, high = np.percentile(boots, [2.5, 97.5], axis=0)
```

Bootstrap здесь оценивает неопределённость **кривой**, а не отдельных пациентов. Для формального вывода о дозе–эффекте нужна параметрическая модель (Emax, spline, GAM) и клиническое обоснование.

5.08.8 Что дальше

Следующий график — **5.09 histogram**: распределение одной непрерывной величины. У него будет свой генератор и свой `data/09_dataset.csv`.

Источники

- Cleveland W. S. Robust Locally Weighted Regression and Smoothing Scatterplots // *JASA*. 1979. — doi:10.1080/01621459.1979.10482531
- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Statsmodels: LOWESS — statsmodels.org
- Tufte E. R. *The Visual Display of Quantitative Information*. 1983. — edwardtufte.com

5.09 Гистограмма: распределение одной величины

Гистограмма показывает, как распределена одна непрерывная величина: центр, разброс, форму, скошенность и выбросы. Она отвечает на вопрос «как устроена выборка», а не «как связаны две переменные».

Главная ловушка — **выбор ширины бина**. Слишком широкие бины скрывают форму, слишком узкие — превращают шум в «структуру». Гистограмма — это семейство изображений, а не одно «истинное».

5.09.1 Сфера применения

Гистограмма отвечает на вопрос: **как распределена величина и где её центр, разброс, хвосты?**

Типичные случаи:

- распределение биомаркера (витамин D, CRP, глюкоза);
- проверка нормальности/скошенности перед тестом;
- поиск выбросов и многомодальности;
- описание выборки до сравнения групп;
- контроль качества измерений.

Когда гистограмма **не** подходит:

- наблюдений мало (десятки) — лучше точки/strip;
- нужно точное значение или квантиль — ECDF (5.10);
- несколько групп — box/violin/small multiples;
- важна форма хвоста, а бины её огрубляют;
- ось X обрезана и хвост скрыт.

5.09.2 Данные

Сценарий: 1 200 взрослых, уровень 25(OH)D (нг/мл). Распределение сдвинуто влево и имеет правый хвост.

Колонка	Смысл	Единица
`patient_id`	идентификатор пациента	—
`vitamin_d_ng_ml`	25(OH)D	нг/мл

Медиана — 23,4 нг/мл; IQR — 16,5–32,5; дефицит (< 20 нг/мл) — у 38 %; диапазон 3–70 нг/мл.

Генератор: `05_charts/09_histogram/scripts/make_data.py → data/09_dataset.csv`.

5.09.3 Плохой график

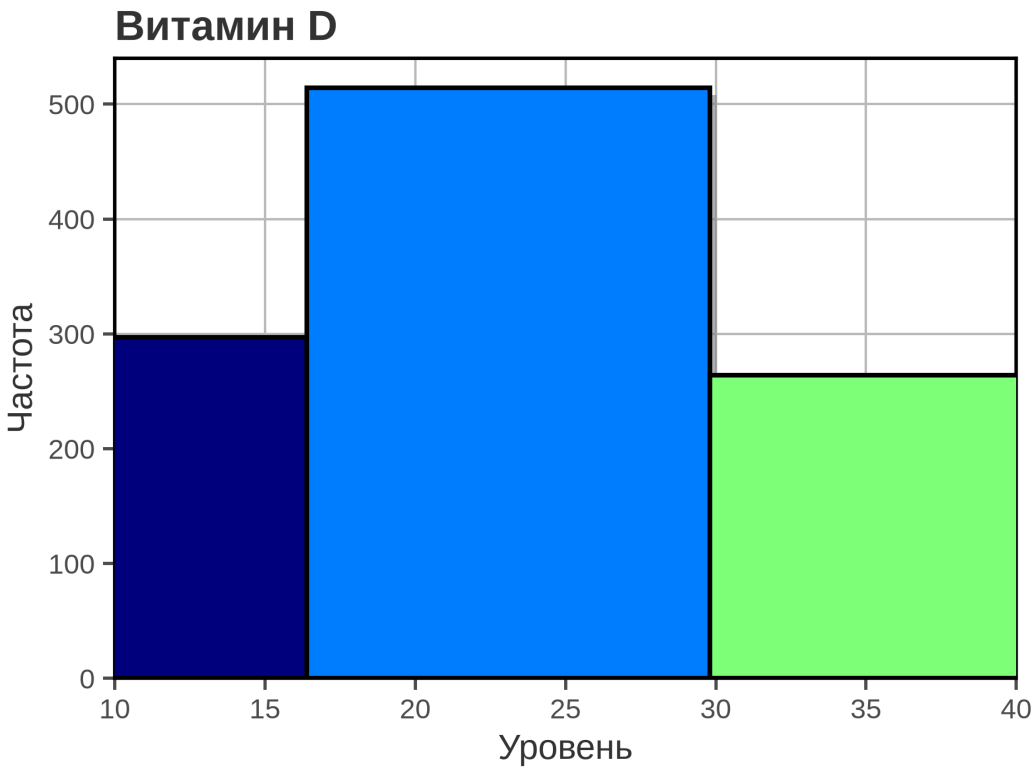


Рисунок 5.9.1. Плохая гистограмма: пять бинов, обрезанная ось 10–40, радужные столбцы, тени, нет единиц и порога.

Код: `05_charts/09_histogram/scripts/bad_plot.py`.

Что с ним не так:

1. **Пять бинов.** Форма распределения и правый хвост исчезли; осталось три столбца.
2. **Обрезанная ось X (10–40).** Низкие и высокие значения не видны.
3. **Радужные столбцы, чёрные края и тени.** Декор, который не кодирует данные.
4. **Тяжёлая сетка по обеим осям и полная рамка.**
5. **Заголовок «Витамин D».** Не сообщает, что важно: дефицит, медиана, форма.
6. **Нет единиц, n, медианы и порога 20.** Гистограмма не читается как клинический результат.

5.09.4 Правильный график

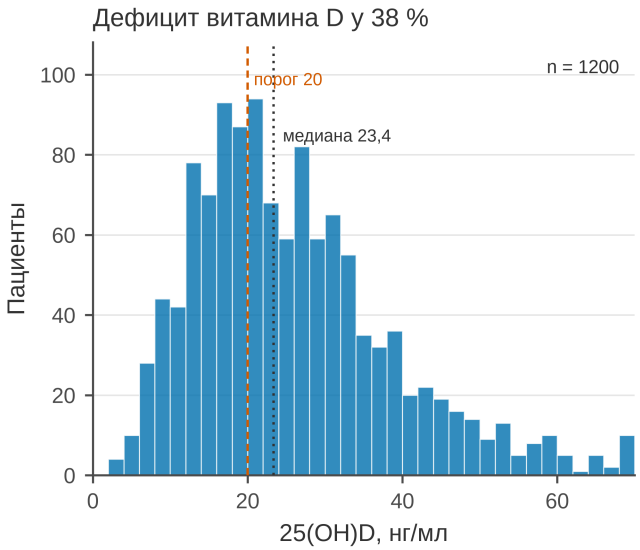


Рисунок 5.9.2. Правильная гистограмма: бины по 2 нг/мл, полный диапазон, порог 20, медиана, n и доля дефицита.

Код: `05_charts/09_histogram/scripts/good_plot.py`.

Что улучшено:

1. **Ширина бина 2 нг/мл.** Видна форма, правый хвост и мода около 18–24 нг/мл.
2. **Полный диапазон 0–70 нг/мл.** Ничего не обрезано.
3. **Один цвет, белые края, без теней.**
4. **Порог дефицита 20 нг/мл** выделен пунктиром.
5. **Медиана 23,4 нг/мл** отмечена и подписана.
6. **n = 1200 и доля дефицита 38 %** в заголовке.
7. **Единицы, лёгкая сетка только по Y, без верхней и правой рамок.**
8. **85 мм.** Рисунок спроектирован в конечном размере.

Проверьте устойчивость: постройте гистограмму с шириной 1, 2 и 5 нг/мл. Если вывод меняется, он не должен держаться на одном выборе бинов.

5.09.5 Сопоставление

Что было	Почему плохо	Что сделано
5 бинов	форма и хвост скрыты	бины по 2 нг/мл
ось X 10–40	хвосты обрезаны	0–70
радуга, тени	декор	один цвет
сетка по X и Y	шум	сетка только по Y
полная рамка	визуальный шум	только левая и нижняя оси
«Витамин D»	нет сообщения	заголовок о дефиците
нет единиц и n	невозможно прочитать	единицы, n
нет порога и медианы	клинический контекст потерян	порог 20, медиана
counts без подписи	непонятно, что такое Y	«Пациенты»

5.09.6 Чек-лист гистограммы

- ☐ Указана единица измерения.
- ☐ Ось X не обрезает хвосты.
- ☐ Ширина бина осмысленна; проверена устойчивость.
- ☐ Указаны *n* и, если важно, медиана/IQR.
- ☐ Есть клинический порог, если он существенен.
- ☐ Один цвет, без 3D и теней.
- ☐ Сетка не конкурирует с данными.
- ☐ Понятно, что по Y: пациенты или плотность.
- ☐ Для малых *n* рассмотрены точки/ECDF.
- ☐ Рисунок проверен в конечном размере 85 мм.

5.09.7 Как воспроизвести

```
uv sync
uv run python 05_charts/09_histogram/scripts/make_data.py
uv run python 05_charts/09_histogram/scripts/bad_plot.py
uv run python 05_charts/09_histogram/scripts/good_plot.py
```

Ключевой фрагмент:

```
bins = np.arange(0, 72, 2)
counts, _, _ = ax.hist(
    values, bins=bins,
    color=PRIMARY_BLUE, alpha=0.8,
    edgecolor="white", linewidth=0.4,
)
ax.axvline(20, color=ACCENT_VERMILLION, linestyle="--", linewidth=0.9)
ax.axvline(np.median(values), color="#333333", linestyle=":", linewidth=0.9)
```

`bins` можно задать числом или массивом границ. Массив границ предпочтительнее: он фиксирует ширину и облегчает сравнение нескольких выборок.

5.09.8 Что дальше

Следующий график — **5.10 ECDF**: эмпирическая функция распределения, точное чтение квантилей. У него будет свой генератор и свой `data/10_dataset.csv`.

Источники

- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Matplotlib: `hist` — matplotlib.org
- Tufte E. R. *The Visual Display of Quantitative Information*. 1983. — edwardtufte.com
- Weissgerber T. L. et al. Beyond Bar and Line Graphs // *PLoS Biology*. 2015. — doi:10.1371/journal.pbio.1002128

5.10 ECDF: функция распределения

ECDF (empirical cumulative distribution function) показывает, какая доля наблюдений не превышает каждое значение X. В отличие от гистограммы, здесь нет бинов: кривая строится по всем точкам и позволяет точно прочитать медиану, квартили и любой перцентиль.

ECDF — это ступенчатая функция. Каждый скачок — одно или несколько наблюдений; высота ступени — накопленная доля.

5.10.1 Сфера применения

ECDF отвечает на вопрос: **какая доля пациентов имеет значение ≤ x и где проходят квантили?**

Типичные случаи:

- распределение длительности госпитализации, времени до выписки;
- сравнение двух групп по всей кривой, а не только по средним;
- чтение медианы, IQR и перцентилей;
- проверка сдвига распределения;
- малые и средние выборки, где гистограмма капризна.

Когда ECDF **не** подходит:

- время до события с цензурированием — Kaplan–Meier (5.27);
- нужно показать плотность/форму — histogram/KDE;
- групп слишком много — кривые перекрываются (нужны small multiples);
- нужна одна сводка, а не распределение — dot/box.

5.10.2 Данные

Сценарий: 1 200 госпитализаций, 600 плановых и 600 экстренных. Длительность — дни; распределение скошено вправо.

Колонка	Смысл	Единица
`patient_id`	идентификатор пациента	—
`admission_type`	плановое/экстренное	—
`los_days`	длительность госпитализации	дни

Медиана: плановые — 6 дней, экстренные — 8,5 дня. Средние: 6,2 и 9,4. Правый хвост — до 20–25 дней.

Генератор: `05_charts/10_ecdf/scripts/make_data.py → data/10_dataset.csv`.

5.10.3 Плохой график

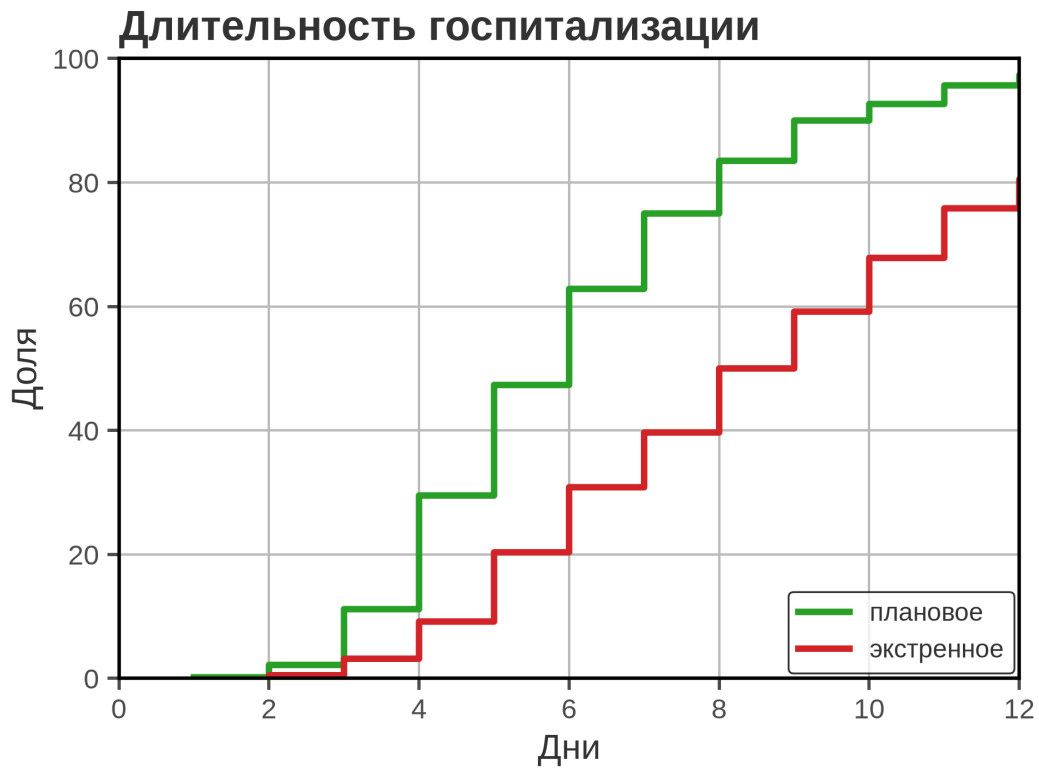


Рисунок 5.10.1. Плохая ECDF: обрезанная ось 0–12, красно-зелёные ступени, легенда, нет медиан и n.

Код: `05_charts/10_ecdf/scripts/bad_plot.py`.

Что с ним не так:

1. **Ось X обрезана до 12 дней.** Правый хвост и половина кривой скрыты; экстренные госпитализации выглядят короче, чем есть.
2. **Красно-зелёная пара.** Неразличима при протанопии/дейтеранопии.
3. **Легенда.** Заставляет переводить взгляд; для двух групп лучше прямые подписи.
4. **Толстые ступени, тяжёлая сетка, полная рамка.**
5. **Нет медиан, квартилей, единиц и n.**
6. **Заголовок «Длительность госпитализации».** Не сообщает, что экстренные длиннее.

5.10.4 Правильный график

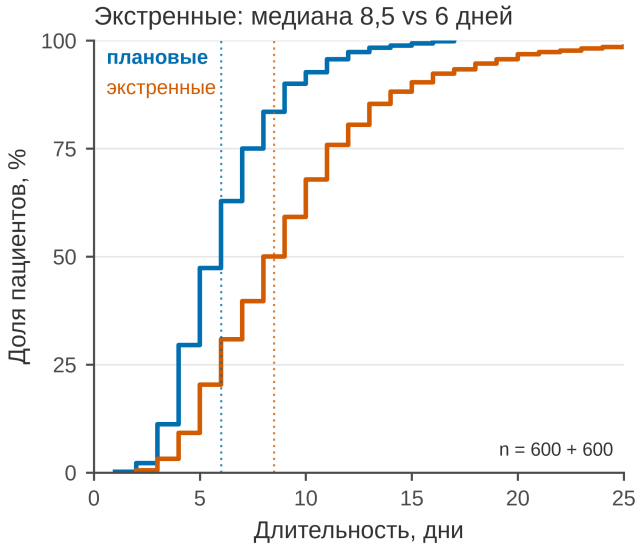


Рисунок 5.10.2. Правильная ECDF: полный диапазон 0–25, синий и вермиллион, медианы, прямые подписи, n.

Код: `05_charts/10_ecdf/scripts/good_plot.py`.

Что улучшено:

1. **Полный диапазон 0–25 дней.** Обе кривые видны целиком, включая хвост.
2. **Синий и вермиллион.** Различимы при CVD; без легенды, с прямыми подписями.
3. **Медианы отмечены пунктиром.** 6 и 8,5 дня; разница видна на уровне 50 %.
4. **Ось Y в процентах.** «Доля пациентов, %» читается без пересчёта.
5. **n = 600 + 600.** Понятно, сколько наблюдений в группах.
6. **Заголовок-вывод.** «Экстренные: медиана 8,5 vs 6 дней».
7. **Лёгкая сетка только по Y, без верхней и правой рамок.**
8. **85 мм.** Рисунок спроектирован в конечном размере.

ECDF читается так: найдите на оси X интересующий срок, поднимитесь до кривой и посмотрите долю на оси Y. Медиана — точка, где кривая пересекает 50 %.

5.10.5 Сопоставление

Что было	Почему плохо	Что сделано
ось X 0–12	хвост обрезан	0–25
красный/зелёный	CVD	синий/вермиллион
легенда	лишний поиск	прямые подписи
толстые ступени	шум	1,7 pt
нет медиан	не читаются квантили	пунктирные медианы
нет единиц и n	невозможно прочитать	«дни», n = 600 + 600
«Длительность…»	нет сообщения	заголовок с медианами
сетка по X и Y	шум	сетка только по Y

5.10.6 Чек-лист ECDF

- ☐ Ось X не обрезает хвост.
- ☐ Указаны единицы и *n*.
- ☐ Подписаны группы (прямо или легендой).
- ☐ Медиана/квартили отмечены, если они важны.
- ☐ Ось Y — доля или процент, ясно что именно.
- ☐ Нет лишних цветов и толстых ступеней.
- ☐ Для цензурированных данных выбран Kaplan–Meier.
- ☐ Сравнение групп не сводится к средним.
- ☐ Кривые не перекрываются из-за числа групп.
- ☐ Рисунок проверен в конечном размере 85 мм.

5.10.7 Как воспроизвести

```
uv sync
uv run python 05_charts/10_ecdf/scripts/make_data.py
uv run python 05_charts/10_ecdf/scripts/bad_plot.py
uv run python 05_charts/10_ecdf/scripts/good_plot.py
```

Ключевой фрагмент:

```
def ecdf(values):
    xs = np.sort(values)
    ys = np.arange(1, len(xs) + 1) / len(xs) * 100
    return xs, ys

xs, ys = ecdf(values)
ax.step(xs, ys, where="post", color=PRIMARY_BLUE, linewidth=1.7)
ax.axvline(np.median(values), color=PRIMARY_BLUE, linestyle=":", linewidth=0.8)
```

`where="post"` важен: ступень держится до следующего значения. Для сравнения групп используйте одинаковые оси и прямые подписи.

5.10.8 Что дальше

Следующий график — **5.11 box plot**: сравнение распределений по группам. У него будет свой генератор и свой `data/11_dataset.csv`.

Источники

- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Matplotlib: `step` — matplotlib.org
- Weissgerber T. L. et al. Beyond Bar and Line Graphs // *PLoS Biology*. 2015. — doi:10.1371/journal.pbio.1002128
- Tufte E. R. *The Visual Display of Quantitative Information*. 1983. — edwardtufte.com

5.11 Boxplot: сравнение распределений по группам

Boxplot — компактная сводка распределения: медиана, межквартильный размах (IQR), усы и выбросы. Он хорош для сравнения 2–5 групп, но **сам по себе скрывает форму** распределения и размер выборки.

Поэтому в этом разделе показаны четыре варианта:

1. плохой boxplot;
2. boxplot + отдельные точки;
3. violin + box + точки;
4. boxplot, совмещённый с гистограммой.

5.11.1 Сфера применения

Boxplot отвечает на вопрос: **как различаются медианы и разброс между группами?**

Типичные случаи:

- сравнение биомаркера по 2–5 группам (активность, тяжесть, центр);
- проверка сдвига и разброса до формального теста;
- поиск выбросов;
- компактная сводка в таблице рисунков;
- сравнение до/после (но для парных данных — 5.18).

Когда boxplot **не** достаточен:

- нужно увидеть форму/модальность — violin или histogram;
- групп много — small multiples;
- выборка маленькая — точки важнее коробки;
- нужны точные квантили — ECDF (5.10);
- данные цензурированы — Kaplan–Meier (5.27).

5.11.2 Данные

Сценарий: 450 взрослых, три уровня физической активности — низкая, умеренная, высокая. Показатель — BMI (кг/м²), по 150 человек в группе.

Колонка	Смысл	Единица
`patient_id`	идентификатор пациента	—
`activity`	уровень активности	—
`bmi_kg_m2`	индекс массы тела	кг/м²

Медианы: низкая — 29,4; умеренная — 27,8; высокая — 24,4 кг/м². Есть правый хвост и отдельные выбросы.

Генератор: `05_charts/11_box/scripts/make_data.py → data/11_dataset.csv`.

5.11.3 Плохой график

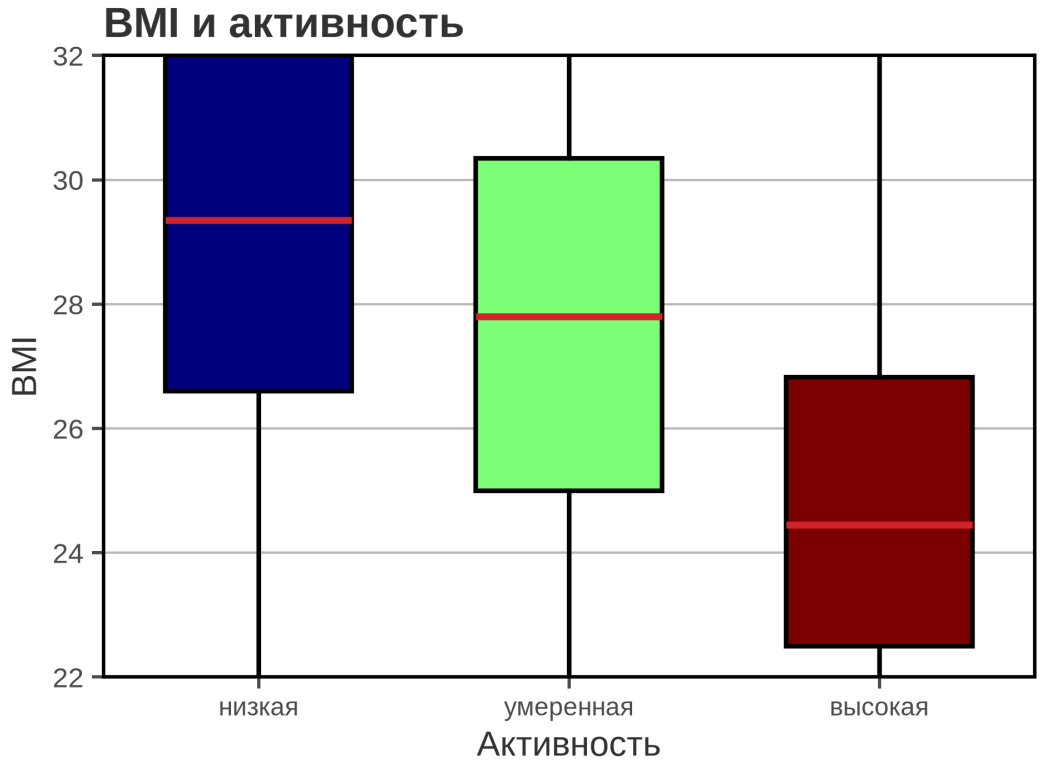


Рисунок 5.11.1. Плохой boxplot: обрезанная ось 22–32, радужные ящики, нет точек, тяжёлая сетка.

Код: `05_charts/11_box/scripts/bad_plot.py`.

Что с ним не так:

1. **Ось Y обрезана до 22–32.** Выбросы и хвосты скрыты; высокая группа выглядит «обрезанной».
2. **Радужные ящики, красные медианы и выбросы.** Декор вместо данных; CVD-небезопасно.
3. **Нет отдельных точек.** Не видно формы, размера групп и того, что за пределами усов.
4. **Тяжёлая сетка, полная рамка, толстые линии.**
5. **Заголовок «BMI и активность».** Не сообщает направление и величину различий.
6. **Нет единиц и *n*.**

5.11.4 Boxplot + точки

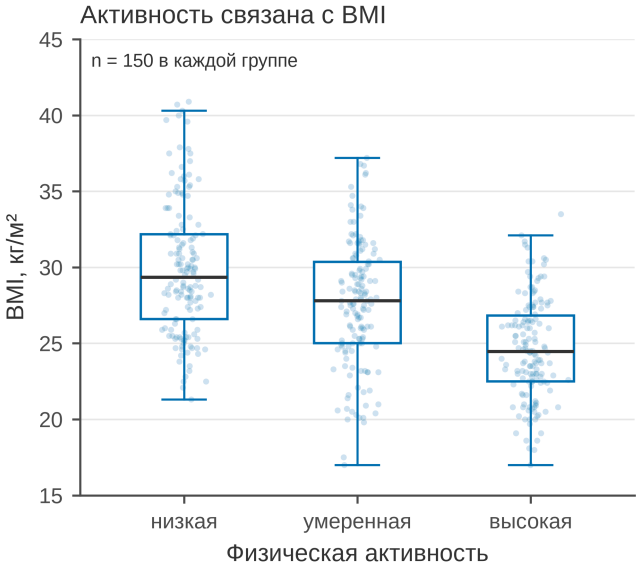


Рисунок 5.11.2. Правильный boxplot с точками: полный диапазон 15–45, jitter, n = 150, единицы.

Код: `05_charts/11_box/scripts/good_box_points.py`.

Что улучшено:

1. **Полный диапазон 15–45 кг/м².** Видны хвосты и выбросы.
2. **Белые ящики с синим контуром, тёмная медиана.** Один цвет, без радуги.
3. **Все 450 точек с jitter.** Видна плотность, форма и размер групп; выбросы не прячутся.
4. **Единицы, *n* = 150, заголовок-вывод.**
5. **Лёгкая сетка только по Y, 85 мм.**

Точки не заменяют boxplot: они показывают, что внутри коробки, а коробка даёт сводку. Вместе они честнее, чем boxplot отдельно.

5.11.5 Violin + box + точки

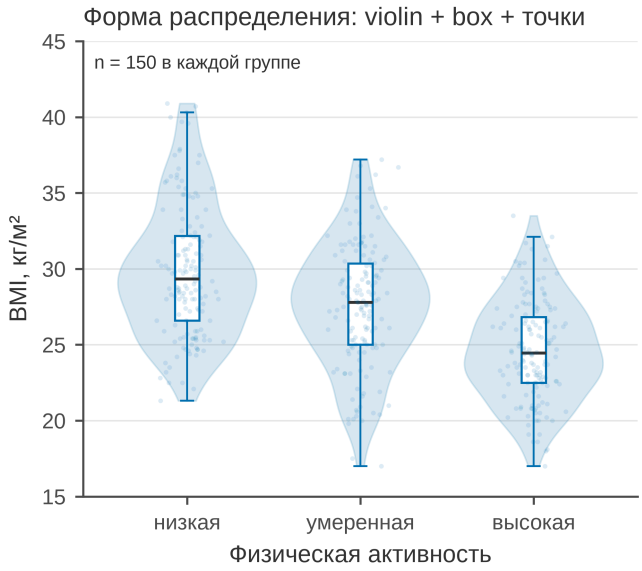


Рисунок 5.11.3. Violin + box + точки: форма распределения, медиана и исходные наблюдения.

Код: `05_charts/11_box/scripts/good_violin_box.py`.

Что показывает:

1. **Violin** — оценку плотности: где значения встречаются чаще.
2. **Box** — медиану, IQR и усы.
3. **Точки** — исходные наблюдения.

Это «raincloud»-подход: форма, сводка и данные одновременно. Он хорош для 3 групп и умеренных выборок. Но violin — это KDE: она может «продлить» хвост за пределы реальных данных и создать ложную плавность. При малых *n* доверяйте точкам больше, чем контуру.

5.11.6 Boxplot + гистограмма

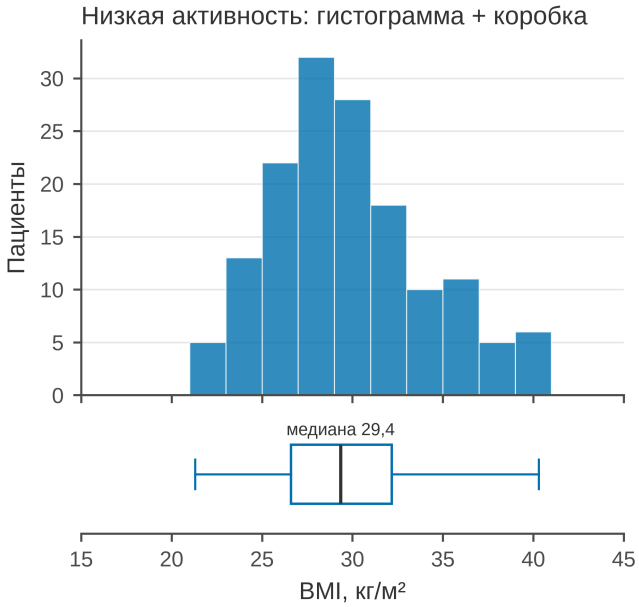


Рисунок 5.11.4. Совмещённый график: гистограмма сверху, горизонтальный boxplot снизу, общая ось BMI.

Код: `05_charts/11_box/scripts/good_box_hist.py`.

Что показывает:

1. **Гистограмма сверху** — форму распределения (бины по 2 кг/м²).
2. **Boxplot снизу** — медиану, IQR, усы и выбросы.
3. **Общая ось X** — гистограмма и коробка выровнены.

Этот вариант полезен, когда нужно показать и форму, и сводку для одной переменной или одной группы. Медиана 29,4 кг/м² подписана прямо над коробкой.

5.11.7 Сопоставление

Что было	Почему плохо	Что сделано
ось Y 22–32	выбросы и хвосты скрыты	15–45
радуга, красные медианы	декор, CVD	один синий цвет
нет точек	не видна форма	jitter-точки
толстые линии	шум	0,8–1,2 pt
сетка по X и Y	шум	сетка только по Y
полная рамка	визуальный шум	только левая и нижняя оси
«BMI и активность»	нет сообщения	заголовок-вывод
нет единиц и n	невозможно прочитать	единицы, n = 150
только коробка	форма скрыта	1. violin / histogram

5.11.8 Чек-лист boxplot

- ☐ Ось Y не обрезает усы и выбросы.
- ☐ Указаны единицы и *n* (по группам).
- ☐ Медиана и IQR читаются; усы объяснены.
- ☐ Точки показаны, если *n* небольшое или важна форма.
- ☐ Для формы добавлен violin или histogram.
- ☐ Цвет не дублирует группы без смысла.
- ☐ Нет 3D, теней и радуги.
- ☐ Сетка не конкурирует с данными.
- ☐ Для многих групп — small multiples.
- ☐ Рисунок проверен в конечном размере.

5.11.9 Как воспроизвести

```
uv sync
uv run python 05_charts/11_box/scripts/make_data.py
uv run python 05_charts/11_box/scripts/bad_plot.py
uv run python 05_charts/11_box/scripts/good_box_points.py
uv run python 05_charts/11_box/scripts/good_violin_box.py
uv run python 05_charts/11_box/scripts/good_box_hist.py
```

Ключевые фрагменты:

```
# boxplot + точки
ax.boxplot(data, positions=[1, 2, 3], widths=0.5, patch_artist=True,
           showfliers=False, boxprops={"facecolor": "white"})
for position, values in zip([1, 2, 3], data, strict=True):
    ax.scatter(position + rng.normal(0, 0.06, len(values)), values,
               s=5, alpha=0.18, linewidths=0)

# violin + box
ax.violinplot(data, positions=[1, 2, 3], widths=0.8, showextrema=False)

# histogram + horizontal box
fig, (ax_hist, ax_box) = plt.subplots(2, 1, sharex=True,
                                      gridspec_kw={"height_ratios": [3, 1]})
ax_box.boxplot([values], orientation="horizontal", positions=[0.5])
```

5.11.10 Что дальше

Следующий график — **5.12 violin**: отдельный разбор скрипичной диаграммы, её преимуществ и ловушек. У него будет свой генератор и свой `data/12_dataset.csv`.

Источники

- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Weissgerber T. L. et al. Beyond Bar and Line Graphs // *PLoS Biology*. 2015. — doi:10.1371/journal.pbio.1002128
- Matplotlib: `boxplot` — matplotlib.org
- Matplotlib: `violinplot` — matplotlib.org

5.12 Violin: форма распределения

Violin plot — это зеркальная оценка плотности (KDE). Ширина скрипки показывает, как часто встречаются значения; форма — модальность, скошенность, хвосты. В отличие от boxplot, violin не прячет форму за коробкой.

Но violin — это **оценка**, а не исходные данные. Ширина зависит от bandwidth, хвосты могут выходить за реальный диапазон, а при малых *n* контур становится фантазией. Поэтому внутри скрипки нужна сводка: квартильные линии или коробка.

5.12.1 Сфера применения

Violin отвечает на вопрос: **как выглядит форма распределения в каждой группе?**

Типичные случаи:

- сравнение 2–5 групп по непрерывной величине;
- поиск модальности/двугорбости;
- проверка формы перед выбором теста;
- замена boxplot, когда форма важна;
- презентация распределений в больших выборках.

Когда violin **не** нужен:

- *n* меньше 20 — лучше точки/strip;
- нужны точные квантили — ECDF;
- групп много — small multiples;
- данные цензурированы — Kaplan–Meier;
- важна только медиана/IQR — boxplot.

5.12.2 Данные

Сценарий: 600 пациентов, три стадии ХБП (1–2, 3, 4–5). Показатель — eGFR (мл/мин/1,73 м²), по 200 человек в группе.

Колонка	Смысл	Единица
`patient_id`	идентификатор пациента	—
`ckd_stage`	стадия ХБП	—
`sex`	пол	—
`egfr_ml_min_1_73m2`	СКФ	мл/мин/1,73 м²

Медианы: 88,2; 44,0; 20,8 мл/мин/1,73 м². Распределения сдвигаются вниз, форма меняется.

Генератор: `05_charts/12_violin/scripts/make_data.py → data/12_dataset.csv`.

5.12.3 Плохой график

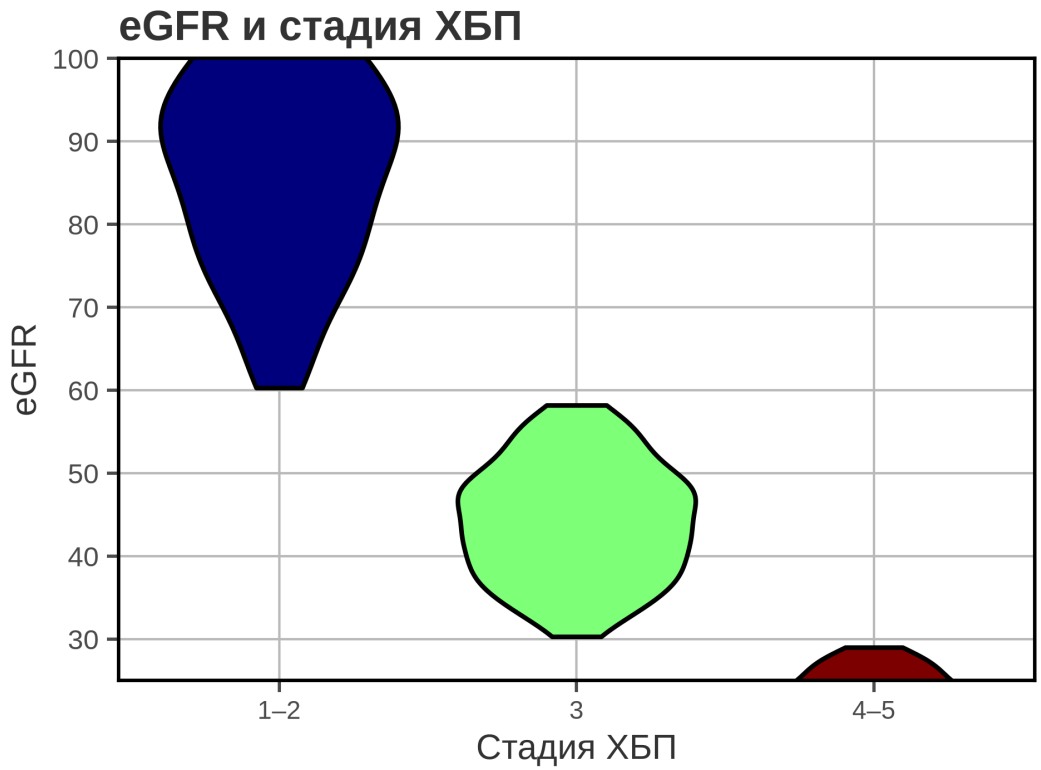


Рисунок 5.12.1. Плохой violin: обрезанная ось 25–100, радужные тела, нет медиан и точек.

Код: `05_charts/12_violin/scripts/bad_plot.py`.

Что с ним не так:

1. **Ось Y обрезана до 25–100.** Стадия 4–5 и верхний хвост стадии 1–2 скрыты; форма искажена.
2. **Радужные тела и толстые чёрные контуры.** Декор, CVD.
3. **Нет медианы, квартилей и точек.** Видна форма, но нет сводки и исходных наблюдений.
4. **Тяжёлая сетка, полная рамка.**
5. **Заголовок «eGFR и стадия ХБП».** Не сообщает направление.
6. **Нет единиц и *n*.**

5.12.4 Violin с квартильными линиями

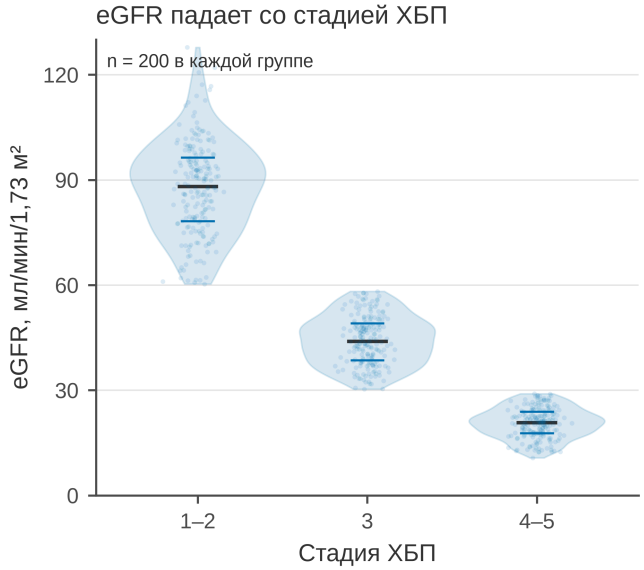


Рисунок 5.12.2. Правильный violin: полный диапазон 0–130, квартильные линии, точки, n = 200.

Код: `05_charts/12_violin/scripts/good_violin_quart.py`.

Что улучшено:

1. **Полный диапазон 0–130.** Все стадии и хвосты видны.
2. **Один цвет, без радуги.**
3. **Квартили и медиана — горизонтальными линиями.** Медиана толще, Q1/Q3 тоньше.
4. **Точки с jitter.** Видны наблюдения и размер групп.
5. **Единицы, *n* = 200, заголовок-вывод.**
6. **Лёгкая сетка по Y, 85 мм.**

5.12.5 Violin с внутренней коробкой

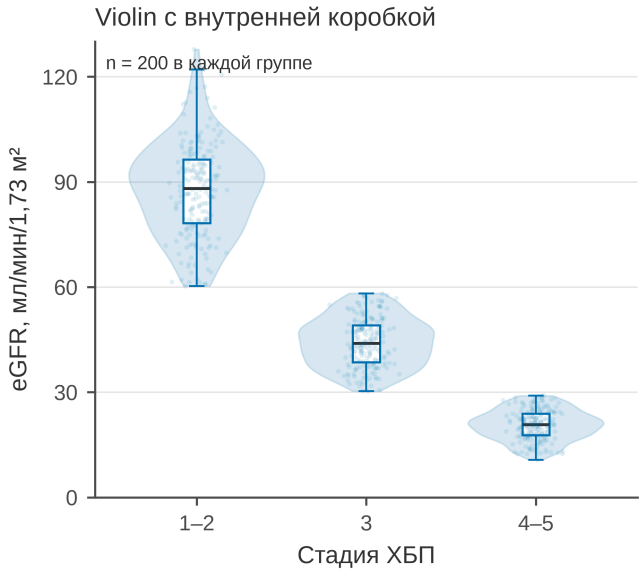


Рисунок 5.12.3. Violin с прямоугольной коробкой внутри: медиана, IQR, усы и точки.

Код: `05_charts/12_violin/scripts/good_violin_box.py`.

Это версия «violin + прямоугольники»: внутри каждой скрипки — мини-коробка с медианой, IQR и усами. Она полезна, когда нужно одновременно показать форму (violin) и классическую сводку (box).

Что важно: коробка внутри должна быть узкой, иначе она закрывает скрипку. Усы и выбросы можно не показывать, если точки уже нанесены; но тогда это нужно указать в подписи.

5.12.6 Сопоставление

Что было	Почему плохо	Что сделано
ось Y 25–100	стадия 4–5 обрезана	0–130
радуга, толстые контуры	декор, CVD	один синий цвет
нет медиан	нет сводки	квартильные линии / коробка
нет точек	не видно наблюдений	jitter-точки
сетка по X и Y	шум	сетка только по Y
полная рамка	визуальный шум	только левая и нижняя оси
«eGFR и стадия ХБП»	нет сообщения	заголовок-вывод
нет единиц и n	невозможно прочитать	единицы, n = 200
только violin	нет сводки	violin + quart / box

5.12.7 Чек-лист violin

- ☐ Ось Y не обрезает хвосты.
- ☐ Указаны единицы и *n*.
- ☐ Внутри есть медиана/IQR (линии или коробка).
- ☐ Точки показаны, если *n* небольшое.
- ☐ Bandwidth/trim не скрывают структуру.
- ☐ Нет радуги и тяжёлых контуров.

- ❐ Для малых *n* выбран strip/dot.
- ❐ Для многих групп — small multiples.
- ❐ Форма не интерпретируется как «точная» плотность.
- ❐ Рисунок проверен в конечном размере 85 мм.

5.12.8 Как воспроизвести

```
uv sync
uv run python 05_charts/12_violin/scripts/make_data.py
uv run python 05_charts/12_violin/scripts/bad_plot.py
uv run python 05_charts/12_violin/scripts/good_violin_quart.py
uv run python 05_charts/12_violin/scripts/good_violin_box.py
```

Ключевые фрагменты:

```
violins = ax.violinplot(data, positions=[1, 2, 3], widths=0.8,
                        showextrema=False, points=100)
for body in violins["bodies"]:
    body.set_facecolor(PRIMARY_BLUE)
    body.set_alpha(0.15)

# квартильные линии
q1, median, q3 = np.percentile(values, [25, 50, 75])
ax.hlines([q1, q3], position - 0.1, position + 0.1, color=PRIMARY_BLUE)
ax.hlines(median, position - 0.12, position + 0.12, color="#333333", linewidth=1.3)

# коробка внутри
ax.boxplot(data, positions=[1, 2, 3], widths=0.16, patch_artist=True,
           showfliers=False, boxprops={"facecolor": "white"})
```

5.12.9 Что дальше

Следующий график — **5.13 strip**: отдельные точки по группам без коробки. У него будет свой генератор и свой `data/13_dataset.csv`.

Источники

- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Hintze J. L., Nelson R. D. Violin Plots: A Box Plot-Density Trace Synergism // *The American Statistician*. 1998. — doi:10.1080/00031305.1998.10480559
- Matplotlib: `violinplot` — matplotlib.org
- Weissgerber T. L. et al. Beyond Bar and Line Graphs // *PLoS Biology*. 2015. — doi:10.1371/journal.pbio.1002128

5.13 Strip: все точки по группам

Strip plot (jitter plot) показывает каждое наблюдение: точки располагаются по группам, а небольшой случайный сдвиг по X не даёт им слиться. Это самый честный способ сравнить небольшие выборки: видны разброс, выбросы и форма, а не только медиана.

Jitter — не декор и не «шум». Он должен быть случайным, но воспроизводимым (seed), и не настолько большим, чтобы точки уходили в соседнюю группу.

5.13.1 Сфера применения

Strip отвечает на вопрос: **как выглядят все наблюдения в группах и где медиана?**

Типичные случаи:

- небольшие выборки (10–50 на группу);
- сравнение 2–5 групп без коробки;
- показ выбросов и гетерогенности;
- замена bar/box, когда важны отдельные пациенты;
- проверка, не скрывает ли среднее бимодальность.

Когда strip **не** нужен:

- точек тысячи — overplotting, нужны hexbin/contour;
- нужны точные квантили — ECDF;
- важна только сводка — box/dot;
- группы сильно разного размера — точки могут перегрузить ось;
- jitter скрывает реальную структуру (например, дискретные значения).

5.13.2 Данные

Сценарий: 90 пациентов, три схемы обезболивания — НПВС, опиоид, комбинация. Через 24 часа — боль по ВАШ (0–100 мм), по 30 человек в группе.

Колонка	Смысл	Единица
`patient_id`	идентификатор пациента	—
`analgesia`	схема обезболивания	—
`vas_mm`	боль по ВАШ	мм

Медианы: НПВС — 56, опиоид — 45,5, комбинация — 32,5 мм.

Генератор: `05_charts/13_strip/scripts/make_data.py → data/13_dataset.csv`.

5.13.3 Плохой график

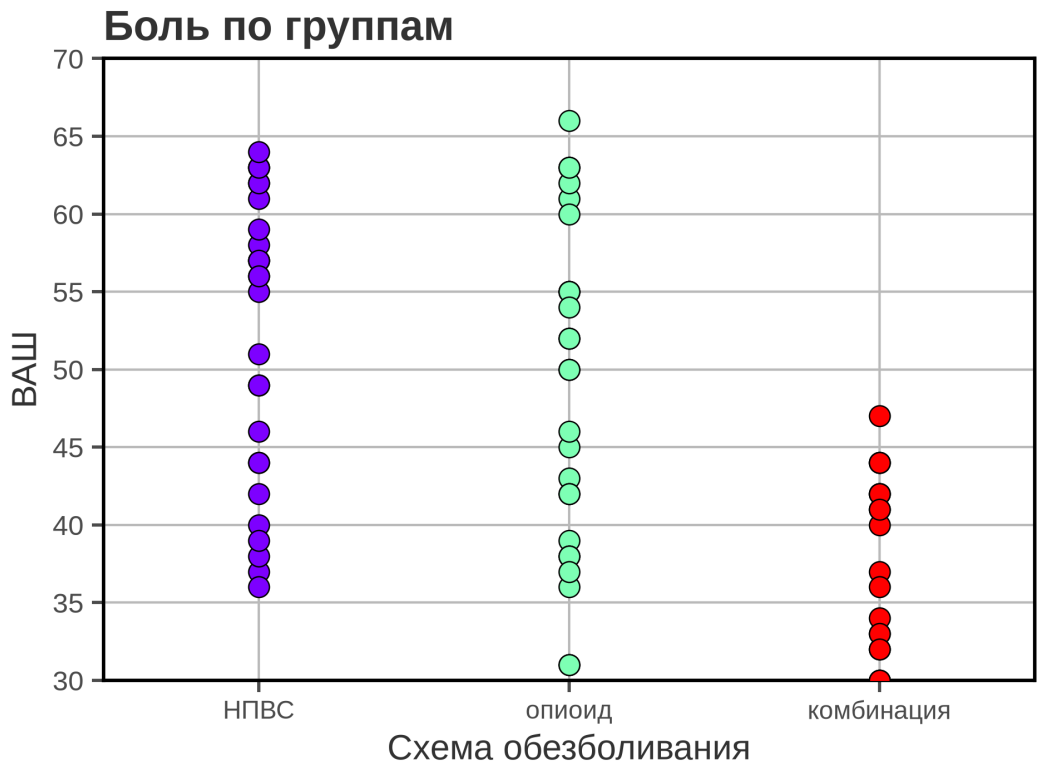


Рисунок 5.13.1. Плохой strip: точки без jitter, радуга, обрезанная ось 30–70, нет медиан и n.

Код: `05_charts/13_strip/scripts/bad_plot.py`.

Что с ним не так:

1. **Нет jitter.** 30 точек в каждой группе стоят строго по одной вертикали и сливаются; видно не распределение, а плотность наложения.
2. **Радужные точки по группам.** Цвет дублирует ось X, CVD.
3. **Обрезанная ось Y (30–70).** Низкие и высокие значения скрыты.
4. **Крупные непрозрачные точки, тяжёлая сетка, полная рамка.**
5. **Заголовок «Боль по группам».** Не сообщает, какая схема лучше.
6. **Нет медиан, единиц и n.**

5.13.4 Правильный график

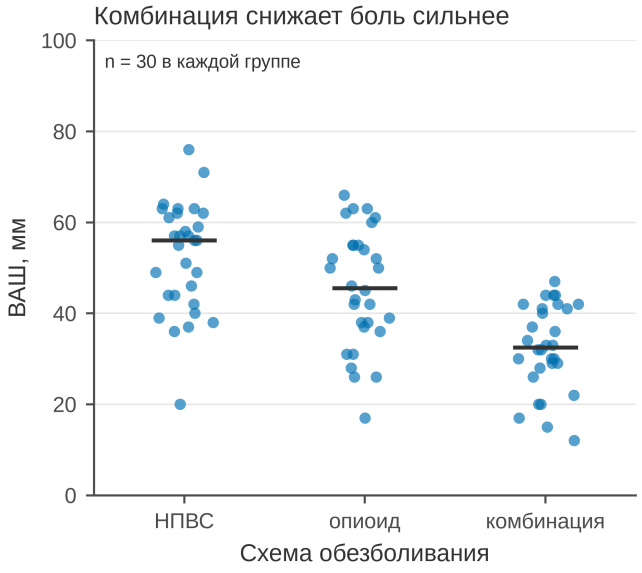


Рисунок 5.13.2. Правильный strip: jitter, один цвет, полный диапазон 0–100, медианы, n = 30.

Код: `05_charts/13_strip/scripts/good_plot.py`.

Что улучшено:

1. **Jitter по X.** Все 30 точек видны отдельно; jitter воспроизводимый.
2. **Один цвет, alpha = 0,65.** Нет двойного кодирования.
3. **Полный диапазон 0–100 мм.**
4. **Медиана — горизонтальная линия** в каждой группе.
5. **n = 30, единицы, заголовок-вывод.**
6. **Лёгкая сетка только по Y, 85 мм.**

Strip особенно хорош, когда *n* небольшое: читатель видит каждого пациента, а не только сводку. При больших *n* точки всё равно сливаются — тогда нужны box/violin/hexbin.

5.13.5 Сопоставление

Что было	Почему плохо	Что сделано
нет jitter	точки сливаются	jitter 0,09
радуга	CVD, двойное кодирование	один цвет
ось Y 30–70	хвосты скрыты	0–100
крупные точки	шум	s=18, alpha=0,65
нет медиан	нет сводки	горизонтальные медианы
сетка по X и Y	шум	сетка только по Y
полная рамка	визуальный шум	только левая и нижняя оси
«Боль по группам»	нет сообщения	заголовок-вывод
нет единиц и n	невозможно прочитать	«мм», n = 30

5.13.6 Чек-лист strip

- ☐ Jitter есть и он воспроизводимый.
- ☐ Jitter не переносит точки в чужую группу.
- ☐ Ось Y не обрезает хвосты.
- ☐ Указаны единицы и *n*.
- ☐ Медиана/среднее показаны, если нужна сводка.
- ☐ Цвет не дублирует ось X.
- ☐ Точек не слишком много; иначе box/hexbin.
- ☐ Дискретные значения не «размазаны» jitter’ом.
- ☐ Группы одинаково читаемы.
- ☐ Рисунок проверен в конечном размере 85 мм.

5.13.7 Как воспроизвести

```
uv sync
uv run python 05_charts/13_strip/scripts/make_data.py
uv run python 05_charts/13_strip/scripts/bad_plot.py
uv run python 05_charts/13_strip/scripts/good_plot.py
```

Ключевой фрагмент:

```
for position, group in enumerate(GROUPS, start=1):
    values = df.loc[df["analgesia"] == group, "vas_mm"].to_numpy()
    jitter = rng.normal(0.0, 0.09, len(values))
    ax.scatter(position + jitter, values,
               s=18, color=PRIMARY_BLUE, alpha=0.65, linewidths=0)
    ax.hlines(np.median(values), position - 0.18, position + 0.18,
              color="#333333", linewidth=1.5)
```

`rng.normal(0, 0.09)` — компромисс: достаточно, чтобы развести точки, но не настолько, чтобы смешать группы. Seed фиксируйте в подписи или коде.

5.13.8 Что дальше

Следующий график — **5.14 dot + CI**: точка оценки и доверительный интервал. У него будет свой генератор и свой `data/14_dataset.csv`.

Источники

- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Weissgerber T. L. et al. Beyond Bar and Line Graphs // *PLoS Biology*. 2015. — doi:10.1371/journal.pbio.1002128
- Matplotlib: `scatter` — matplotlib.org
- Tufte E. R. *The Visual Display of Quantitative Information*. 1983. — edwardtufte.com

5.14 Dot + CI: оценка и неопределённость

Dot + CI — это точка оценки и доверительный интервал вокруг неё. Такой график отвечает не только «сколько», но и «насколько точно». Он честнее столбца с одной высотой: видно, что оценка — случайная величина с неопределённостью.

Ключевое различие: **CI — это не SD**. Стандартное отклонение описывает разброс наблюдений, доверительный интервал — точность оценки. Для доли используют интервал Уилсона, для среднего — t-интервал или бутстрэп.

5.14.1 Сфера применения

Dot + CI отвечает на вопрос: **какова оценка в каждой группе и насколько она точна?**

Типичные случаи:

- доля осложнений/смертности по центрам;
- средние показатели по больницам с 95 % CI;
- результаты подгрупп перед forest plot (5.16);
- сравнение центров без ложного ранжирования;
- оценка эффекта с неопределённостью.

Когда dot + CI **не** нужен:

- нужны все наблюдения — strip/box;
- нужна одна сводка без сравнения — таблица;
- групп много и CI пересекаются — forest plot;
- оценка без интервала — описательная статистика;
- время до события — Kaplan–Meier.

5.14.2 Данные

Сценарий: 600 пациентов, шесть центров, по 100 человек. Исход — осложнение (1/0). Для каждой доли — 95 % ДИ Уилсона.

Колонка	Смысл	Единица
`patient_id`	идентификатор пациента	—
`center`	центр	—
`complication`	осложнение (1/0)	—

Доли: 9–19 %; общая — 14,7 %. Интервалы широкие (≈ 5–28 %) из-за $n = 100$ на центр.

Генератор: `05_charts/14_dot_ci/scripts/make_data.py → data/14_dataset.csv`.

5.14.3 Плохой график

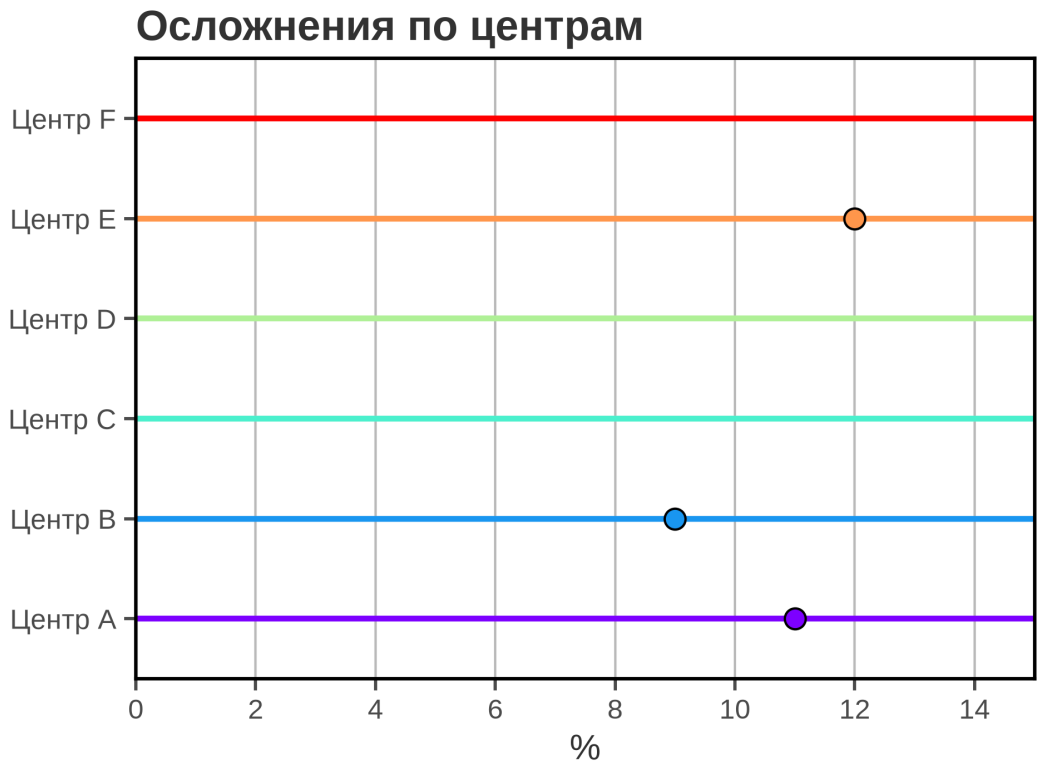


Рисунок 5.14.1. Плохой dot + CI: вместо ДИ — SD, обрезанная ось 0–15, радуга, нет общей доли и n.

Код: `05_charts/14_dot_ci/scripts/bad_plot.py`.

Что с ним не так:

1. **Вместо 95 % ДИ — стандартное отклонение.** Усы выглядят как «интервалы», но это разброс бинарного исхода; их нельзя интерпретировать как точность оценки.
2. **Ось X обрезана до 0–15 %.** Центры с долей 18–19 % вообще не видны.
3. **Радужные точки и усы.** CVD, декор.
4. **Тяжёлая сетка, полная рамка.**
5. **Нет общей доли, n и единиц.**
6. **Заголовок «Осложнения по центрам».** Не сообщает, что показана неопределённость.

5.14.4 Правильный график

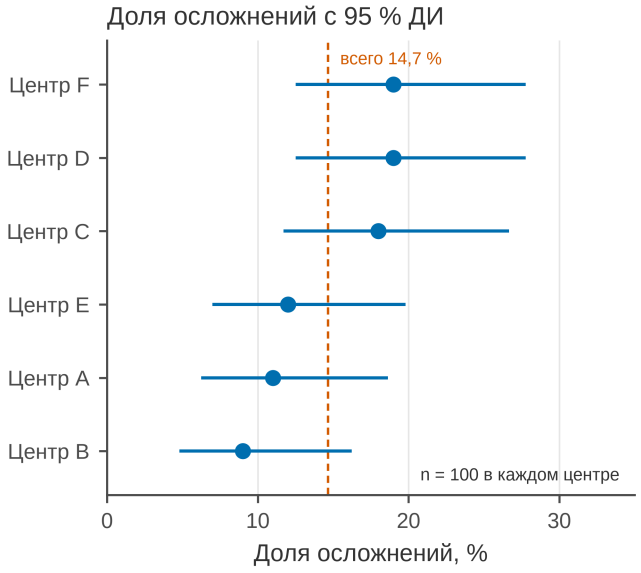


Рисунок 5.14.2. Правильный dot + CI: 95 % ДИ Уилсона, полный диапазон 0–35, общая доля, n = 100.

Код: `05_charts/14_dot_ci/scripts/good_plot.py`.

Что улучшено:

1. **95 % ДИ Уилсона** для каждой доли — корректная неопределённость.
2. **Полный диапазон 0–35 %.** Все центры видны.
3. **Один цвет.** Точки и усы не конкурируют.
4. **Общая доля 14,7 %** — пунктирная линия и подпись.
5. **Сортировка по доле.** Легче читать, но CI показывают, что различия неочевидны.
6. **n = 100 в каждом центре, единицы, 85 мм.**

Пересекающиеся интервалы — важный сигнал: нельзя ранжировать центры без формального сравнения. Dot + CI как раз показывает, что разница между 9 % и 19 % при $n = 100$ может быть случайной.

5.14.5 Сопоставление

Что было	Почему плохо	Что сделано
SD вместо CI	не та неопределённость	95 % ДИ Уилсона
ось X 0–15	центры 18–19 % скрыты	0–35
радуга	CVD, декор	один цвет
нет общей доли	нет ориентира	линия 14,7 %
нет сортировки	трудно читать	сортировка по доле
сетка по X и Y	шум	сетка только по X
полная рамка	визуальный шум	только левая и нижняя оси
«Осложнения по центрам»	нет сообщения	заголовок о 95 % ДИ
нет n	непонятна точность	n = 100

5.14.6 Чек-лист dot + CI

- ☐ Указано, что такое интервал: 95 % CI, а не SD/SE.
- ☐ Для долей — Уилсон/точный интервал, не нормальное приближение.
- ☐ Ось не обрезает интервалы.
- ☐ Указаны единицы и *n* по группам.
- ☐ Есть общая оценка/референс, если она нужна.
- ☐ Сортировка не выдаёт себя за статистический вывод.
- ☐ Пересечение CI не игнорируется.
- ☐ Цвет не дублирует ось.
- ☐ Сетка не конкурирует с усами.
- ☐ Рисунок проверен в конечном размере 85 мм.

5.14.7 Как воспроизвести

```
uv sync
uv run python 05_charts/14_dot_ci/scripts/make_data.py
uv run python 05_charts/14_dot_ci/scripts/bad_plot.py
uv run python 05_charts/14_dot_ci/scripts/good_plot.py
```

Ключевой фрагмент:

```
def wilson_ci(successes, n, z=1.96):
    p = successes / n
    denominator = 1 + z**2 / n
    center = (p + z**2 / (2 * n)) / denominator
    half = z * np.sqrt(p * (1 - p) / n + z**2 / (4 * n**2)) / denominator
    return (center - half) * 100, (center + half) * 100

low, high = wilson_ci(successes, n)
ax.errorbar(p, y, xerr=[[p - low], [high - p]], fmt="o", color=PRIMARY_BLUE)
```

Для средних используйте t-интервал или бутстрэп; для долей Уилсон устойчивее нормального приближения при малых *n* и крайних долях.

5.14.8 Что дальше

Следующий график — **5.15 bar**: столбцы для сравнения величин и их типичные ошибки. У него будет свой генератор и свой `data/15_dataset.csv`.

Источники

- Wilson E. B. Probable Inference, the Law of Succession, and Statistical Inference // *JASA*. 1927. — doi:10.1080/01621459.1927.10502953
- Cumming G. *Understanding the New Statistics*. Routledge, 2012. — routledge.com
- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Matplotlib: `errorbar` — matplotlib.org

5.15 Bar: сравнение величин

Bar chart сравнивает **агрегированные величины** по категориям: число госпитализаций, затраты, койко-дни, объём выборки. Это не график распределения и не график тренда: для распределения — histogram/box, для времени — line.

Главное правило: **нулевая база обязательна**. Длина столбца должна быть пропорциональна величине; обрезанная ось превращает небольшую разницу в «драму».

5.15.1 Сфера применения

Bar отвечает на вопрос: **какая категория больше и насколько?**

Типичные случаи:

- число пациентов/госпитализаций по отделениям;
- затраты или койко-дни по программам;
- объём выборки по центрам;
- сравнение немногих категорий (2–8);
- рейтинг, где важна абсолютная величина.

Когда bar **не** нужен:

- нужно распределение — histogram/box/violin;
- динамика во времени — line;
- много категорий — horizontal bar или dot;
- важна точность оценки — dot + CI;
- части целого — stacked bar 100 % (5.21), не pie (5.22).

5.15.2 Данные

Сценарий: пять отделений больницы, число госпитализаций за год. Величины — счётчики, поэтому столбцы уместны.

Колонка	Смысл	Единица
`department`	отделение	—
`admissions`	госпитализаций за год	число

Терапия — 1 240, хирургия — 980, кардиология — 860, урология — 540, офтальмология — 420. Всего 4 040.

Генератор: `05_charts/15_bar/scripts/make_data.py → data/15_dataset.csv`.

5.15.3 Плохой график

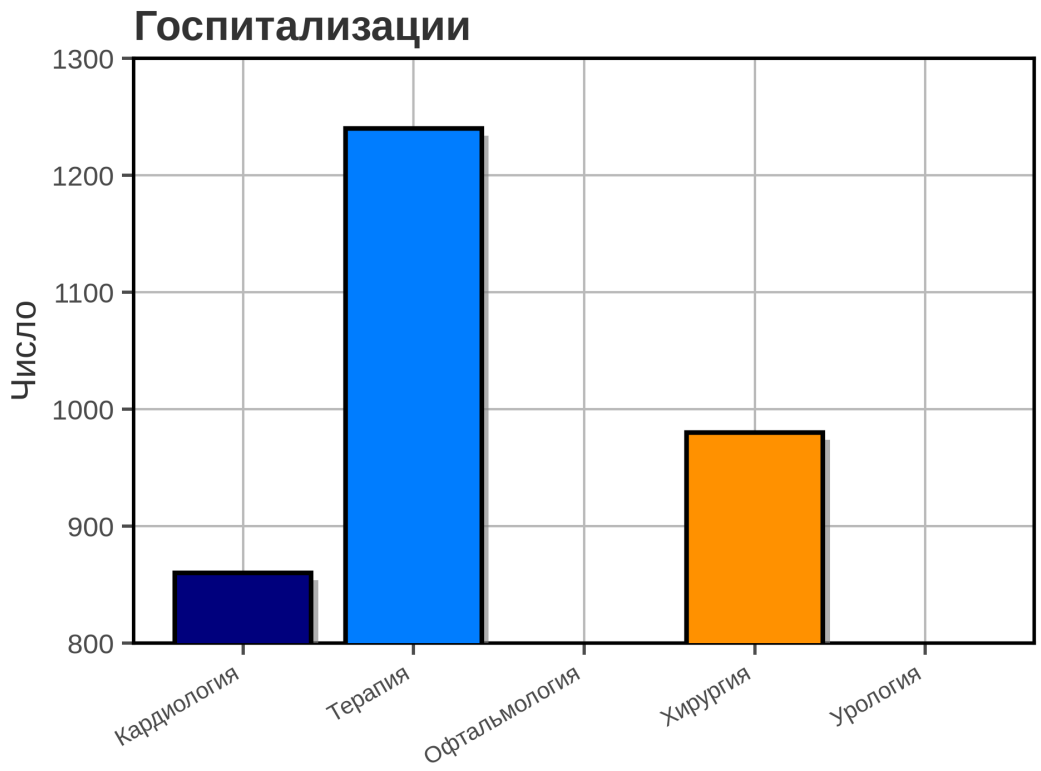


Рисунок 5.15.1. Плохой bar: обрезанная ось 800–1300, радужные столбцы, тени, нет значений.

Код: `05_charts/15_bar/scripts/bad_plot.py`.

Что с ним не так:

1. **Ось Y обрезана до 800–1300.** Нулевая база скрыта; столбцы 540 и 420 вообще не видны, а разница между 980 и 1 240 преувеличена.
2. **Радужные столбцы, чёрные края и тени.** Декор, CVD.
3. **Отделения не отсортированы.** Глаз не может ранжировать.
4. **Тяжёлая сетка по обеим осям и полная рамка.**
5. **Заголовок «Госпитализации».** Не сообщает вывод.
6. **Нет значений на столбцах, единиц и n.**

5.15.4 Правильный график

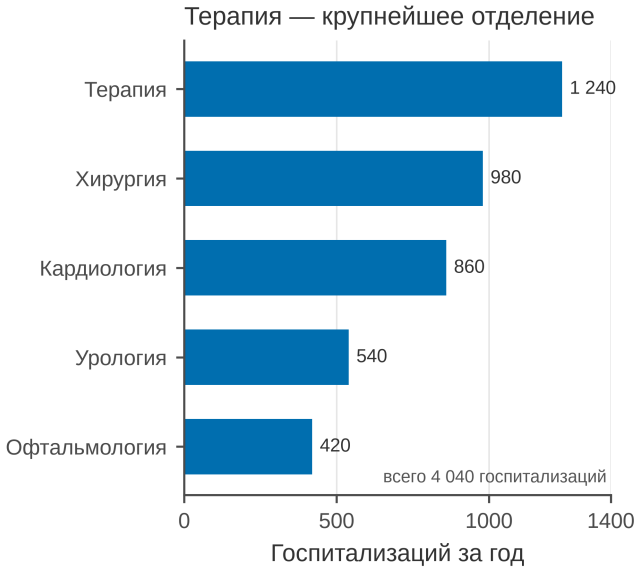


Рисунок 5.15.2. Правильный bar: горизонтальные сортированные столбцы, нулевая база, значения, всего 4 040.

Код: `05_charts/15_bar/scripts/good_plot.py`.

Что улучшено:

1. **Горизонтальные столбцы.** Длинные названия отделений читаются без поворота.
2. **Сортировка по величине.** Ранжирование очевидно.
3. **Нулевая база.** Ось X начинается с 0; длины пропорциональны.
4. **Значения подписаны** прямо у столбцов.
5. **Один цвет, без теней и 3D.**
6. **Единицы, общее число 4 040, заголовок-вывод, 85 мм.**

Bar — не «универсальный график». Если нужна форма распределения, он её не покажет; если нужна динамика, он её скроет.

5.15.5 Сопоставление

Что было	Почему плохо	Что сделано
ось Y 800–1300	нулевая база скрыта	0–1400
радуга, тени	декор	один цвет
без сортировки	трудно ранжировать	сортировка
вертикально	подписи наклонены	горизонтально
нет значений	нужно оценивать на глаз	подписи значений
сетка по X и Y	шум	сетка только по X
полная рамка	визуальный шум	только левая и нижняя оси
«Госпитализации»	нет вывода	заголовок-вывод
нет единиц и n	непонятно, что считать	«за год», всего 4 040

5.15.6 Чек-лист bar

- ☐ Ось начинается с нуля.
- ☐ Длина пропорциональна величине.
- ☐ Категории отсортированы, если нет смыслового порядка.
- ☐ Значения подписаны или легко читаются.
- ☐ Указаны единицы и период.
- ☐ Один цвет, без 3D/теней.
- ☐ Длинные подписи — горизонтально.
- ☐ Для распределения выбран histogram/box.
- ☐ Для тренда выбрана line.
- ☐ Рисунок проверен в конечном размере 85 мм.

5.15.7 Как воспроизвести

```
uv sync
uv run python 05_charts/15_bar/scripts/make_data.py
uv run python 05_charts/15_bar/scripts/bad_plot.py
uv run python 05_charts/15_bar/scripts/good_plot.py
```

Ключевой фрагмент:

```
df = pd.read_csv(...).sort_values("admissions")
bars = ax.barh(df["department"], df["admissions"], color=PRIMARY_BLUE)
for bar in bars:
    value = int(bar.get_width())
    ax.text(value + 25, bar.get_y() + bar.get_height() / 2, f"{value:,}")
ax.set_xlim(0, 1400)
```

`barh` удобнее для длинных названий; сортировка и подписи значений делают график самодостаточным.

5.15.8 Что дальше

Следующий график — **5.16 forest**: оценки эффектов и доверительные интервалы для многих подгрупп. У него будет свой генератор и свой `data/16_dataset.csv`.

Источники

- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Tufte E. R. *The Visual Display of Quantitative Information*. 1983. — edwardtufte.com
- Matplotlib: `barh` — matplotlib.org

5.16 Forest: эффект по подгруппам

Forest plot — это ряд оценок эффекта с доверительными интервалами, выстроенных по вертикали. Он показывает не только «где эффект», но и «насколько он точен» в каждой подгруппе.

Для отношений (OR, RR, HR) ось **обязательно логарифмическая**: только тогда OR = 0,5 и OR = 2 симметричны относительно 1. Линия «нет эффекта» — OR = 1 — обязательна.

5.16.1 Сфера применения

Forest отвечает на вопрос: **каков эффект в подгруппах и перекрывают ли интервалы единицу?**

Типичные случаи:

- подгрупповой анализ RCT;
- мета-анализ нескольких исследований;
- OR/RR/HR по центрам и стратам;
- проверка гетерогенности эффекта;
- честное представление неопределённости.

Когда forest **не** нужен:

- одна оценка — dot + CI;
- нужны исходные распределения — box/strip;
- нет общего эффекта и осмысленной группировки;
- подгруппы выбраны post hoc без поправки;
- эффект выражен в абсолютных единицах без лог-шкалы.

5.16.2 Данные

Сценарий: RCT, 800 пациентов (400 лечение / 400 контроль), исход — осложнение. Эффект — OR с 95 % CI Уолфа; восемь подгрупп и общая оценка.

Колонка	Смысл	Единица
`subgroup`	подгруппа	—
`n_treatment`	n в группе лечения	—
`events_treatment`	события в лечении	—
`n_control`	n в контроле	—
`events_control`	события в контроле	—

Общая OR — 0,62 (95 % ДИ 0,46–0,84). В подгруппах — 0,56–0,67; у женщин, ≥65 лет и ХБП интервал пересекает 1.

Генератор: `05_charts/16_forest/scripts/make_data.py → data/16_dataset.csv`.

5.16.3 Плохой график

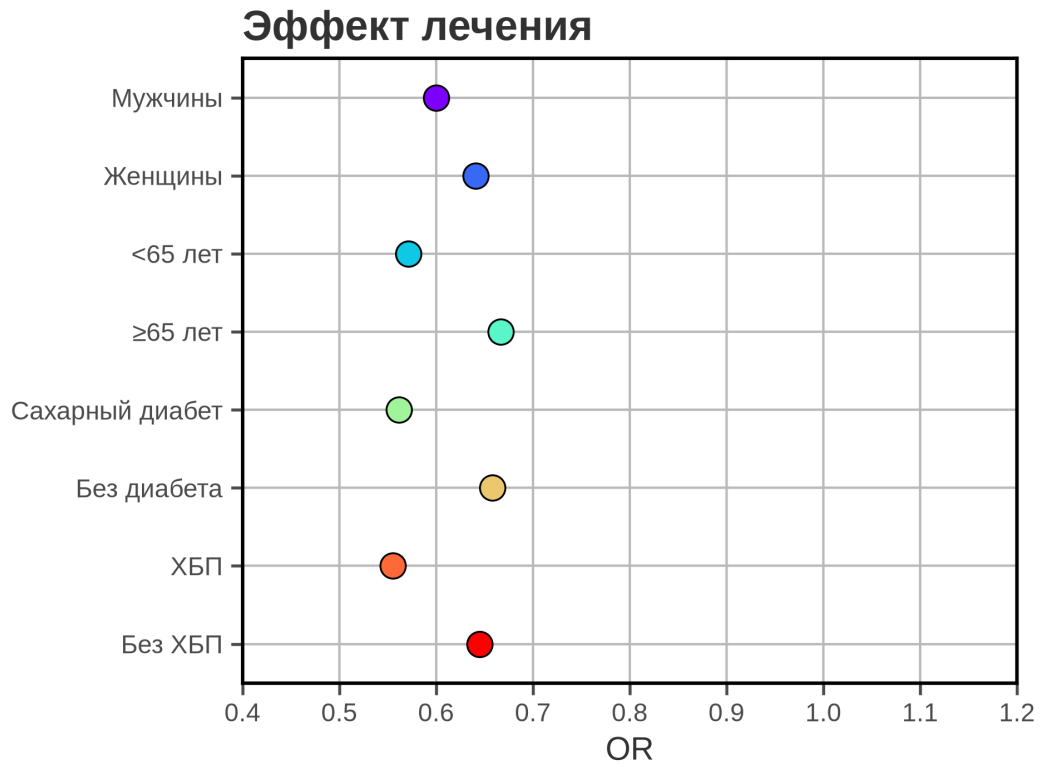


Рисунок 5.16.1. Плохой forest: только точки OR, линейная ось, нет ДИ, линии 1 и общей оценки.

Код: `05_charts/16_forest/scripts/bad_plot.py`.

Что с ним не так:

1. **Нет доверительных интервалов.** Точка без CI не показывает неопределённость; подгруппы выглядят точнее, чем есть.
2. **Линейная ось OR.** Расстояния между 0,5 и 0,7 и между 1,0 и 1,2 не сопоставимы; лог-шкала обязательна.
3. **Нет линии OR = 1.** Непонятно, где «нет эффекта».
4. **Радужные точки, тяжёлая сетка, полная рамка.**
5. **Нет общей оценки и n.**
6. **Заголовок «Эффект лечения».** Не сообщает направление и неопределённость.

5.16.4 Правильный график

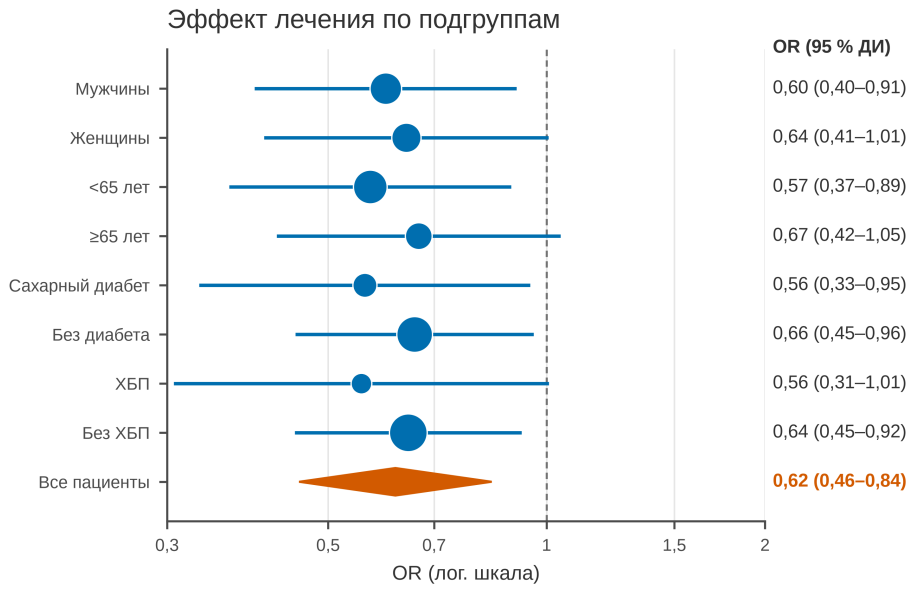


Рисунок 5.16.2. Правильный forest: лог-ось 0,3–2, 95 % ДИ, линия 1, размер по n, ромб общей оценки.

Код: `05_charts/16_forest/scripts/good_plot.py`.

Что улучшено:

1. **95 % ДИ для каждой подгруппы.**
2. **Логарифмическая ось 0,3–2,0.** OR симметричны относительно 1.
3. **Линия OR = 1** — референс «нет эффекта».
4. **Размер квадрата пропорционален n.** Видно, где оценка точнее.
5. **Ромб общей оценки** внизу; OR 0,62 (0,46–0,84).
6. **Справа — OR (95 % ДИ), слева — подгруппы.**
7. **Один цвет, лёгкая сетка, 170 мм.**

CI, пересекающие 1, — не «отсутствие эффекта», а недостаток точности. Не ранжируйте подгруппы по p-value и не делайте причинных выводов из подгруппового анализа.

5.16.5 Сопоставление

Что было	Почему плохо	Что сделано
нет CI	не видна неопределённость	95 % ДИ
линейная ось	OR искажены	лог-ось 0,3–2
нет линии 1	нет референса	пунктир OR = 1
радуга	CVD, декор	один цвет
нет размера по n	не видна точность	размер квадрата
нет общей оценки	нет итога	ромб
нет таблицы справа	нужно считать в уме	OR (95 % ДИ)
«Эффект лечения»	нет сообщения	заголовок о подгруппах
нет n	непонятна точность	n в данных

5.16.6 Чек-лист forest

- ☐ Для OR/RR/HR — логарифмическая ось.
- ☐ Есть линия «нет эффекта» (1).
- ☐ Показаны 95 % ДИ, а не только точки.
- ☐ Размер маркера отражает вес/n.
- ☐ Есть общая оценка (ромб/линия).
- ☐ Подгруппы не ранжированы по значимости.

- ❐ Указаны n и единицы эффекта.
- ❐ CI, пересекающие 1, не поданы как «нет эффекта».
- ❐ Подгрупповой анализ не подан как причинный.
- ❐ Рисунок проверен в конечном размере.

5.16.7 Как воспроизвести

```
uv sync
uv run python 05_charts/16_forest/scripts/make_data.py
uv run python 05_charts/16_forest/scripts/bad_plot.py
uv run python 05_charts/16_forest/scripts/good_plot.py
```

Ключевой фрагмент:

```
odds = (a / b) / (c / d)
se = np.sqrt(1/a + 1/b + 1/c + 1/d)
low = np.exp(np.log(odds) - 1.96 * se)
high = np.exp(np.log(odds) + 1.96 * se)

ax.set_xscale("log")
ax.axvline(1, color="#777777", linestyle="--")
ax.hlines(y, low, high, color=PRIMARY_BLUE)
ax.scatter(odds, y, s=n_total / 3, color=PRIMARY_BLUE)
```

Для мета-анализа вместо OR Уолфа используйте модель с фиксированным/случайным эффектом и вес исследований.

5.16.8 Что дальше

Следующий график — **5.17 slope**: изменение показателя между двумя точками для многих групп. У него будет свой генератор и свой `data/17_dataset.csv`.

Источники

- Cumming G. *Understanding the New Statistics*. Routledge, 2012. — routledge.com
- Cochrane Handbook, Chapter 10 — training.cochrane.org
- Wilke C. O. *Fundamentals of Data Visualization*. 2019. — clauswilke.com/dataviz
- Matplotlib: `hlines` — matplotlib.org